

Control Neuronal

Pastora Vega Cruz/Rosalba Lammana

Dpto. Informática y Automática

USAL

Control Neuronal

Pastora Vega Cruz/Rosalba Lammana

Dpto. Informática y Automática

USAL

Control con Redes Neuronales

- **Aplicación de las Redes Neuronales en Control**
- Identificación de sistemas dinámicos con Redes Neuronales
- Control de Procesos con Redes Neuronales
 - Controladores Neuronales.
 - Esquemas de control neuronal de diseño indirecto
- Bibliografía

Aplicación de las Redes Neuronales en Control

Inspiradas en redes biológicas son eficientes aproximadores universales de funciones no-lineales con capacidad de aprendizaje implícito

Su naturaleza facilita el modelado de sistemas de múltiples entradas y salidas

Su estructura paralela permite procesar de forma rápida la información

Utilización de topologías específicas de control

Presentan buena tolerancia a fallos

Aunque se empleaban inicialmente para la obtención de modelos experimentales y ajustando sus parámetros para minimizar una cierta función de coste usando datos experimentales actualmente tienen muchas más aplicaciones



Interés de las Redes Neuronales en identificación y control

Estado del arte

- Interés creciente dado el gran éxito obtenido en muchas y muy diversas aplicaciones reales
- Software diseño de Redes uso muy extendido y bajo costo
- Dificultades teóricas en asegurar la estabilidad cuando se utilizan redes neuronales para identificación y control de sistemas dinámicos hacen que sea un campo abierto de investigación

Aplicaciones de las redes neuronales en control

- Redes neuronales artificiales : Gran variedad de modelos



Mapeado no lineal entre entradas-salidas

Reconocimiento de patrones

- Aplicaciones: Modelado y control de sistemas dinámicos, Supervisión, Detección de fallos
- Características distintivas: PARALELISMO Y APRENDIZAJE

Aplicaciones de las redes neuronales en control

- Modelado de la dinámica de los procesos (Identificación de sistemas)
- Filtración de las señales ruidosas
- Modelación de las acciones de los operadores humanos
- Interpretación de datos procedentes de sensores
- Realización de sensores virtuales
- Detección y diagnóstico de fallas
- Control de procesos

Control con Redes Neuronales


- Aplicación de las Redes Neuronales en Control
- **Identificación de sistemas dinámicos con Redes Neuronales**
- Control de Procesos con Redes Neuronales
 - Controladores Neuronales.
 - Esquemas de control neuronal de diseño indirecto
- Bibliografía

Identificación con redes neuronales


Identificación de sistemas: Dado un conjunto de datos experimentales $u(t)$, $y(t)$, minimizar una función objetivo de error respecto los parámetros desconocidos de un **modelo dinámico** $y_m = f(\theta, t)$

Ejemplo

$$V = \frac{1}{N} \sum_{t=1}^N e(t)^2 = \frac{1}{N} \sum_{t=1}^N [(y(t) - y_m(t))]^2$$




Identificación con redes neuronales



Identificación con redes neuronales


Red Neuronal Multi-capa estática



Identificación con redes neuronales

Red Neuronal



- **Nodo** j-ésimo de la capa m



- w_{ji} : **peso** que conecta la i-ésima entrada al nodo j
$$v_j(k) = \sum_{i=0}^N w_{mji} x_{0j}(k)$$
- f_i : **función de activación**
$$x_{mj}(k) = f_j(v_j(k))$$

Aplicaciones de las redes neuronales en control

Aprendizaje supervisado



Identificación con Redes Neuronales

Pasos a seguir en la identificación de sistemas

- Diseño de experimentos para la obtención de datos
 - Elegir las señales de entrada
 - Cuáles señales medir y cuándo medirlas
- Determinación de la estructura del modelo
 - Estructura fenomenológica
 - Modelo caja negra
- Estimación de los parámetros del modelo
 - El mejor modelo
 - El criterio
- Validación del modelo
 - Procedimientos de prueba
 - Usos posteriores

Identificación con redes neuronales

Diseño de experimentos

- Forma, duración del experimento
- Frecuencia de muestreo
- Diseño de señales de excitación:
 - Entradas deben cubrir todo el rango de amplitud y frecuencia a las que va a estar sometido el sistema

Determinación de la estructura del modelo

- Familia de estructuras
 - Modelos lineales
 - Redes neuronales multi-capas
 - Modelos no lineales
- Sub-conjunto de familias
 - Auto-regresivo, Determinístico, Discreto, etc.

Identificación con redes neuronales

Representación de la dinámica con redes neuronales

La dinámica del proceso puede ser introducida a la

R-N, mediante alguno de los siguientes **mecanismos** :

- Utilizando una **Red estática** e introduciendo a la R-N, historia pasada de la planta. Se utiliza una red multi-capa y un modelo de identificación serie-paralelo.(K.J.Hunt et al. (1992))
- Utilizando una **Red Recurrente** (con conexiones en retro-alimentación). En este caso se emplearía un modelo de identificación paralelo.
- Agregando el comportamiento dinámico a los nodos.

Identificación con redes neuronales

Representación de la dinámica con redes neuronales

Redes estáticas

- Proporcionan un mapeado estático no lineal entre entradas y salidas
- Pueden utilizarse redes estáticas para sistemas cuya relación entrada / salida equivale a un sistema cuyo estado depende de un conjunto fijo de valores pasados de sus entradas y salidas

$$x(t) = f(y(t), y(t-1), \dots, y(t-n), u(t-1), \dots, u(t-m))$$

- Representación de la dinámica mediante ventanas deslizantes de datos que contienen un número predefinido de valores pasados E/S y utilización de un [modelo serie paralelo](#)



Redes dinámicas o recurrentes

- Representación de la dinámica con conexiones hacia atrás y retardos evitando el uso de ventanas de datos, dando lugar a relaciones dinámicas y utilización de un [modelo paralelo](#)

$$x(t) = f(\text{número infinito de valores de } y \text{ e } u)$$

Identificación con redes neuronales

- Modelo de Identificación Serie-Paralelo $\hat{y}(t+1) = \hat{\alpha}_0 y(t) + \hat{\alpha}_1 y(t-1) + u(t)$





Red Neuronal estática

$$\hat{y}(\underline{\theta}) = g_i(\underline{\theta}) = F_i \left(\sum_{j=1}^{NH} W_{ij} f_j \left(\sum_{l=1}^{NI} w_{jl} \varphi_l + w_{j0} \right) + W_{i0} \right)$$

Identificación con redes neuronales

- Modelo de Identificación en Paralelo $\hat{y}(t+1) = \hat{\alpha}_0 \hat{y}(t) + \hat{\alpha}_1 \hat{y}(t-1) + \dots + u(t)$




Red Neuronal recurrente

Predicción con redes neuronales con redes estáticas


Modelo

$$\hat{y}(t|t-1) = G(u(t-1), u(t-2), \dots, y(t-1), y(t-2), \dots, v(t-1), v(t-2), \dots)$$

Estructura de la Red Neuronal




Entrenamiento de la Red Neuronal



Vectores de entrada y de salida de la red de tamaño variable

Ejemplo de Modelado con Redes Estáticas


Proceso de difusión de una fábrica azucarera




Sección de difusión

Objetivos

- ★ Reducir la polarización de la pulpa agotada
- ★ Limitar el caudal de jugo verde a la siguiente sección



Control basado en modelos no-lineales del proceso



Modelo

$$[P_{pag}] = f\left(\frac{F_{afr}}{W_{cos}}, P_{cos}, P_{pag}, W_{cos}\right)$$

Ejemplo de Modelado con Redes Estáticas

Entradas de la red

Caudal de agua/flujo cosetas

Polarización de coseta P_{cos}

$$e1 = fafr/wcos(t-1)$$

$$e2 = fafr/wcos(t-2)$$

$$e3 = fafr/wcos(t-3)$$

$$e4 = fafr/wcos(t-4)$$

Flujo de cosetas $Wcos$

Polarización de pulpa agotada

$$e5 = wcos(t-1)$$

$$e6 = wcos(t-2)$$

$$e7 = wcos(t-3)$$

$$e8 = wcos(t-4)$$


$$e9 = pcos(t-1)$$

$$e10 = pcos(t-2)$$


$$e11 = ppag(t-1)$$

Salida de la red

$$sal = ppag(t)$$



Polarización pulpa agotada



Identificación con redes neuronales

Aprendizaje de la Redes: Estimación de Parámetros

- Secuencias de entrenamiento de longitud N
- Criterios optimización

Minimización del funcional cuadrático de error

$$J(\theta, i) = \frac{1}{2N} \sum_{k=1}^N \underline{E}^i(k)^T P \underline{E}^i(k)$$

θ : vector de coeficientes, iteración i

P: matriz definida positiva

$\underline{E}^i(k)$: vector de los errores en el instante k

- Métodos recursivos
 - Búsqueda iterativa en la dirección del descenso del gradiente

$$\theta_{i+1} = \theta_i + \mu_i \Delta \theta_i \quad \Delta \theta_i = -\mu_i \nabla J(\theta_i) \quad \Delta \theta_i = -\mu_i H_i \nabla J(\theta_i)$$

- Algoritmo de retropropagación del error para redes multicapas (Hilera y Martínez, 1995; Haykin, 2007)
 - Algoritmos genéticos
- Problemas de convergencia

Validación del modelo

- Evaluación de los errores de predicción
- Estimación del error de generalización promedio
- Convergencia del error y velocidad de convergencia
- Visualización de la habilidad del modelo para predecir:
Datos de entrenamiento, Datos de validación
- Estabilidad del modelo ante cambios abruptos en las entradas

Control con Redes Neuronales

- Aplicación de las Redes Neuronales en Control
- Identificación de sistemas dinámicos con Redes Neuronales
- **Control con Redes Neuronales**
 - Controladores Neuronales
 - Esquemas de control neuronal de diseño directo
 - Esquemas de control neuronal de diseño indirecto
- Bibliografía

Control Neuronal


Clasificación de métodos de control neuronal: Control directo y control indirecto

Diseño directo: la propia red neuronal previamente entrenada calcula la señal de control

Características: Frecuentemente son esquemas basados en modelos pero no siempre

Ventaja: Fácil implementación

Desventaja : Entrenamiento complicado que frecuentemente requieren re-entrenamiento y/o esquemas en línea que adaptan la red neuronal.



Control Neuronal

Diseño indirecto: Una red neuronal se usa como modelo del sistema. El controlador se diseña de empleando técnicas más convencionales


Características

- Hay que realizar previamente la experimentación e identificación del sistema.
- Con el modelo neuronal, se diseña el controlador en línea

Ventajas

- Son flexibles y de mayor aplicabilidad práctica
- Hay que realizar previamente la experimentación e identificación del sistema.

Desventajas: Requieren una implementación compleja



Redes neuronales en Control de Procesos

- **Controladores neuronales directos**

- Controlador Neuronal Inverso
- Control por Adaptativo por Modelo de Referencia
- Control Neuronal Adaptativo Indirecto
- Control por Modelo Interno
- Control Supervisor

- **Métodos de diseño neuronal indirecto**


- Control Inferencial
- Control Neuronal PID Autoajustable
- Control Neuronal Autoajustable (Gain Scheduling)
- Control Predictivo

Controlador Neuronal Inverso

Controlador: La red neuronal debe ser entrenada como inverso del sistema para garantizar el fiel seguimiento de la referencia

Si el sistema viene descrito como: $y(t+1) = g(y(t), \dots, y(t-n+1), u(t), \dots, u(t-m))$


la red debe producir $\hat{u} = \hat{g}^{-1}(y(t), \dots, y(t-n+1), u(t-1), \dots, u(t-m))$



Implementación del sistema de control

Controlador Neuronal Inverso

Esquema de aprendizaje



- La salida del sistema es usada como entrada a la R-N y la entrada como salida.
- La salida de la R-N es comparada con la señal de entrenamiento. El error es usado para entrenar a la R-N.
- Esta estructura debería forzar a la R-N, representar la inversa de la planta.

Desventajas :

- El procedimiento de entrenamiento no es directo.
- Si el mapeo de la planta no lineal, no es uno a uno, entonces se puede obtener un modelo inverso incorrecto y valores indeseados del control

Controlador Neuronal Inverso

- Desventajas:
- No se producen los valores deseados. La señal de entrenamiento debe ser seleccionada para muestrear un amplio rango de posibles señales de entradas al sistema. Esto es muy difícil de definir a priori (logrando además entradas persistentemente excitadoras).
- La meta en el contexto de control, es hacer que la salida del sistema siga una referencia deseada, y sin embargo la señal de entrenamiento (error de ajuste) en el modelo inverso directo no se corresponde al valor explícito que se desea minimizar, que sería en efecto, el error de control:

$$J(\theta, Z^N) = \frac{1}{2N} \sum_{t=1}^N (r(t) - y(t))^2$$

Minimizar este funcional es imposible fuera de línea porque $y(t)$ depende de la salida de la red en proceso de ajuste ($u(t-1)$)

Controlador Neuronal Inverso

Señal de entrenamiento

Esquema de aprendizaje especializado

- La red inversa puede ser entrenada en cambio, por minimización iterativa del siguiente funcional:

$$J_t(\theta, Z^t) = J_{t-1}(\theta, Z^{t-1}) + (r(t) - y(t))^2$$

- Como el ajuste del controlador es en línea, se trata de control adaptativo.
- Si se asume método de gradiente descendente para la minimización, y además, que J_{t-1} ya ha sido minimizado, los pesos de la red inversa, se re-ajustarían según:

$$\hat{\theta}(t) = \hat{\theta}(t-1) - \mu \frac{de^2(t)}{d\theta}$$

$$\frac{de^2(t)}{d\theta} = -\frac{dy(t)}{d\theta} e(t) = -\frac{\partial y(t)}{\partial u(t-1)} \frac{du(t-1)}{d\theta} e(t)$$


Jacobiano del sistema

Una red entrenada con el modelo de la planta puede ser usada para estimar el Jacobiano del sistema: $\frac{\partial y(t)}{\partial u(t-1)} \approx \frac{\partial \hat{y}(t)}{\partial u(t-1)}$

Además, despreciando la dependencia de $u(t-1)$ respecto a los estimados en instantes anteriores, se puede aproximar:

$$\frac{\partial u(t-1)}{\partial \theta} \approx \frac{du(t-1)}{d\theta}$$


Controlador Neuronal Adaptativo Inverso Especializado



- La R-N tiene como entrada la señal de referencia
- Se ignora que la red inversa es recurrente $\Rightarrow$ se ignora la dependencia regresiva de la salida respecto a los pesos anteriores siendo ésta es una simplificación que suele converger bastante bien.
- La señal de error para el algoritmo de entrenamiento es la diferencia entre la señal de referencia y la salida de la planta o del modelo neural (caso plantas ruidosas,..)
- Se demuestra que usando la salida de la planta, se produce el inverso exacto, aún cuando el modelo de R-N directo, sea inexacto.
- **Características de los controladores inversos:** acciones de control muy activas y violentas ante escalones $\Rightarrow$ se modifica la referencia según un modelo amortiguado $\Rightarrow$ esquema de control por

Controlador Neuronal por referencia a un modelo

el entrenamiento forzará al controlador a actuar como una inversa “desajustada” según el modelo de referencia.



Control Neuronal por referencia a un modelo:

- El comportamiento deseado se especifica a través de un modelo de referencia lineal estable.
- El sistema de control está diseñado para determinar el control $u(t)$ tal que para $t > 0$ $\lim_{t \rightarrow \infty} |y_m(t) - y(t)| \leq \varepsilon$ para $\varepsilon > 0$
- El error así definido se usa para el entrenamiento y adaptación de la red neuronal controladora
- Debe idearse técnica para que el error de control pueda ser retroalimentado para proveer la dirección del gradiente descendente para el reajuste de los pesos de la red controladora. (Cálculo de e_u)

Controlador Neuronal por referencia a un modelo

- Los valores atrasados de las entradas/salidas de la planta, forman la entrada a la R-N-C, la cual genera la señal de control retroalimentado a la planta.
- R-N-I es ajustada retropropagando e_i .
- R-N-C es ajustada retropropagando el error entre el modelo de referencia y el modelo identificado.

Controlador Neuronal por referencia a un modelo

Ventajas


- El controlador se entrena solo con las trayectorias de referencia relevantes (deseadas)
- Puede usarse en sistemas con dinámicas variantes en el tiempo ya que dispone de un mecanismo de adaptación en línea

Desventajas

- La lenta convergencia inicial de los algoritmos de gradiente conjuntamente con gran número de pesos a ajustar pueden conducir al sistema fuera de los rangos de operación. Se puede hacer necesario:
 - Inicializar la red inversa con métodos de ajuste general, o bien
 - Usar algoritmos del tipo Gauss-Newton para la optimización
- Hasta el momento no hay estudios disponibles que garanticen métodos para ajustar establemente el controlador neuronal, basados en el error de salida. Esto es debido a la naturaleza no lineal del problema

Esquemas de Control Expertos

Control supervisor



- Entre las aplicaciones se encuentra el modelaje y adquisición de destrezas, para ser transferidas a robots y telerobots.
- Es una alternativa aproximada de los sistemas expertos.

Controlador Neuronal Adaptativo por referencia a un modelo

La característica principal es que la red directa y la red neuronal controladora se va adaptando on-line

Control con Redes Neuronales

- Introducción
- Identificación y predicción con Redes Neuronales
- Control de Procesos con Redes Neuronales
 - Controladores Neuronales. Control Predictivo
 - Control Inverso
- Bibliografía

Redes neuronales en Control de Procesos

- **Controladores neuronales directos**


- Controlador Neuronal Inverso
- Control por Adaptativo por Modelo de Referencia
- Control Neuronal Adaptativo Indirecto
- Control por Modelo Interno
- Control Supervisor

- **Métodos de diseño neuronal indirecto**


- Control Inferencial
- Control Neuronal PID Autoajutable
- Control Neuronal Autoajutable (Gain Scheduling)
- **Control Predictivo**

Neural Model Predictive Control (NMPC)


- ✓ Control strategy based in the on-line use of a model to predict the future behaviour of the process output over a certain temporal horizon, as a function of the future control actions
- ✓ The best control action is selected using an optimization procedure
- ✓ Many methods sharing some common principles



MPC



Model Predictive Control (MPC)




$$\min_{u(t), u(t+1), \dots} J = \sum_{j=N1}^{N2} [\hat{y}(t+j) - w(t+j)]^2 + \sum_{j=0}^{Nu-1} [\beta \Delta u(t+j)]^2$$

$y(t+j)$ are related with $u(t), u(t+1) \dots$ through the prediction equations computed with the process model. Constraints

MPC, control implementation

At time t , $u(t)$ is applied to the process



An open loop optimization problem is solved every sampling time, starting in the current state

$u(t)$, $u(t+1)$, $u(t+2)$ are considered independent variables in the optimization problem and they are evaluated by minimising

Prediction horizon: N_2


Control horizon: N_u

Weighting control factor β



$$\min_{u(t), u(t+1), \dots} J = \sum_{j=N_1}^{N_2} [\hat{y}(t+j) - w(t+j)]^2 + \sum_{j=0}^{N_u-1} [\beta \Delta u(t+j)]^2$$


Controller parameters



Prediction horizon: $N2$





Control horizon: Nu

Weighting control factor β



$$\min_{u(t), u(t+1), \dots} J = \sum_{j=N1}^{N2} [\hat{y}(t+j) - w(t+j)]^2 + \sum_{j=0}^{Nu-1} [\beta \Delta u(t+j)]^2$$

MPC Moving horizon



...at time $t + 1$, the whole process is repeated with the information available

Time and efforts

Control Without model

Process
analysis

Controller
tuning

With model

Modeling
Identification

Control
especifications

MPC advantages

Able to deal with complex dynamical systems, with interaction, constraints, different number of MV and CV, disturbances, and basic ideas **easy to understand**

disadvantages

Control Predictivo Neuronal (MPC)

Desventajas

- El problema numérico de optimización puede ser muy pesado y consumir en cada iteración un tiempo mayor a la óptima frecuencia de muestreo y control del sistema.

λ

- Para permitir una frecuencia de muestreo razonablemente rápida, $N_u=1$ se utiliza en la mayoría de los casos prácticos.

CONCLUSIONES

- Las redes neuronales constituyen modelos muy precisos de sistemas no lineales. Sin embargo, la determinación de la “mejor” red es un problema no trivial
- Los controladores neuronales predictivos que generalmente se reportan en la literatura, plantean un problema de optimización muy complejo, que en muchos casos hace imposible implantar el esquema en tiempo real.
- La rapidez del sistema se ve afectada a medida que las diferencias entre la planta y el modelo lineal aumentan. Por ejemplo, ante las perturbaciones no medibles en la concentración de la solución básica.
- El esquema GPC es muy preciso.

BIBLIOGRAFIA

- Haykin S. "Neural Networks. A comprehensive foundation". Prentice Hall. 3a. Ed. Mayo 2007.
- Hertz J., A. Krogh y R. Palmer. "Introduction to the Theory of Neural Computation". Addison-Wesley, 1991.
- Hilera J. y V. Martínez. "Redes Neuronales Artificiales. Fundamentos, modelos y aplicaciones". Addison-Wesley Iberoamericana. Ra-ma. 1995.
- Jain L. C.(Editor), N. M. Martin (Editor). "Fusion of neural Networks, Fuzzy Sets, and Genetic Algorithms: Industrial Applications" (International Series on Computational Intelligence). 2000.
- Kasabov N. K. "Foundations of Neural Networks, Fuzzy Systems and Knowledge Engineering". Bradford Book. MIT Press. 1996.
- Kosko B. "Neural Networks and Fuzzy Systems. A dynamical system approach to machine intelligence". Prentice-Hall, Inc. 1992.
- Norgaard M., O. Ravn, N.K. Poulsen and L. K. Hansen. "Neural Networks for Modelling and Control of Dynamical Systems: A Practitioner's Handbook (Advanced Textbooks in Control and Signal Processing). Springer. 2006.
- Page G.F, Gromm J.B. y Williams D. " Applications of Neural Networks to Modelling and Control". Chapman & Hall. Londres, 1993.