

Guía explicada de la práctica

«Del problema científico al artículo» — Pasos 1, 2 y 3

Angel Luis Acosta González · Máster Universitario en Sistemas Inteligentes (USAL) ·

Metodología de la Investigación

Qué se hizo, con qué herramientas, dónde se ejecutó y de dónde sale cada dato, fórmula, tabla y figura · 30 de septiembre de 2026

Para qué sirve esta guía. Para que entiendas, paso a paso, todo lo que hemos hecho y puedas explicarle a la profesora el origen de cada número. Está escrita para alguien que empieza: cada concepto técnico lleva una explicación sencilla y, cuando ayuda, una analogía (recuadros verdes). Los avisos importantes van en recuadros amarillos. Al final (sección 12) hay una lista de preguntas que la profesora podría hacerte, con la respuesta.

Contenido

1. Visión general: el camino completo en una página
2. Dónde está cada archivo
3. Paso 1 — Ficha del problema, pregunta, objetivos e hipótesis
4. Paso 2 — Búsqueda bibliográfica y el archivo .bib
5. Paso 3 — Herramientas: lenguaje, librerías y dónde se ejecutó
6. El modelo físico: cada fórmula y cada constante
7. El conjunto de datos (dataset)
8. Los tres modelos de aprendizaje automático
9. Cómo se evaluaron: validación cruzada, métricas y McNemar
10. Cómo se hicieron la tabla, las figuras y el PDF de resumen
11. Cómo repetirlo tú mismo en tu ordenador
12. Preguntas que puede hacerte la profesora (con respuesta)
13. Trazabilidad: de dónde sale cada dato

1. Visión general: el camino completo en una página

La práctica pide ir del problema científico al artículo en cinco pasos. Hasta ahora hemos completado tres. La idea de fondo es sencilla: tu trabajo de fin de grado (TFG, RUT MIIT 2026) diseñó una red DWDM de fibra óptica para el tramo ferroviario Moscú-Kazánskaya - Riazán-1 y comprobó con una fórmula que el caso más desfavorable cumplía la calidad exigida. Nosotros preguntamos si un modelo de aprendizaje automático puede decir, *para cualquier canal y con la red envejecida*, si cumple o no esa calidad.

La Fig. 1 resume el recorrido completo, de izquierda a derecha y de arriba abajo. Cada caja corresponde a una sección de esta guía.




Fig. 1. Flujo de trabajo de los Pasos 1-3: de los datos del TFG a los entregables de Studium.

Analogía. Es como estudiar si un médico puede predecir qué pacientes enfermarán. No tenemos historiales reales, así que construimos un «simulador de pacientes» basado en la fisiología conocida (el modelo físico), generamos 10 000 pacientes ficticios, y comprobamos qué método predice mejor quién enferma usando solo lo que el médico puede medir en consulta.

2. Dónde está cada archivo

Todo está guardado en tu repositorio de GitHub [angelluisacosta99-bit/Molu](#), dentro de la carpeta `master-sistemas-inteligentes/metodologia-de-la-investigacion/practica-del-problema-al-articulo/`. La Tabla 1 lista las carpetas y qué contiene cada una.

Tabla 1. Carpetas de la práctica y su contenido.

Carpeta	Contenido principal
paso-1-planteamiento/	generar_ficha.py (genera la ficha), ficha-paso-1.pdf/.docx (mi versión) y Angel_Luis_Acosta_Gonzalez_Paso1-version-final.pdf (la tuya, la entregada).
paso-2-bibliografia/	referencias.bib (10 artículos), las exportaciones originales de Web of Science, notas-de-lectura.md (resumen de los 10 artículos).
paso-3-experimento/	simulador.py (modelo físico y datos), experimento.py (modelos, evaluación, figuras), experimento.ipynb (cuaderno), datos/, resultados/, figuras/, generar_resumen.py y resumen-paso-3.pdf.
plantilla-lncs/	La plantilla LaTeX de Springer LNCS que dio la profesora (para el Paso 5).
../materiales-de-clase/	Presentación de la asignatura, artículos y pósters de ejemplo, guías de redacción, citas, póster y LaTeX.

3. Paso 1 — Ficha del problema, pregunta, objetivos e hipótesis

Qué pedía la profesora: una ficha de una página con el problema, la pregunta de investigación, la novedad, los objetivos y una hipótesis.

De dónde salió el contenido:

- **Problema:** de tu TFG. El TFG calculó la calidad (factor $Q = 7,37$; $BER = 8,9 \cdot 10^{-14}$) solo para el tramo más desfavorable (Voskresensk - Riazán-1, 108,9 km), una vez y con márgenes fijos. No contempla el envejecimiento, las reparaciones ni el hielo, riesgos que el propio TFG menciona.
- **Umbral de calidad** $BER \leq 10^{-11}$ (equivale a $Q = 6,71$): es la norma que usaba el TFG.
- **Novedad:** la estimación de calidad con aprendizaje automático ya existe en redes troncales [Pointurier 2021; Kozdrowski 2021], también con datos sintéticos [Rottondi 2018], pero no encontramos trabajos en redes ferroviarias.

- **Hipótesis (redacción final):** «Si se entrena un modelo de ensamble (por ejemplo, Random Forest) con parámetros que el operador puede medir, será posible predecir si un canal cumple el umbral $BER \leq 10^{-11}$ con mayor acierto que un modelo lineal sencillo». Sigue el modelo de la presentación de la profesora y del artículo de Espejo et al.: una comparación clara, verificable y sin cifras inventadas.

Herramientas: el script `generar_ficha.py` (Python) escribe el mismo texto en dos formatos: HTML, que Chromium (el navegador) convierte en PDF A4 con Times New Roman 11 pt, y Word (.docx) con la librería `python-docx`. Tú hiciste después tu versión final en Word y es la que se entregó.

4. Paso 2 — Búsqueda bibliográfica y el archivo .bib

Qué pedía: un archivo `referencias.bib` con 8-10 artículos de bases de datos científicas (WoS, Scopus, IEEE), exportado con un gestor bibliográfico.

1. **Búsqueda:** la hiciste tú en clase en **Web of Science** (acceso USAL) con cadenas como ("quality of transmission" OR QoT) AND ("machine learning" OR "random forest") AND ("optical network*" OR DWDM). Salieron 50 registros (`wos-export-2026-09-29.txt`).
2. **Selección:** elegimos 10, los más cercanos al tema, y comprobé con Crossref que ninguno está retractado.
3. **Exportación:** exportaste de WoS en formato BibTeX. Lo que entregaste en Studium es esa exportación sin tocar, solo renombrada (`savedrecs-wos-corto-original.bib`).
4. **Versión de trabajo:** para el artículo usaremos `referencias.bib`, la misma exportación con claves cortas (`rotondi2018`, `kozdrovski2021...`) y el DOI que faltaba de Samadi 2017. Se validó con la librería `pybtex`, que lee el archivo como lo haría LaTeX y confirma que hay 10 entradas sin errores.
5. **Lectura:** `notas-de-lectura.md` resume los 10 artículos. De ellos salieron decisiones del Paso 3: Random Forest por Rottondi y Kozdrovski; cuidar el desbalance de clases por Kozdrovski; no dar a los modelos las causas ocultas, siguiendo a Aladin 2020.

5. Paso 3 — Herramientas: lenguaje, librerías y dónde se ejecutó

Qué pedía: un diseño experimental con al menos una tabla y una figura, entregando datos y código.

Dónde se ejecutó: yo (Claude, el asistente de IA) escribí y ejecuté el código en un ordenador Linux en la nube (el entorno de Claude Code), con Python 3.11. Todo quedó guardado en tu repositorio. El cuaderno `experimento.ipynb` se entrega ya ejecutado: al abrirlo en VS Code se ven los resultados sin ejecutar nada. Si lo ejecutas tú (sección 11), obtendrás los mismos datos, porque usamos una «semilla» fija.

La Tabla 2 recoge el lenguaje y cada librería, con la versión exacta usada y para qué sirvió.

Tabla 2. Software utilizado en el Paso 3.

Herramienta	Versión	Para qué
Python	3.11.15	Lenguaje de programación de todo el experimento.
NumPy	2.4.6	Cálculo numérico: fórmulas y números aleatorios.
pandas	3.0.6	Tablas de datos (el dataset y la tabla de resultados); guarda el CSV y el .tex.
SciPy	1.17.1	Función erfc (paso de Q a BER) y distribución χ^2 (McNemar).
scikit-learn	1.9.1	Regresión logística, Random Forest, validación cruzada, métricas, importancia por permutación.
XGBoost	3.2.0	El tercer modelo (gradient boosting).
Matplotlib	3.11.2	Las tres figuras (PNG a 300 ppp y PDF vectorial).
Jupyter (nbformat)	—	El cuaderno experimento.ipynb, creado por crear_cuaderno.py.
Chromium	—	Convierte HTML en PDF (ficha del Paso 1, resumen del Paso 3 y esta guía).

¿Qué es la «semilla» (semilla=42)? Los números «aleatorios» de un ordenador salen de una receta fija que arranca en un número inicial. Con la misma semilla sale exactamente la misma secuencia, como barajar las cartas siempre igual. Por eso cualquiera que ejecute el código obtiene los mismos 10 000 canales y los mismos resultados. El 42 no tiene ningún significado; solo importa que sea siempre el mismo.

6. El modelo físico: cada fórmula y cada constante

El archivo `simulador.py` contiene un modelo de cómo viaja la luz por la fibra y llega al receptor. No es un modelo inventado: son las fórmulas estándar de los sistemas ópticos de 10 Gbit/s con modulación NRZ y detección directa (IM/DD, como tu red). Con él calculamos, para cada canal, si cumple o no.

Si la profesora pregunta «¿por qué datos sintéticos si el modelo es real?»: las fórmulas son reales, pero no tenemos mediciones de una red real envejecida (ningún operador ferroviario las publica). Simulamos muchos estados posibles de la red (años, reparaciones, hielo) y el modelo físico dice qué pasaría en cada uno. Por eso los datos se llaman sintéticos: los genera un simulador a partir de física conocida, no un aparato de medida.

6.1 Constantes y de dónde sale cada una

La Tabla 3 lista todas las constantes del código (primeras líneas de `simulador.py`) con su origen. Es la tabla más importante para defender el trabajo: separa lo que viene de tu TFG de lo que es una suposición nuestra.

Tabla 3. Constantes del modelo físico y su origen.

Constante (código)	Valor	Significado	Origen
ESTACIONES_KM	21 estaciones, 0-198,3 km	Kilómetro de cada estación	TFG (tabla de estaciones). Se omite Rybnoye porque su kilómetro no se lee en la tabla.
ALFA_NOMINAL	0,22 dB/km	Atenuación de la fibra G.652 a 1550 nm	TFG
LONG_CONSTRUCCION, PERDIDA_EMPALME	4 km; 0,1 dB	Un empalme de fábrica cada 4 km, 0,1 dB cada uno	TFG
SENSIBILIDAD	-25 dBm	Potencia mínima del receptor	TFG
PERDIDA_CONECTORES	1,0 dB	Dos conectores	Valor típico de ficha técnica (0,5 dB por conector)
PERDIDA_OADM	5,0 dB	Multiplexor + demultiplexor	Valor típico de ficha técnica. Simplificación: se aplica igual a todos los canales.
Q_SENSIBILIDAD	7,03	Q en la sensibilidad ($BER = 10^{-12}$)	Cálculo: $BER(7,03) = 1,03 \cdot 10^{-12}$
Q_UMBRAL	6,71	Q mínimo exigido ($BER = 10^{-11}$)	Norma del TFG; comprobado: $BER(6,71) = 9,7 \cdot 10^{-12}$
MARGEN_DISENO	3 dB	Si el margen nominal es menor, se pone amplificador	Suposición de diseño (margen habitual)
DISPERSION	17 ps/(nm·km)	Dispersión cromática de la fibra G.652	Valor estándar de la norma UIT-T G.652
TOLERANCIA_DISP	1600 ps/nm	Dispersión que tolera el transceptor	Valor típico de transceptor de 10G (suposición)
BO_BE	$12,5/7,5 \approx 1,67$	Ancho óptico de referencia (0,1 nm = 12,5 GHz) / ancho eléctrico del receptor (7,5 GHz)	Valores estándar para 10G
Figura de ruido del EDFA	6-7 dB (+ envejecimiento)	Ruido que añade el amplificador	TFG (rango de 6-9 dB)

6.2 Paso a paso: cómo se calcula un canal

(a) Elegir un canal. Un canal va de una estación a otra. Hay 208 pares posibles separados por al menos 5 km; el código elige uno al azar para cada una de las 10 000 filas. Su longitud d es la diferencia de kilómetros.

(b) Pérdida nominal (la red recién instalada). Es la suma de todo lo que «se come» la señal:

$$\text{Pérdida}_{\text{nominal}} = 0,22 \cdot d + [d/4] \cdot 0,1 + 1,0 + 5,0 \quad [\text{dB}]$$

([] significa redondear hacia arriba: $33,4/4 = 8,35 \rightarrow 9$ empalmes.) En código: `perdida_nominal(d_km)`.

(c) Regla de diseño: ¿lleva amplificador? El láser emite 0 dBm. Si la potencia que llega (-Pérdida) supera la sensibilidad (-25 dBm) en menos de 3 dB, el diseñador pone un preamplificador EDFA:

$$\text{margen} = -\text{Pérdida}_{\text{nominal}} - (-25) \rightarrow \text{amplificado si margen} < 3 \text{ dB}$$

Con estos números, todo canal de más de 65 km va amplificado (a 65,0 km el margen es justo 3 dB). Los amplificados llevan un EDFA cada 110 km como máximo: número de vanos $n = \lceil d/110 \rceil$ (1 o 2 en esta línea).

(d) Envejecimiento y averías (la red en explotación). Aquí entra el azar. La Tabla 4 resume qué se sortea para cada canal (líneas «Estado de explotación» y «Causas físicas ocultas» de generar()). Estos rangos son **supuestos del estudio**, no salen del TFG, y habrá que declararlos así en el artículo.

Tabla 4. Variables aleatorias de degradación (por canal).

Qué	Cómo se sortea	¿Lo ve el operador?
Antigüedad	Uniforme 0-25 años	Sí
Temperatura	Uniforme -30 a 35 °C (clima de Riazán)	Sí
Averías reales	Poisson con media = tasa $\times d \times$ años; tasa uniforme 0,002-0,015 por km y año	No
Averías registradas	Cada avería real se registra con probabilidad 0,6 (binomial)	Sí
Pérdida por reparaciones	2 empalmes por avería, cada uno uniforme 0,05-0,5 dB	No
Atenuación envejecida	$0,22 + (0-0,0015) \times \text{años} + 0,0002 \times (\text{frío bajo } 0 \text{ °C})/10$ dB/km	No
Empalmes de fábrica	$\lceil d/4 \rceil \times \text{Normal}(0,1; 0,02)$ dB, mínimo 0,03	No
Hielo	Si hace menos de -5 °C, con probabilidad 0,30: pérdida uniforme 0,5-5 dB	No
Conectores sucios	$1,0 +$ exponencial de media 0,4 dB	No
Potencia del láser	$\text{Normal}(0; 0,3)$ dBm $- (0-0,1 \text{ dB}) \times \text{años}$	No
Figura de ruido del EDFA	Uniforme 6-7 dB $+ (0-0,08 \text{ dB}) \times \text{años}$	No
Dispersión residual (amplificados)	Uniforme -250 a 250 ps/nm (queda tras compensar)	No

(e) Potencia recibida real. Se suman todas las pérdidas reales y, si hay varios vanos, se reparten entre ellos. La potencia calculada es la de la entrada de cada amplificador o del receptor:

$$P_{\text{rx}} = P_{\text{láser}} - (\alpha \cdot d + \text{empalmes} + \text{reparaciones} + \text{hielo} + \text{conectores} + 5) / n \text{ [dBm]}$$

(f) Factor Q. El factor Q mide la separación entre «0» y «1» frente al ruido: cuanto mayor, menos errores. Se calcula distinto según el tipo de canal.

- **Canal sin amplificar** (limitado por el ruido térmico del receptor). Q es proporcional a la potencia en unidades lineales: en la sensibilidad (-25 dBm) vale 7,03, y cada 10 dB más lo multiplican por 10.

$$Q_{\text{térmico}} = 7,03 \cdot 10^{(P_{\text{rx}} + 25)/10}$$

- **Canal amplificado** (limitado por el ruido ASE de los EDFA). Primero la OSNR, relación señal/ruido óptica en 0,1 nm, con la regla estándar para 1550 nm (el 58 sale de la energía de un fotón por el ancho de 0,1 nm, -58 dBm):

$$\text{OSNR} = 58 + P_{\text{rx}} - \text{NF} - 10 \cdot \log_{10}(n) \text{ [dB]}$$

Luego Q, con la fórmula de detección directa con ruido señal-ASE (OSNR en lineal):

$$Q_{ASE} = \sqrt{(B_o/B_e) \cdot 2 \cdot OSNR / (1 + \sqrt{(1 + 4 \cdot OSNR)})}$$

Por último se combina con el ruido del receptor: el preamplificador sube la señal, que queda unas 10 veces por encima de la sensibilidad (Q = 70,3):

$$Q = 1 / \sqrt{(1/Q_{ASE}^2 + 1/70,3^2)}$$

(g) Penalización por dispersión cromática. Los pulsos se ensanchan al viajar. En los canales sin amplificar la dispersión acumulada es 17·d ps/nm; en los amplificados, la residual tras compensar. La penalización se resta de Q:

$$\text{Penalización} = 2 \cdot (D_{\text{acum}}/1600)^2 \text{ dB} \rightarrow Q_{\text{efectivo}} = Q \cdot 10^{-\text{Penalización}/10}$$

(h) BER y etiqueta. De Q se pasa a la tasa de errores con la fórmula estándar, y se decide si cumple:

$$\text{BER} = \frac{1}{2} \cdot \text{erfc}(Q / \sqrt{2}) \quad \text{cumple} = 1 \text{ si } Q_{\text{efectivo}} \geq 6,71 \ (\Leftrightarrow \text{BER} \leq 10^{-11})$$

(i) Medición que hace el operador. El transceptor SFP mide la potencia recibida con un error de ±0,5 dB: p_rx_medida = P_rx + Normal(0; 0,5). Es la variable clave del escenario B.

6.3 Tres ejemplos resueltos (red nueva, sin degradación)

Para que veas las fórmulas funcionando, la Tabla 5 calcula tres canales con valores nominales (sin azar) y NF = 6,5 dB. Los números salen de ejecutar las funciones de simulador.py.

Tabla 5. Ejemplos de cálculo con la red recién instalada.

Canal	Pérdida nominal	Margen	¿Amplificado?	Cálculo	Q
33,4 km	7,35 + 9·0,1 + 1 + 5 = 14,25 dB	10,75 dB	No	Q _t = 7,03·10 ^{1,075} = 83,6; D = 568 ps/nm → penalización 0,25 dB	78,9
108,9 km (caso del TFG)	23,96 + 28·0,1 + 1 + 5 = 32,76 dB	−7,76 dB	Sí, 1 vano	P = −32,76 dBm; OSNR = 58 − 32,76 − 6,5 = 18,74 dB; Q _{ASE} = 10,54	10,4
145,8 km	41,78 dB	−16,8 dB	Sí, 2 vanos	P = −20,89 dBm por vano; OSNR = 58 − 20,89 − 6,5 − 3,01 = 27,6 dB; Q _{ASE} = 30,3	27,9

Diferencia con el TFG (Q = 7,37 frente a 10,4): el TFG usó otro planteamiento y, en la revisión, detectamos incoherencias internas en su cálculo (por ejemplo, recalculando sus propios números sale Q = 7,31, no 7,37). Nuestro modelo añade el preamplificador EDFA que exige la regla de diseño. En el artículo el TFG se cita como *el diseño de partida*, no como fuente de estos números.

7. El conjunto de datos (dataset)

generar(n=10000, semilla=42) repite el cálculo de la sección 6 para 10 000 canales y guarda el resultado en datos/dataset.csv, una tabla que se abre con Excel. La Tabla 6 describe sus columnas. Las que empiezan por oculta_ son causas que el operador **no** puede medir: no se dan a los modelos (salvo en el escenario C, de referencia).

Tabla 6. Columnas de datos/dataset.csv.

Columna	Tipo	Qué es
longitud_km, amplificado, n_vanos	Observable (inventario)	Longitud; 1 si lleva EDFA; número de vanos
antiguedad_anios, reparaciones_registradas, temperatura_c	Observable (inventario)	Años en servicio; averías apuntadas; temperatura
p_rx_medida_dbm	Observable (monitorización)	Potencia recibida medida por el transceptor ($\pm 0,5$ dB)
oculta_* (5 columnas)	Oculto	Pérdida por reparaciones, hielo y conectores; figura de ruido; atenuación real
q, ber	Resultado físico	Q efectivo y BER calculados
cumple	Etiqueta	1 = cumple $BER \leq 10^{-11}$; 0 = no cumple

Cifras del dataset (calculadas sobre el CSV): 10 000 canales de 5,4 a 198,3 km; el 50,3 % (5028) van amplificados: 2698 con 1 vano y 2330 con 2; **no cumple el 20,4 %** (2039 canales). Por debajo de 40 km cumple el 99 %.

¿Por qué importa que haya un 20 % de «no cumple»? Si solo fallara el 1 %, un modelo que dijera siempre «cumple» acertaría el 99 % y no serviría para nada. Por eso no usamos la exactitud simple, sino métricas que miran cómo se detectan los que fallan (sección 9), y damos más peso a la clase minoritaria.

8. Los tres modelos de aprendizaje automático

Los tres reciben las variables observables de un canal y responden «cumple» o «no cumple». Aprenden de ejemplos: se les enseñan canales con la respuesta correcta y ajustan sus reglas internas.

- **Regresión logística** (modelo lineal, la referencia sencilla). Suma las variables multiplicadas por pesos y convierte el resultado en una probabilidad. Antes se estandarizan las variables (StandardScaler) para que todas pesen en la misma escala.

Como una balanza: cada variable pone un peso a favor o en contra, y según hacia dónde se incline se decide.

- **Random Forest** (ensamble de 300 árboles de decisión). Cada árbol hace preguntas del tipo «¿potencia < -27 dBm?» y aprende con una muestra distinta de datos; al final votan.

Como preguntar a 300 expertos que han visto casos distintos y quedarse con lo que diga la mayoría.

- **XGBoost** (gradient boosting, 300 árboles de profundidad 4). Construye los árboles uno detrás de otro; cada nuevo árbol se centra en corregir los errores de los anteriores.

Como un alumno que repasa solo los ejercicios que falló en el examen anterior.

Pesos de clase: como hay menos canales «no cumple», se les da más peso. En la logística y en Random Forest con `class_weight="balanced"`; en XGBoost con `scale_pos_weight = 79,6/20,4 \approx 3,9`.

Tres escenarios (según qué variables ve el modelo):

- **A — planificación:** solo el inventario (longitud, amplificado, vanos, antigüedad, reparaciones registradas, temperatura).
- **B — monitorización:** A + potencia recibida medida.
- **C — oráculo:** B + las 5 causas ocultas. Es irreal; sirve de techo para saber cuánto se pierde por no conocerlas.

9. Cómo se evaluaron: validación cruzada, métricas y McNemar

9.1 Validación cruzada estratificada 10 × 3

No se puede evaluar un modelo con los mismos datos con los que aprendió, porque sería como corregir un examen cuyas respuestas el alumno ya había visto. La validación cruzada divide los 10 000 canales en 10 partes («pliegues»): entrena con 9 y evalúa con la restante, 10 veces, rotando. «Estratificada» significa que cada parte mantiene el 20,4 % de «no cumple». Todo se repite 3 veces con mezclas distintas: 30 evaluaciones por modelo y escenario. La tabla da la **media ± desviación típica** de esas 30. Código: `RepeatedStratifiedKFold(n_splits=10, n_repeats=3, random_state=42)` y `cross_validate`.

9.2 Las métricas

Clase positiva = «no cumple» (lo que interesa detectar). Con VP = no cumple detectados, FN = no cumple que se escapan, FP = falsas alarmas y VN = cumple bien clasificados:

- **Sensibilidad** = $VP / (VP + FN)$: de los que fallan, qué fracción detecta el modelo.
- **Precisión** = $VP / (VP + FP)$: de las alarmas que da, qué fracción es real.
- **F1** = $2 \cdot \text{Precisión} \cdot \text{Sensibilidad} / (\text{Precisión} + \text{Sensibilidad})$: equilibrio entre las dos.
- **Exactitud equilibrada** = $(\text{Sensibilidad} + \text{Especificidad}) / 2$, con $\text{Especificidad} = VN / (VN + FP)$.
- **AUC** (área bajo la curva ROC): probabilidad de que el modelo dé más «riesgo» a un canal que falla que a uno que cumple, escogidos al azar. 0,5 = tirar una moneda; 1 = perfecto.

9.3 Prueba de McNemar

Compara dos modelos sobre **los mismos** canales de prueba: 30 % de los datos (3000 canales, 612 «no cumple»), separados con `train_test_split(..., test_size=0.3, stratify=y, random_state=42)`. Solo cuentan los casos en que uno acierta y el otro falla:

$$\chi^2 = (|n_{01} - n_{10}| - 1)^2 / (n_{01} + n_{10}), \text{ con 1 grado de libertad}$$

- Random Forest frente a logística (escenario B): $n_{01} = 44, n_{10} = 13 \rightarrow \chi^2 = 30^2/57 = 15,79 \rightarrow p = 7,1 \cdot 10^{-5}$.
- XGBoost frente a logística: $54 \text{ y } 23 \rightarrow \chi^2 = 30^2/77 = 11,69 \rightarrow p = 6,3 \cdot 10^{-4}$.

$p < 0,05$ indica que la diferencia no se debe al azar. Los números están en `resultados/mcnemar.txt` y la función es `mcnemar()` de `experimento.py`.

10. Cómo se hicieron la tabla, las figuras y el PDF de resumen

10.1 La tabla de resultados

experimento.py guarda las 9 filas (3 escenarios $\times$ 3 modelos) con pandas en dos formatos: resultados/tabla_resultados.csv (para Excel) y tabla_resultados.tex (código LaTeX listo para pegar en el artículo LNCS). La Tabla 7 reproduce esos resultados.

Tabla 7. Resultados de la validación cruzada (media $\pm$ desviación típica). Es la Tabla 1 del resumen y del artículo.

Escenario	Modelo	AUC	Exact. equilibrada	Sensibilidad	F1
A	Regresión logística	0,983 $\pm$ 0,003	0,929 $\pm$ 0,009	0,939 $\pm$ 0,017	0,832 $\pm$ 0,014
A	Random Forest	0,981 $\pm$ 0,003	0,921 $\pm$ 0,011	0,901 $\pm$ 0,023	0,847 $\pm$ 0,015
A	XGBoost	0,982 $\pm$ 0,003	0,925 $\pm$ 0,010	0,914 $\pm$ 0,019	0,845 $\pm$ 0,014
B	Regresión logística	0,998 $\pm$ 0,001	0,977 $\pm$ 0,004	0,987 $\pm$ 0,007	0,931 $\pm$ 0,009
B	Random Forest	0,998 $\pm$ 0,001	0,976 $\pm$ 0,007	0,974 $\pm$ 0,012	0,947 $\pm$ 0,012
B	XGBoost	0,998 $\pm$ 0,001	0,973 $\pm$ 0,008	0,964 $\pm$ 0,014	0,947 $\pm$ 0,012
C	Regresión logística	0,998 $\pm$ 0,001	0,980 $\pm$ 0,004	0,991 $\pm$ 0,006	0,940 $\pm$ 0,010
C	Random Forest	0,998 $\pm$ 0,001	0,978 $\pm$ 0,006	0,976 $\pm$ 0,011	0,951 $\pm$ 0,011
C	XGBoost	0,999 $\pm$ 0,001	0,978 $\pm$ 0,007	0,969 $\pm$ 0,012	0,958 $\pm$ 0,011

Cómo leerla: en B, los ensambles tienen mejor F1 (0,947 frente a 0,931), pero la logística detecta más canales que fallan (sensibilidad 0,987) a costa de más falsas alarmas. El AUC es prácticamente igual en todos. Por eso decimos que la hipótesis se cumple **solo en parte**.

10.2 Las tres figuras

Se dibujan con Matplotlib al final de experimento.py y se guardan en figuras/ en PNG (300 ppp) y en PDF (vectorial, para LaTeX). Los colores siguen una paleta comprobada para daltonismo. La Fig. 2 es el factor Q frente a la longitud.




Fig. 2. Factor Q de cada canal según su longitud (fig1_q_vs_longitud; es la Fig. 1 del resumen). Por claridad se dibujan 1500 puntos de cada clase, eje vertical logarítmico y línea discontinua en $Q = 6,71$.

La Fig. 3 muestra el F1 de la Tabla 7 como puntos con barras de error (media $\pm$ desviación típica), para comparar escenarios y modelos de un vistazo.




Fig. 3. F1 por escenario y modelo (fig2_f1_escenarios; es la Fig. 2 del resumen).

La Fig. 4 es la importancia por permutación: sobre el 30 % de prueba y con el Random Forest del escenario B, se desordena una columna cada vez y se mide cuánto baja el AUC (10 repeticiones). Si al desordenar una variable el modelo empeora mucho, esa variable es importante. Código: `permutation_importance(..., scoring="roc_auc", n_repeats=10)`.




Fig. 4. Importancia de las variables (fig3_importancia; es la Fig. 3 del resumen).

10.3 El cuaderno y el PDF de resumen

- `crear_cuaderno.py` genera `experimento.ipynb`: un cuaderno guiado que comprueba el caso del TFG, genera los datos, llama a `experimento.py` (`%run experimento.py`) y muestra la tabla y las figuras.
- `generar_resumen.py` lee el CSV y las figuras, escribe una página HTML y Chromium la convierte en `resumen-paso-3.pdf` (2 páginas). Cumple la regla de la profesora: cada tabla y figura se cita antes de aparecer.

11. Cómo repetirlo tú mismo en tu ordenador

1. Instala **Python 3.11** (python.org) y, en VS Code, las extensiones **Python** y **Jupyter** de Microsoft.
2. Abre una terminal en VS Code (menú *Terminal* → *New Terminal*) e instala las librerías:

```
py -m pip install -r requirements.txt
```

3. Abre la carpeta `paso-3-experimento` en VS Code y el archivo `experimento.ipynb`.

4. Arriba a la derecha, *Select Kernel* → Python 3.11. Luego **Run All**. Tarda unos 2-3 minutos.
5. Se regeneran datos/, resultados/ y figuras/. Sin cuaderno, en la terminal:

```
python experimento.py
```

¿Saldrán exactamente los mismos números? Los datos (`dataset.csv`), sí: dependen solo de la semilla. Las métricas pueden variar en la tercera cifra decimal si tu versión de scikit-learn o XGBoost es distinta de la de la Tabla 2. No cambia ninguna conclusión.

12. Preguntas que puede hacerte la profesora (con respuesta)

¿Por qué datos sintéticos? No existen datos públicos de calidad de canales de redes ferroviarias envejecidas. Rottondi et al. (2018) y Aladin et al. (2020) también entrenan con datos sintéticos de modelos físicos. Es un primer paso; la validación con datos reales queda como trabajo futuro (por ejemplo, el conjunto de datos de Microsoft que usan Allogba y Di Cicco).

¿De dónde salen las fórmulas? Son las estándar de un enlace óptico IM/DD: balance de potencia, Q térmico, OSNR con la regla de 58 dB, Q con ruido señal-ASE, penalización por dispersión y $BER = \frac{1}{2} \cdot \text{erfc}(Q/\sqrt{2})$. Los parámetros del TFG están en la Tabla 3; el resto son valores típicos o supuestos que se declaran.

¿Qué es la «circularidad»? La etiqueta sale del mismo modelo físico que genera las variables, así que la tarea es más fácil que con datos reales ($AUC \geq 0,98$). Por eso ocultamos las causas físicas a los modelos, y lo declaramos como la limitación principal.

¿Por qué la logística tiene el mismo AUC que los ensambles? Porque la relación entre potencia medida y calidad es casi monótona (a menos potencia, peor Q), algo que un modelo lineal capta bien. Los ensambles ganan en F1 porque colocan mejor el punto de corte, no porque ordenen mejor los canales.

¿Por qué 10 pliegues × 3 repeticiones? Diez pliegues es el estándar; repetir tres veces da 30 medidas y una desviación típica fiable.

¿Por qué semilla 42? El valor da igual; lo importante es fijarlo para que el experimento sea reproducible.

¿Por qué la hipótesis «se cumple solo en parte»? McNemar muestra que Random Forest acierta significativamente más ($p = 7 \cdot 10^{-5}$), pero el AUC es igual y la logística detecta más fallos. Un resultado matizado también es válido: el artículo de Espejo et al. que usa la profesora de ejemplo publica una hipótesis que no se cumple.

¿Usaste inteligencia artificial? Respuesta honesta: sí, un asistente (Claude) programó el simulador y el experimento a partir de tu TFG, y tú dirigiste las decisiones y revisaste los resultados. Conviene decirlo si te lo preguntan, y comprobar si la asignatura pide declararlo en el artículo (muchas revistas lo exigen ya en un apartado de agradecimientos o de métodos). Lo que te protege es poder explicar cada paso, y para eso es esta guía.

13. Trazabilidad: de dónde sale cada dato

La Tabla 8 relaciona cada cifra que aparece en el resumen del Paso 3 con el archivo o el cálculo del que sale.

Tabla 8. Origen de cada dato del resumen del Paso 3.

Dato	Dónde se calcula	Dónde queda guardado
10 000 canales, 5-198 km	<code>simulador.generar(n=10000, semilla=42)</code>	<code>datos/dataset.csv</code>
$\alpha = 0,22$ dB/km; sensibilidad -25 dBm; estaciones	Constantes de <code>simulador.py</code>	TFG (Tabla 3)
$Q = 6,71 \Rightarrow \text{BER} = 10^{-11}$	<code>ber_desde_q()</code>	<code>Q_UMBRAL</code> en <code>simulador.py</code>
No cumple el 20,4 %	<code>1 - df.cumple.mean()</code>	Salida de <code>experimento.py</code> y del cuaderno
Cumple el 99 % por debajo de 40 km; fallos entre 40 y 110 km	Recuento por tramos de longitud sobre el CSV	Cálculo de comprobación (<code>pandas crosstab</code>)
AUC, exactitud equilibrada, sensibilidad, F1	<code>cross_validate</code> con CV 10×3	<code>resultados/tabla_resultados.csv</code> y <code>.tex</code>
McNemar 44/13 y 54/23, p	<code>mcnemar()</code> sobre el 30 % de prueba	<code>resultados/mcnemar.txt</code>
AUC de 0,98 (A) a 0,998 (B)	Columna AUC de la tabla	<code>tabla_resultados.csv</code>
Potencia recibida = variable decisiva	<code>permutation_importance</code>	<code>figuras/fig3_importancia.*</code>
$Q \approx 10,5$ en 108,9 km	Celda 1 del cuaderno (<code>q_ase</code>)	<code>experimento.ipynb</code>

Resumen en tres frases para la profesora. (1) A partir del diseño de mi TFG construí un modelo físico estándar de enlace óptico y generé 10 000 canales con degradaciones realistas. (2) Comparé una regresión logística con Random Forest y XGBoost usando solo variables que el operador puede medir, con validación cruzada estratificada 10×3 y la prueba de McNemar. (3) Los ensambles aciertan significativamente más en F1, pero el AUC es igual y la potencia recibida medida es lo que más aporta; la limitación principal es que los datos son sintéticos.