

Estimación de la calidad de transmisión mediante aprendizaje automático en la red DWDM ferroviaria Moscú-Kazánskaya – Riazán

Angel Luis Acosta González

Título provisional · 28 de septiembre de 2026

1. PLANTEAMIENTO DEL PROBLEMA

En mi trabajo de fin de grado (ingeniería ferroviaria, RUT MIIT, 2026) diseñé la red primaria de comunicaciones del tramo Moscú-Kazánskaya – Riazán-1 (198,3 km): un anillo DWDM entre Moscú-Kazánskaya, Voskresensk y Riazán-1, más una cadena de acceso de 22 estaciones, con canales de 10 Gbit/s sobre fibra G.652 ($\alpha = 0,22$ dB/km). La calidad de transmisión (QoT) se verificó con un modelo analítico aplicado solo al tramo más desfavorable (Voskresensk – Riazán-1, 108,9 km). El resultado fue $Q = 7,37$ y $BER = 8,9 \cdot 10^{-14}$, frente a un umbral normativo de 10^{-11} ($Q = 6,71$).

Ese enfoque es **estático y conservador**: se calcula una sola vez, para un caso extremo y con márgenes fijos. No tiene en cuenta la degradación durante la explotación: envejecimiento de la fibra y de los amplificadores EDFA, empalmes por reparaciones o variaciones de temperatura. Tampoco recoge el hielo y las inundaciones, que el propio proyecto identifica como riesgos del trazado, ni la reconfiguración de canales en los OADM. Recalculer a mano cada canal óptico (*lightpath*) en cada situación es costoso, y los márgenes fijos tienden a sobredimensionar la red.

2. PREGUNTA INICIAL DE INVESTIGACIÓN

¿Puede un modelo de aprendizaje automático, entrenado con parámetros de enlace a los que accede el operador, estimar el factor Q y la BER de todos los canales de la red ferroviaria con una precisión comparable al modelo analítico, en mucho menos tiempo y también en condiciones degradadas?

3. NOVEDAD E INTERÉS

- **Vacío:** la estimación de QoT con aprendizaje automático está consolidada en redes troncales de larga distancia [1–3]. Su aplicación a **redes de comunicaciones ferroviarias** parece mucho menos tratada, lo que se confirmará en la revisión bibliográfica del Paso 2. Estas redes son regionales, con muchas estaciones de acceso, expuestas a condiciones ambientales severas y, en este caso, limitadas a equipos de fabricación nacional.
- **Interés:** se sustituye un cálculo puntual por un sistema inteligente que evalúa la red de forma continua. Es un paso hacia la gestión autónoma de redes y el mantenimiento predictivo de una infraestructura crítica para la seguridad ferroviaria.

4. OBJETIVOS

General: desarrollar y evaluar un estimador de QoT basado en aprendizaje automático para la red DWDM del tramo Moscú-Kazánskaya – Riazán.

1. Generar un conjunto de datos de canales ópticos a partir del modelo analítico del proyecto de grado. Se variarán la longitud, los empalmes, la potencia, la ganancia EDFA, el envejecimiento y la temperatura.
2. Entrenar y comparar varios modelos: una regresión lineal como referencia, *Random Forest*, XGBoost y un perceptrón multicapa.
3. Evaluar el error de estimación del factor Q (MAE, RMSE), el acierto al clasificar el umbral $BER \leq 10^{-11}$ y el tiempo de cálculo frente al método analítico.
4. Cuantificar el margen de diseño que podría reducirse sin incumplir el umbral de BER.

5. HIPÓTESIS PROVISIONAL

H₁: un modelo de ensemble de árboles (*Random Forest* o XGBoost) estimará el factor Q de los canales de la red con un error absoluto medio inferior a 0,3. Además, clasificará correctamente el cumplimiento de $BER \leq 10^{-11}$ en al menos el 95 % de los casos, con un tiempo de inferencia al menos un orden de magnitud menor que el cálculo analítico.

H₀: los modelos de aprendizaje automático no mejoran de forma significativa a la regresión lineal de referencia.

Limitación prevista: el conjunto de datos será sintético, generado con el modelo físico del proyecto, y no con mediciones reales del operador. La validez externa deberá contrastarse con conjuntos de datos públicos de QoT.

[1] Pointurier, Y. (2021). Machine learning techniques for quality of transmission estimation in optical networks. *Journal of Optical Communications and Networking*, 13(4), B60. <https://doi.org/10.1364/JOCN.417434>

[2] Mata, J., de Miguel, I., Durán Barroso, R. J., et al. (2018). Supervised machine learning techniques for quality of transmission assessment in optical networks. *ICTON 2018*, 1–4. IEEE. <https://doi.org/10.1109/ICTON.2018.8473819>

[3] Kozdrowski, S., Cichosz, P., Paziewski, P., & Sujecki, S. (2020). Machine learning algorithms for prediction of the quality of transmission in optical networks. *Entropy*, 23(1), 7. <https://doi.org/10.3390/e23010007>