

Paso 3 — Diseño experimental y resultados

Angel Luis Acosta González · Máster Universitario en Sistemas Inteligentes (USAL) · Metodología de la Investigación
Estimación de la calidad de transmisión (QoT) con aprendizaje automático en la red DWDM ferroviaria Moscú-
Kazánskaya – Riazán

Hipótesis. Un modelo de ensamble (Random Forest, XGBoost) entrenado con parámetros que el operador puede medir predice si un canal cumple $BER \leq 10^{-11}$ con mayor acierto que un modelo lineal sencillo (regresión logística).

1. Diseño experimental

- **Datos:** 10 000 canales ópticos sintéticos (10 Gbit/s NRZ, detección directa) entre pares de estaciones reales de la línea (5–198 km), generados con un modelo físico: balance de potencia, ruido térmico, ruido ASE de los EDFA y dispersión cromática. Parámetros de partida del TFG ($\alpha = 0,22$ dB/km, sensibilidad -25 dBm).
- **Degradación:** 0–25 años de servicio, envejecimiento de fibra, láser y EDFA, reparaciones (solo el 60 % registradas), hielo y conectores sucios. **Etiqueta:** $Q \geq 6,71 \Leftrightarrow BER \leq 10^{-11}$; no cumple el 20,4 %.
- **Escenarios:** A = planificación (solo inventario); B = A + potencia recibida medida ($\pm 0,5$ dB); C = oráculo con las causas ocultas (solo referencia).
- **Modelos:** regresión logística, Random Forest (300 árboles) y XGBoost (300 árboles), con pesos de clase.
- **Validación:** validación cruzada estratificada 10 pliegues $\times$ 3 repeticiones; prueba de McNemar sobre un 30 % de prueba. Clase positiva = «no cumple». Semilla fija (42): resultados reproducibles.

2. Resultados

Tabla 1. Validación cruzada (media $\pm$ desviación típica). Clase positiva: canal que no cumple $BER \leq 10^{-11}$.

Escenario	Modelo	AUC	Exactitud equilibrada	Sensibilidad	F1
A: planificación	Regresión logística	0,983 $\pm$ 0,003	0,929 $\pm$ 0,009	0,939 $\pm$ 0,017	0,832 $\pm$ 0,014
A: planificación	Random Forest	0,981 $\pm$ 0,003	0,921 $\pm$ 0,011	0,901 $\pm$ 0,023	0,847 $\pm$ 0,015
A: planificación	XGBoost	0,982 $\pm$ 0,003	0,925 $\pm$ 0,010	0,914 $\pm$ 0,019	0,845 $\pm$ 0,014
B: monitorización	Regresión logística	0,998 $\pm$ 0,001	0,977 $\pm$ 0,004	0,987 $\pm$ 0,007	0,931 $\pm$ 0,009
B: monitorización	Random Forest	0,998 $\pm$ 0,001	0,976 $\pm$ 0,007	0,974 $\pm$ 0,012	0,947 $\pm$ 0,012
B: monitorización	XGBoost	0,998 $\pm$ 0,001	0,973 $\pm$ 0,008	0,964 $\pm$ 0,014	0,947 $\pm$ 0,012
C: oráculo	Regresión logística	0,998 $\pm$ 0,001	0,980 $\pm$ 0,004	0,991 $\pm$ 0,006	0,940 $\pm$ 0,010
C: oráculo	Random Forest	0,998 $\pm$ 0,001	0,978 $\pm$ 0,006	0,976 $\pm$ 0,011	0,951 $\pm$ 0,011
C: oráculo	XGBoost	0,999 $\pm$ 0,001	0,978 $\pm$ 0,007	0,969 $\pm$ 0,012	0,958 $\pm$ 0,011

McNemar (escenario B): Random Forest acierta 44 casos que la logística falla, frente a 13 al revés ($p = 7 \cdot 10^{-5}$); XGBoost, 54 frente a 23 ($p = 6 \cdot 10^{-4}$).




Fig. 1. Factor Q de cada canal según su longitud; la línea discontinua es el umbral $BER = 10^{-11}$.




Fig. 2. F1 de la clase «no cumple» por escenario y modelo (media $\pm$ desviación típica).




Fig. 3. Importancia de las variables por permutación (Random Forest, escenario B).

3. Interpretación

- **La hipótesis se cumple solo en parte:** los ensambles tienen mejor F1 y la diferencia es significativa (McNemar), pero el AUC es igual en los tres modelos y la logística detecta más canales que fallan, a costa de más falsas alarmas.
- **La potencia recibida medida es la variable decisiva** (Fig. 3): el AUC sube de 0,98 (A) a 0,998 (B). Monitorizar el receptor aporta más que cambiar de modelo.
- **Limitación:** los datos son sintéticos y la etiqueta sale de un modelo físico determinista, por eso la tarea resulta fácil ($AUC \geq 0,98$). Habrá que contrastarlo con datos medidos reales.

Código, datos y figuras en alta resolución (PNG y PDF): archivo .zip adjunto (*experimento.ipynb*, *simulador.py*, *experimento.py*, *datos/dataset.csv*).