

Paso 3 — Diseño experimental y resultados

Angel Luis Acosta González · Máster Universitario en Sistemas Inteligentes (USAL) · Metodología de la Investigación
Estimación de la calidad de transmisión (QoT) con aprendizaje automático en la red DWDM ferroviaria
Moscú-Kazánskaya – Riazán

Hipótesis (ficha de planteamiento revisada). Si se entrena un modelo de ensamble (Random Forest, XGBoost) con parámetros observables de los enlaces, será posible predecir si un canal cumple el umbral $BER \leq 10^{-11}$ con mayor acierto que un modelo lineal sencillo (regresión logística).

Alcance. Este paso cubre los objetivos 1 (conjunto de datos con un modelo físico y degradación), 2 (comparar modelos con una referencia sencilla) y, en parte, el 3 (evaluar en canales no vistos en el entrenamiento, con validación cruzada; la evaluación en trayectos y condiciones no vistos se completa en el artículo). El objetivo 4 (cuantificar el margen de diseño que podría ahorrarse sin incumplir el umbral) queda fuera del alcance de este estudio y se plantea como trabajo futuro.

1. Diseño experimental

- **Datos:** 10 000 canales ópticos sintéticos (10 Gbit/s NRZ, detección directa) entre pares de estaciones reales de la línea (5–198 km), generados con un modelo físico: balance de potencia, ruido térmico, ruido ASE de los EDFA y dispersión cromática. Parámetros de partida del TFG ($\alpha = 0,22$ dB/km, sensibilidad -25 dBm).
- **Degradación:** 0–25 años de servicio, envejecimiento de fibra, láser y EDFA, reparaciones (solo el 60 % registradas), hielo y conectores sucios. **Etiqueta:** $Q \geq 6,71 \Leftrightarrow BER \leq 10^{-11}$; no cumple el 20,4 %.
- **Escenarios (variables de entrada):** A = planificación (longitud, amplificado, n.º de vanos, antigüedad, reparaciones registradas, temperatura); B = A + potencia recibida medida ($\pm 0,5$ dB); C = B + causas ocultas (pérdidas por reparaciones, hielo y conectores, figura de ruido del EDFA, atenuación real), solo como referencia.
- **Modelos:** regresión logística, Random Forest (300 árboles) y XGBoost (300 árboles, profundidad 4), con pesos de clase e hiperparámetros fijados a priori, sin ajuste; umbral de decisión 0,5.
- **Validación:** validación cruzada estratificada 10 pliegues $\times$ 3 repeticiones; prueba de McNemar sobre un 30 % de prueba. Clase positiva = «no cumple». Semilla fija (42): resultados reproducibles.

2. Resultados

En la Tabla 1 se recogen las métricas de validación cruzada de los tres modelos en los tres escenarios: AUC, exactitud equilibrada, sensibilidad y F1 de la clase «no cumple».

Tabla 1. Validación cruzada (media $\pm$ desviación típica). Clase positiva: canal que no cumple $BER \leq 10^{-11}$.

Escenario	Modelo	AUC	Exactitud equilibrada	Sensibilidad	F1
A: planificación	Regresión logística	0,983 $\pm$ 0,003	0,929 $\pm$ 0,009	0,939 $\pm$ 0,017	0,832 $\pm$ 0,014
A: planificación	Random Forest	0,981 $\pm$ 0,003	0,921 $\pm$ 0,011	0,901 $\pm$ 0,023	0,847 $\pm$ 0,015
A: planificación	XGBoost	0,982 $\pm$ 0,003	0,925 $\pm$ 0,010	0,914 $\pm$ 0,019	0,845 $\pm$ 0,014
B: monitorización	Regresión logística	0,998 $\pm$ 0,001	0,977 $\pm$ 0,004	0,987 $\pm$ 0,007	0,931 $\pm$ 0,009
B: monitorización	Random Forest	0,998 $\pm$ 0,001	0,976 $\pm$ 0,007	0,974 $\pm$ 0,012	0,947 $\pm$ 0,012
B: monitorización	XGBoost	0,998 $\pm$ 0,001	0,973 $\pm$ 0,008	0,964 $\pm$ 0,014	0,947 $\pm$ 0,012
C: oráculo	Regresión logística	0,998 $\pm$ 0,001	0,980 $\pm$ 0,004	0,991 $\pm$ 0,006	0,940 $\pm$ 0,010
C: oráculo	Random Forest	0,998 $\pm$ 0,001	0,978 $\pm$ 0,006	0,976 $\pm$ 0,011	0,951 $\pm$ 0,011
C: oráculo	XGBoost	0,999 $\pm$ 0,001	0,978 $\pm$ 0,007	0,969 $\pm$ 0,012	0,958 $\pm$ 0,011

McNemar (escenario B): Random Forest acierta 44 casos que la logística falla, frente a 13 al revés ($p = 7 \cdot 10^{-5}$); XGBoost, 54 frente a 23 ($p = 6 \cdot 10^{-4}$).

La Fig. 1 representa el factor Q de cada canal frente a su longitud: los canales que no cumplen quedan por debajo del umbral y se concentran entre 40 y 110 km; por debajo de 40 km cumple el 99 %.




Fig. 1. Factor Q de cada canal según su longitud (muestra aleatoria de 1500 canales por clase); la línea discontinua es el umbral $BER = 10^{-11}$.

En la Fig. 2 se compara el F1 de los tres modelos en cada escenario: la mayor mejora se debe a pasar del escenario A al B, no al cambio de modelo.




Fig. 2. F1 de la clase «no cumple» por escenario y modelo (media $\pm$ desviación típica).

La Fig. 3 muestra cuánto empeora el AUC del Random Forest al permutar aleatoriamente cada variable: la potencia recibida medida es, con diferencia, la más importante.




Fig. 3. Importancia de las variables por permutación (Random Forest, escenario B). Barras de error: desviación típica en 10 permutaciones.

3. Interpretación

- **La hipótesis se cumple solo en parte:** los ensambles obtienen mayor F1 y mayor exactitud global, con diferencia significativa (McNemar, $p < 0,001$, también tras la corrección de Bonferroni para dos comparaciones). Sin embargo, el AUC y la exactitud equilibrada son prácticamente iguales en los tres modelos. En el conjunto de prueba (escenario B), Random Forest deja sin detectar 12 canales que no cumplen, frente a 2 de la logística, a cambio de 41 falsas alarmas menos (49 frente a 90). La ventaja del ensamble depende, por tanto, del umbral de decisión y del coste que el operador asigne a cada error.
- **La potencia recibida medida es la variable decisiva** (Fig. 3): el AUC sube de 0,98 (A) a 0,998 (B). Monitorizar el receptor aporta más que cambiar de modelo.
- **Limitación:** los datos son sintéticos y la etiqueta sale de un modelo físico determinista, por eso la tarea resulta fácil ($AUC \geq 0,98$). Además, los 10 000 canales proceden de 208 pares de estaciones, por lo que no se evalúa la generalización a trayectos no vistos (validación agrupada por trayecto como trabajo futuro). Queda pendiente su contraste con datos medidos reales.

Código, datos y figuras en alta resolución (PNG y PDF): archivo .zip adjunto (*experimento.ipynb*, *simulador.py*, *experimento.py*, *datos/dataset.csv*).