

Paso 3 — Diseño experimental y resultados

Angel Luis Acosta González · Máster Universitario en Sistemas Inteligentes (USAL) · Metodología de la Investigación
Estimación de la calidad de transmisión (QoT) con aprendizaje automático en la red DWDM ferroviaria
Moscú-Kazánskaya – Riazán

Hipótesis. Si se entrena un modelo de ensamble (Random Forest, XGBoost) con parámetros observables de los enlaces, será posible predecir si un canal cumple el umbral $BER \leq 10^{-11}$ con mayor acierto que un modelo lineal sencillo (regresión logística).

Alcance. Este paso cubre los objetivos 1 (conjunto de datos con un modelo físico y degradación), 2 (comparar modelos con una referencia sencilla) y, en parte, el 3 (evaluar en canales no vistos en el entrenamiento, con validación cruzada; la evaluación en trayectos y condiciones no vistos se completa en el artículo). El objetivo 4 (cuantificar el margen de diseño que podría ahorrarse sin incumplir el umbral) queda fuera del alcance de este estudio y se plantea como trabajo futuro.

1. Diseño experimental

- **Datos:** 10 000 canales ópticos sintéticos (10 Gbit/s NRZ, detección directa) entre pares de estaciones reales de la línea (5–198 km), generados con un modelo físico: balance de potencia, ruido térmico, ruido ASE de los EDFA y dispersión cromática. Parámetros de partida del TFG ($\alpha = 0,22$ dB/km, sensibilidad -25 dBm).
- **Degradación:** 0–25 años de servicio, envejecimiento de fibra, láser y EDFA, reparaciones (solo el 60 % registradas), hielo y conectores sucios. **Etiqueta:** $Q \geq 6,71 \Leftrightarrow BER \leq 10^{-11}$; no cumple el 20,4 %.
- **Escenarios (variables de entrada):** A = planificación (longitud, amplificado, n.º de vanos, antigüedad, reparaciones registradas, temperatura); B = A + potencia recibida medida (error gaussiano $\sigma = 0,5$ dB); C = B + causas ocultas (pérdidas por reparaciones, hielo y conectores, figura de ruido del EDFA, atenuación real), solo como referencia.
- **Modelos:** regresión logística, Random Forest (300 árboles) y XGBoost (300 árboles, profundidad 4), con pesos de clase e hiperparámetros fijados a priori, sin ajuste; umbral de decisión 0,5.
- **Validación:** validación cruzada estratificada 10 pliegues $\times$ 3 repeticiones; prueba de McNemar sobre un 30 % de prueba. Clase positiva = «no cumple». Semilla fija (42): resultados reproducibles.

2. Resultados

En la Tabla 1 se recogen las métricas de validación cruzada de los tres modelos en los tres escenarios: AUC, exactitud equilibrada, sensibilidad y F1 de la clase «no cumple».

Tabla 1. Validación cruzada (media $\pm$ desviación típica). Clase positiva: canal que no cumple $BER \leq 10^{-11}$.

Escenario	Modelo	AUC	Exactitud equilibrada	Sensibilidad	F1
A: planificación	Regresión logística	0,983 $\pm$ 0,003	0,929 $\pm$ 0,009	0,939 $\pm$ 0,017	0,832 $\pm$ 0,014
A: planificación	Random Forest	0,981 $\pm$ 0,003	0,921 $\pm$ 0,011	0,901 $\pm$ 0,023	0,847 $\pm$ 0,015
A: planificación	XGBoost	0,982 $\pm$ 0,003	0,925 $\pm$ 0,010	0,914 $\pm$ 0,019	0,845 $\pm$ 0,014
B: monitorización	Regresión logística	0,998 $\pm$ 0,001	0,977 $\pm$ 0,004	0,987 $\pm$ 0,007	0,931 $\pm$ 0,009
B: monitorización	Random Forest	0,998 $\pm$ 0,001	0,976 $\pm$ 0,007	0,974 $\pm$ 0,012	0,947 $\pm$ 0,012
B: monitorización	XGBoost	0,998 $\pm$ 0,001	0,973 $\pm$ 0,008	0,964 $\pm$ 0,014	0,947 $\pm$ 0,012
C: oráculo	Regresión logística	0,998 $\pm$ 0,001	0,980 $\pm$ 0,004	0,991 $\pm$ 0,006	0,940 $\pm$ 0,010
C: oráculo	Random Forest	0,998 $\pm$ 0,001	0,978 $\pm$ 0,006	0,976 $\pm$ 0,011	0,951 $\pm$ 0,011
C: oráculo	XGBoost	0,999 $\pm$ 0,001	0,978 $\pm$ 0,007	0,969 $\pm$ 0,012	0,958 $\pm$ 0,011

McNemar (escenario B): Random Forest acierta 44 casos que la logística falla, frente a 13 al revés ($p = 7 \cdot 10^{-5}$); XGBoost, 54 frente a 23 ($p = 6 \cdot 10^{-4}$).

La Fig. 1 representa el factor Q de cada canal frente a su longitud: los canales que no cumplen quedan por debajo del umbral y se concentran entre 40 y 110 km; por debajo de 40 km cumple el 99 %.




Fig. 1. Factor Q de cada canal según su longitud (muestra aleatoria de 1500 canales por clase); la línea discontinua es el umbral $BER = 10^{-11}$.

En la Fig. 2 se compara el F1 de los tres modelos en cada escenario: la mayor mejora se debe a pasar del escenario A al B, no al cambio de modelo.




Fig. 2. F1 de la clase «no cumple» por escenario y modelo (media $\pm$ desviación típica).

La Fig. 3 muestra cuánto empeora el AUC del Random Forest al permutar aleatoriamente cada variable: la potencia recibida medida es, con diferencia, la más importante.




Fig. 3. Importancia de las variables por permutación (Random Forest, escenario B). Barras de error: desviación típica en 10 permutaciones.

3. Interpretación

- **La hipótesis se cumple solo en parte:** los ensambles obtienen mayor F1 y mayor exactitud global, con diferencia significativa (McNemar, $p < 0,001$; $p \leq 0,0013$ tras la corrección de Bonferroni para dos comparaciones). Sin embargo, el AUC y la exactitud equilibrada son prácticamente iguales en los tres modelos. En el conjunto de prueba (escenario B), Random Forest deja sin detectar 12 canales que no cumplen, frente a 2 de la logística, a cambio de 41 falsas alarmas menos (49 frente a 90). La ventaja del ensamble depende, por tanto, del umbral de decisión y del coste que el operador asigne a cada error.
- **La potencia recibida medida es la variable decisiva** (Fig. 3): el AUC sube de 0,98 (A) a 0,998 (B). Monitorizar el receptor aporta más que cambiar de modelo.
- **Limitación:** los datos son sintéticos y la etiqueta sale de un modelo físico determinista, por eso la tarea resulta fácil ($AUC \geq 0,98$). Además, los 10 000 canales proceden de 208 pares de estaciones, por lo que la validación cruzada no evalúa la generalización a trayectos no vistos; esa validación agrupada por trayecto se presenta en el artículo. Queda pendiente su contraste con datos medidos reales.

Código, datos y figuras en alta resolución (PNG y PDF): archivo .zip adjunto (*experimento.ipynb*, *simulador.py*, *experimento.py*, *datos/dataset.csv*).