Genotipado con microarrays

Máster en Sistemas Inteligentes

Luis Quintales
Departamento de Informática

VNiVERSiDAD
D SALAMANCA

Índice

OMIM

YEARS 50 OMIM
Human Genetics Knowledge for the World

OMIM®

Online Mendelian Inheritance in Man®

An Online Catalog of Human Genes and Genetic Disorders

Updated March 9, 2021

Search OMIM for clinical features, phenotypes, genes, and more...

Advanced Search : OMIM, Clinical Synopses, Gene Map

Need help? : Example Searches, OMIM Search Help, OMIM Video Tutorials

Mirror site : https://mirror.omim.org

OMIM is supported by a grant from NHGRI, licensing fees, and generous contributions from people like you.

OMIM Entry Statistics

Number of Entries in OMIM (Updated March 9th, 2021) :

MIM Number Prefix	Autosomal	X Linked	Y Linked	Mitochondrial	Totals
Gene description *	15,597	747	51	37	16,432
Gene and phenotype, combined +	28	0	0	0	28
Phenotype description, molecular basis known #	5,626	355	5	34	6,020
Phenotype description or locus, molecular basis unknown %	1,412	112	4	0	1,528
Other, mainly phenotypes with suspected mendelian basis	1,657	102	3	0	1,762
Totals	24,320	1,316	63	71	25,770

Herencia autosómica dominante

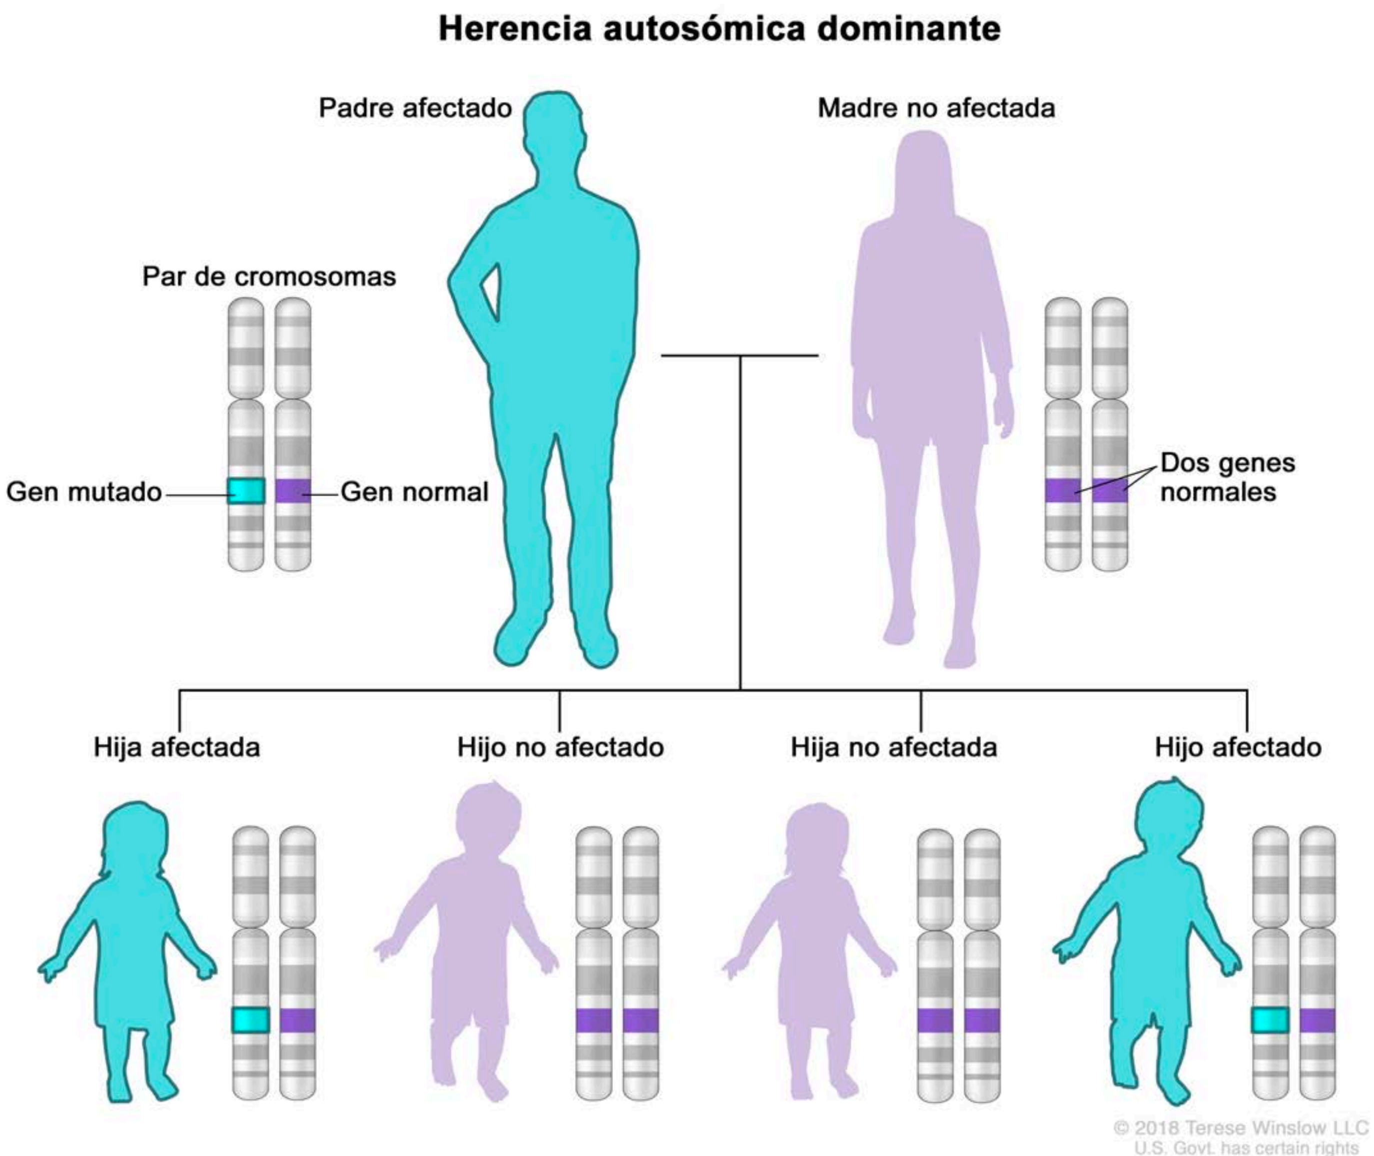

Herencia autosómica dominante

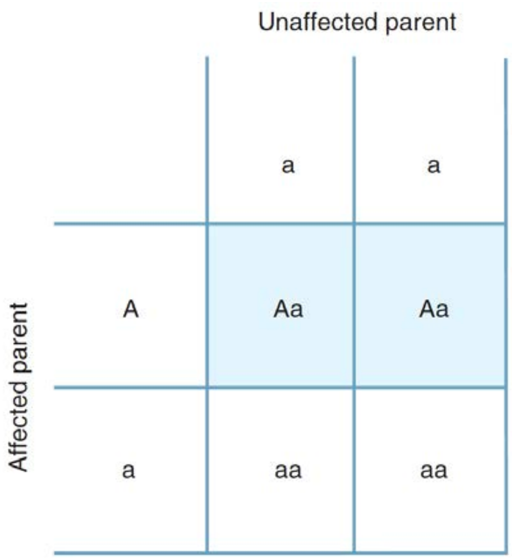

Cuadro de Punnet

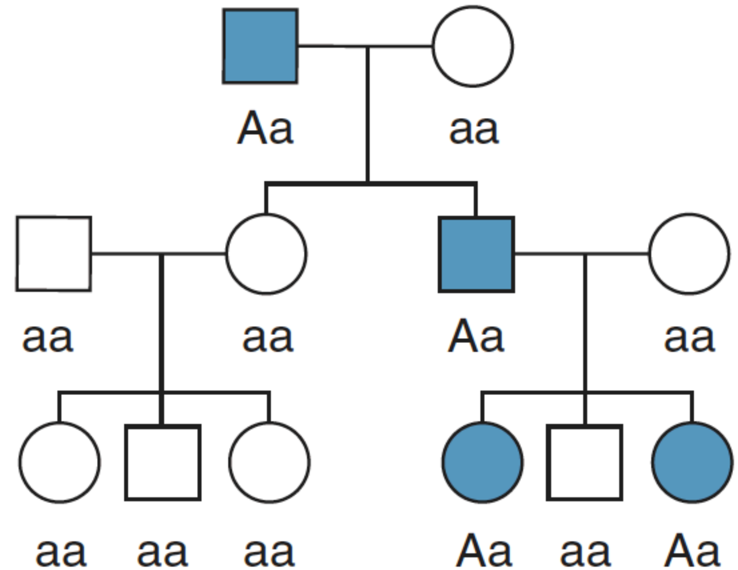

Ejemplo de genealogía

Herencia autosómica recesiva

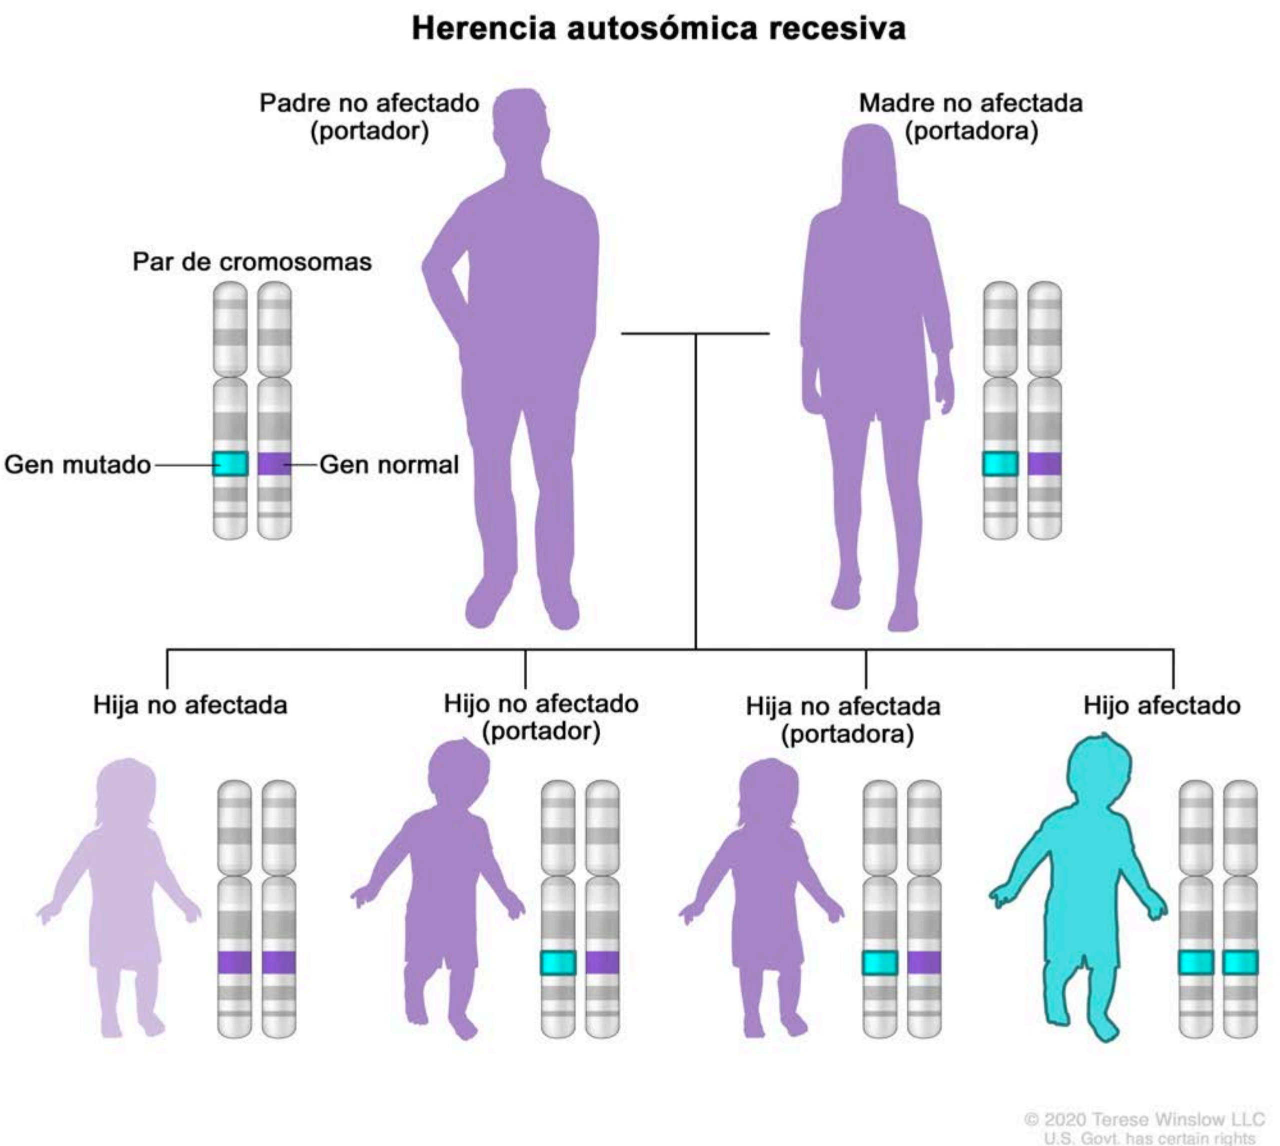

Herencia autosómica recesiva

Carrier parent

Carrier parent	A	a
A	AA	Aa
a	Aa	aa

Cuadro de Punnet

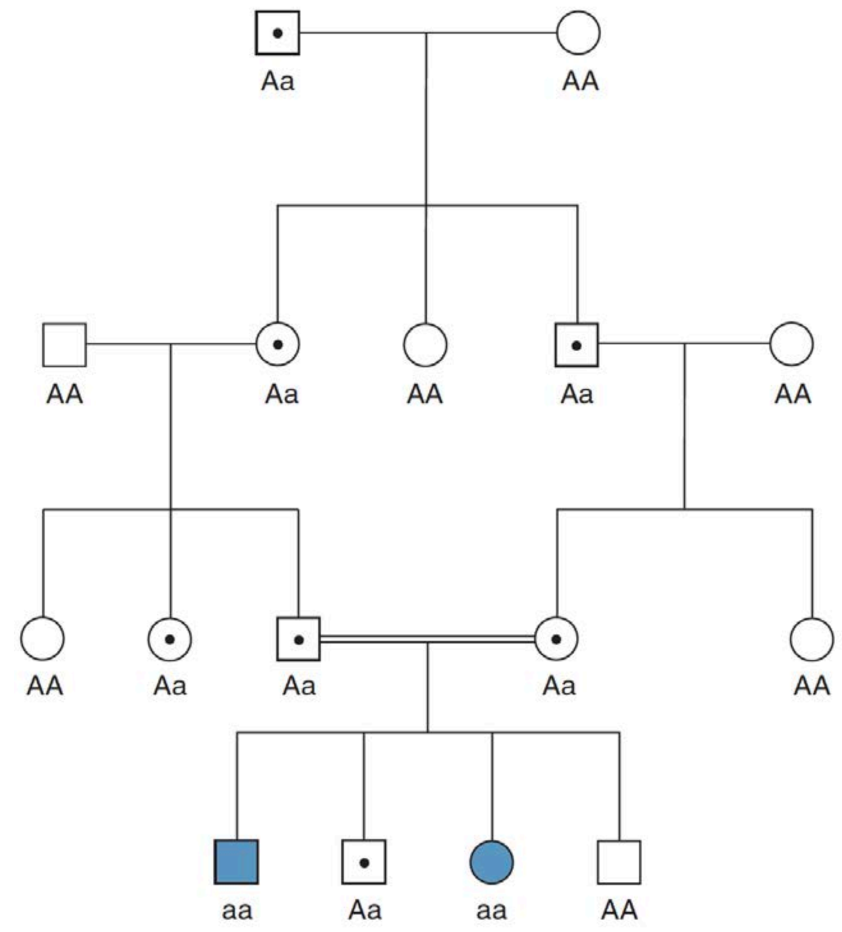

Ejemplo de genealogía

Herencia dominante ligada al cromosoma X

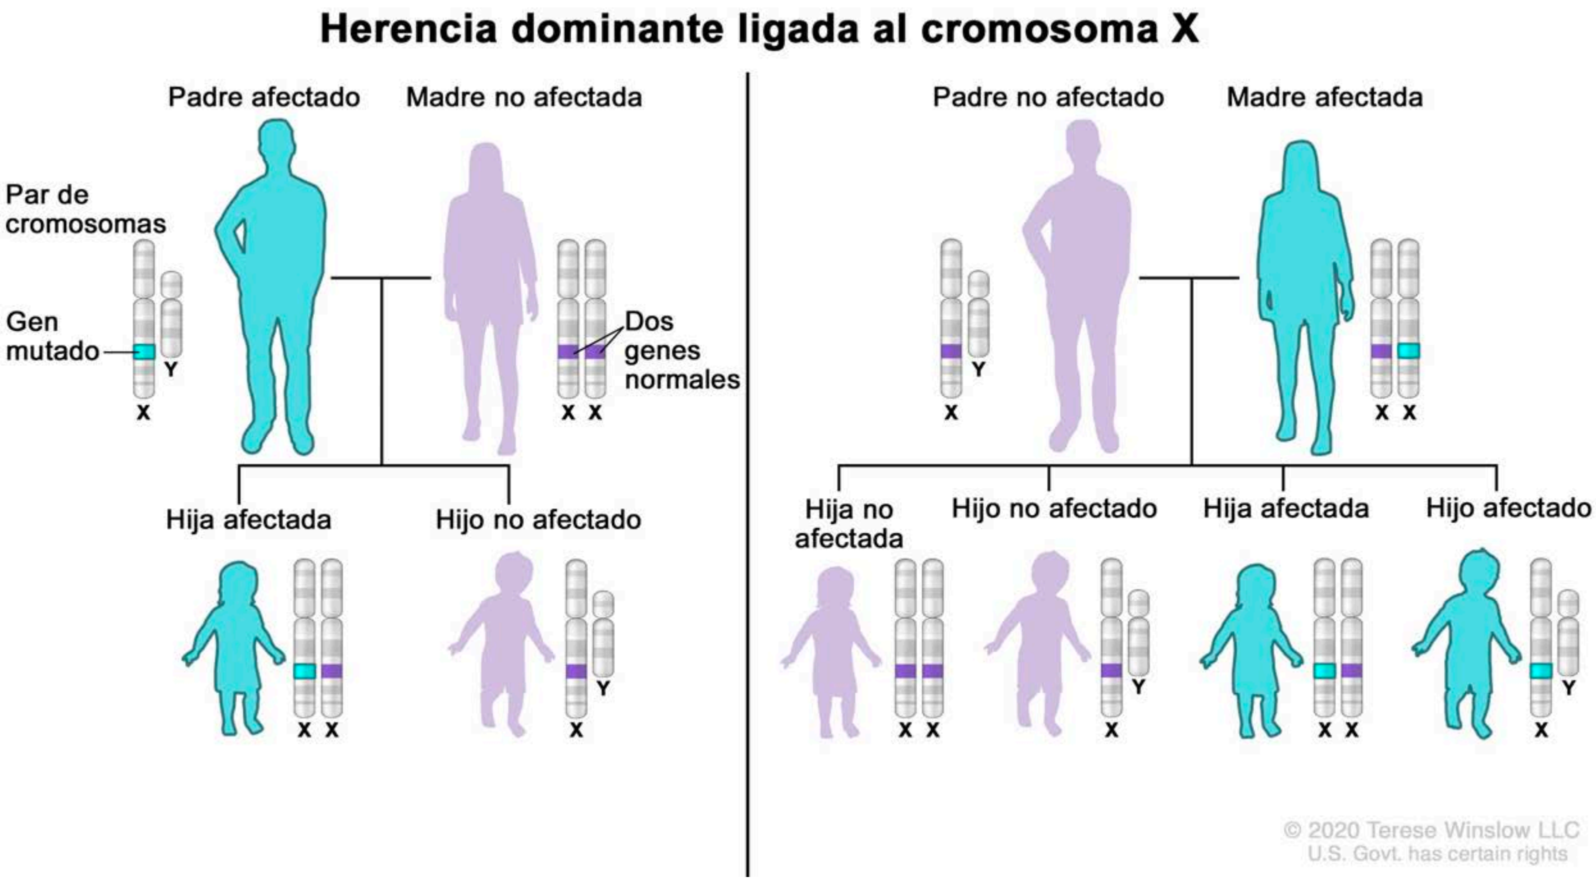

Herencia recesiva ligada al cromosoma X

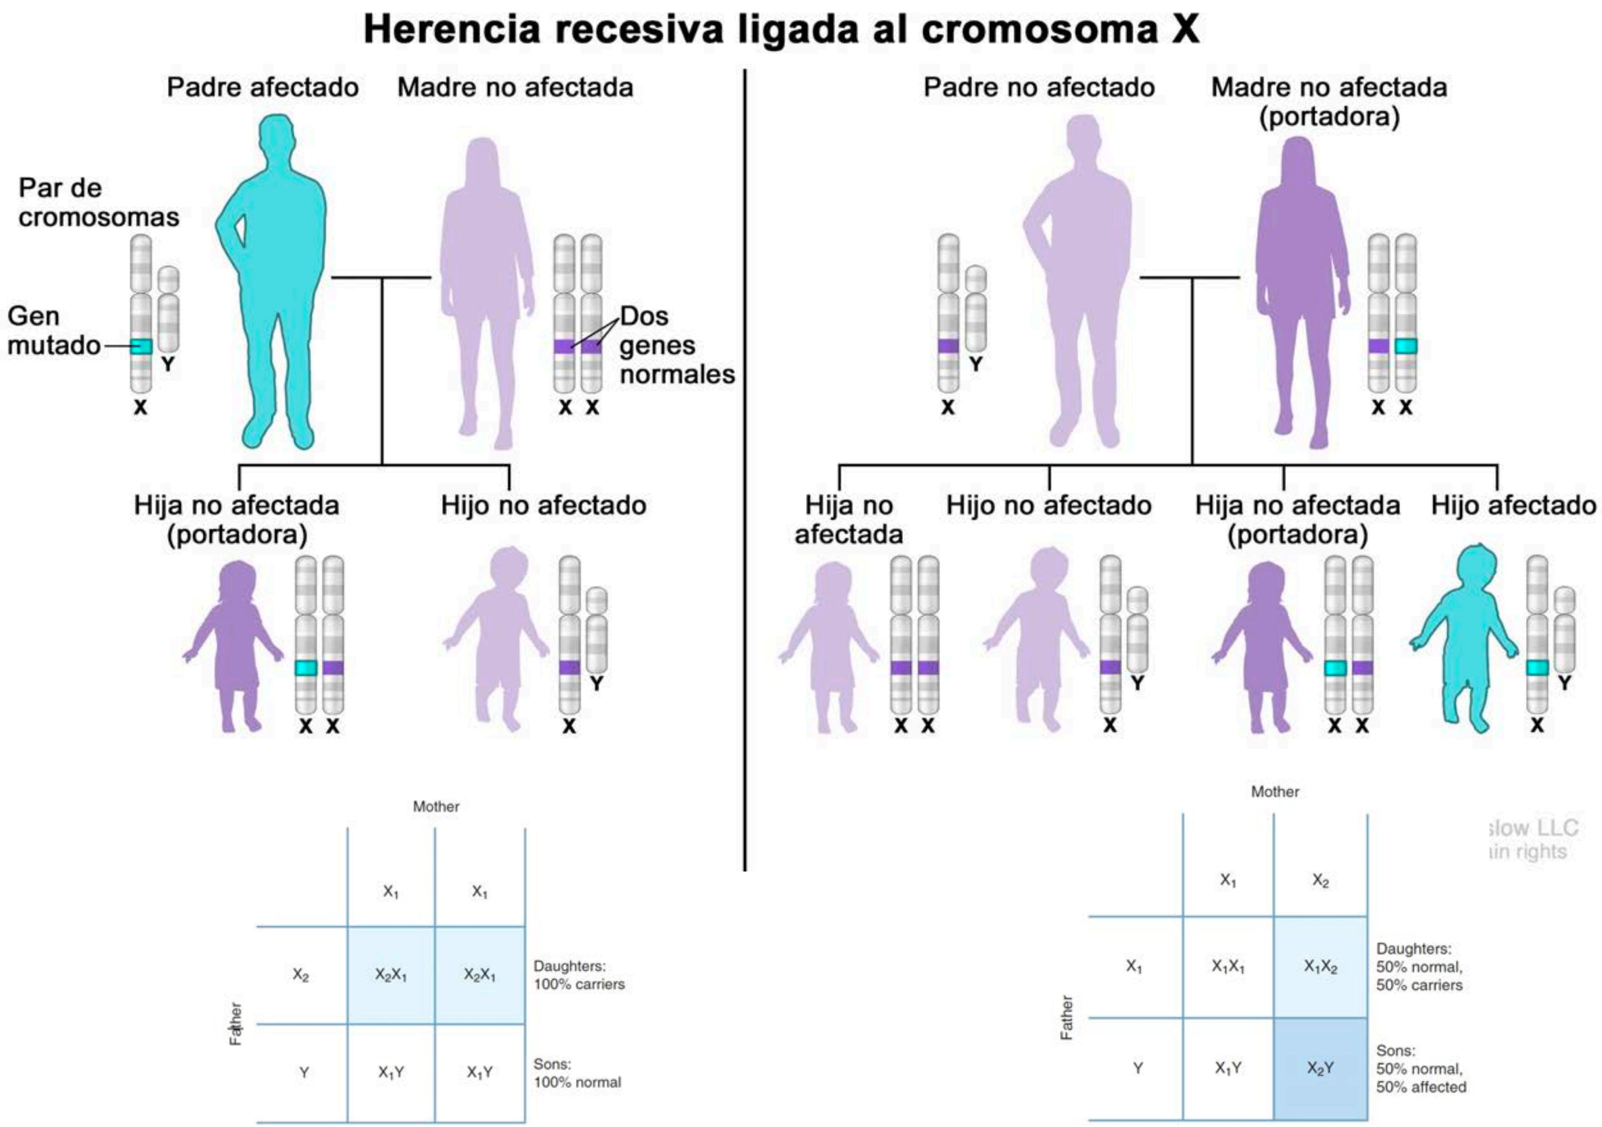

Índice

Whole-Genome Genotyping

- Microarrys
- NGS

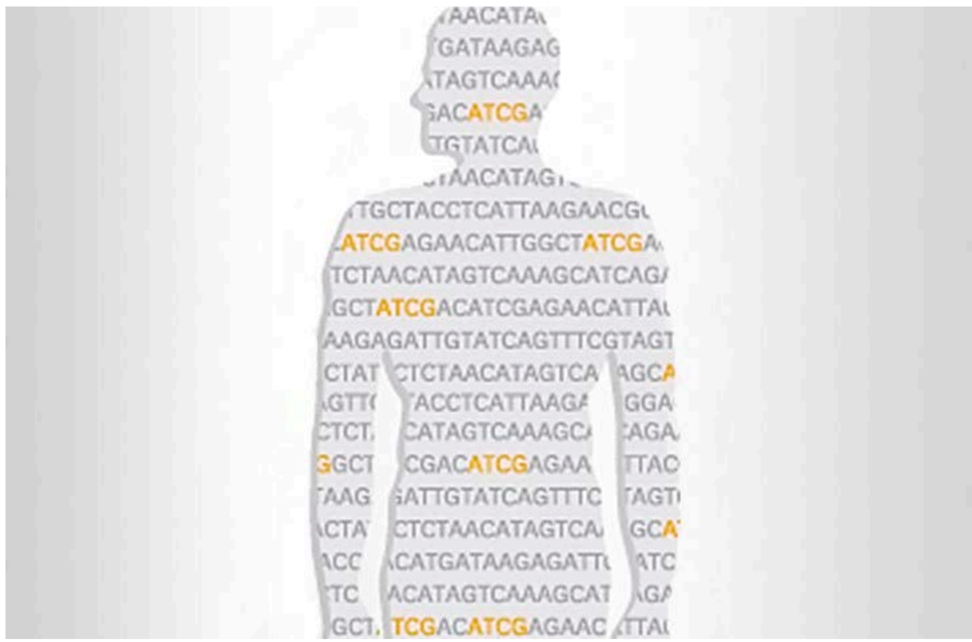

Illumina Infinium OmniExpress-24 Kit

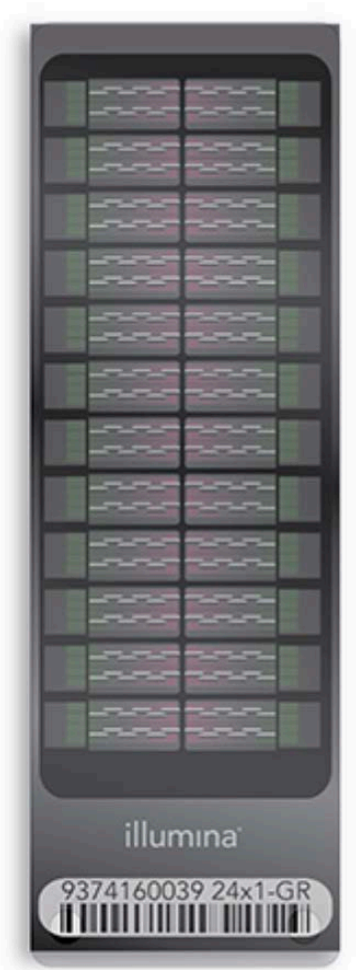

24 muestras por array
Sondas: aprox. 710.000

Illumina Infinium Assay

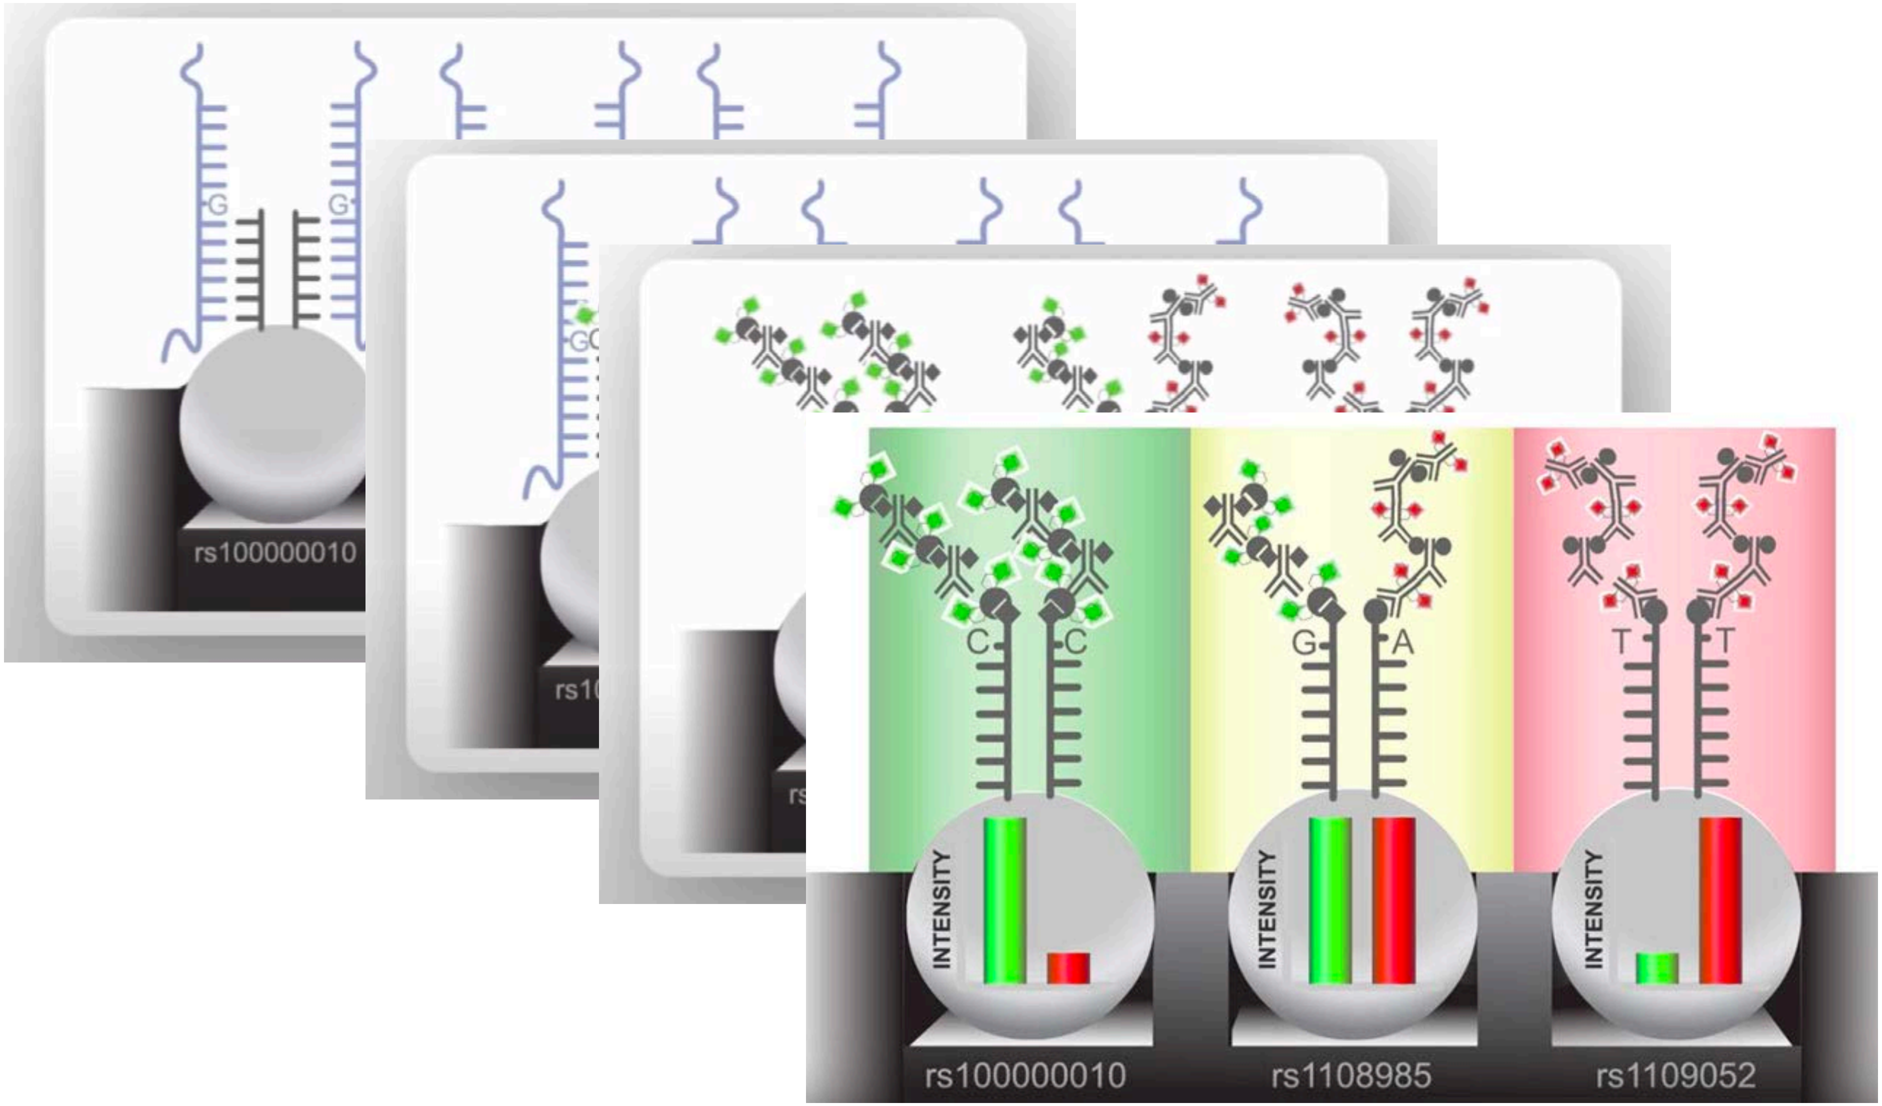

Illumina Infinium Assay

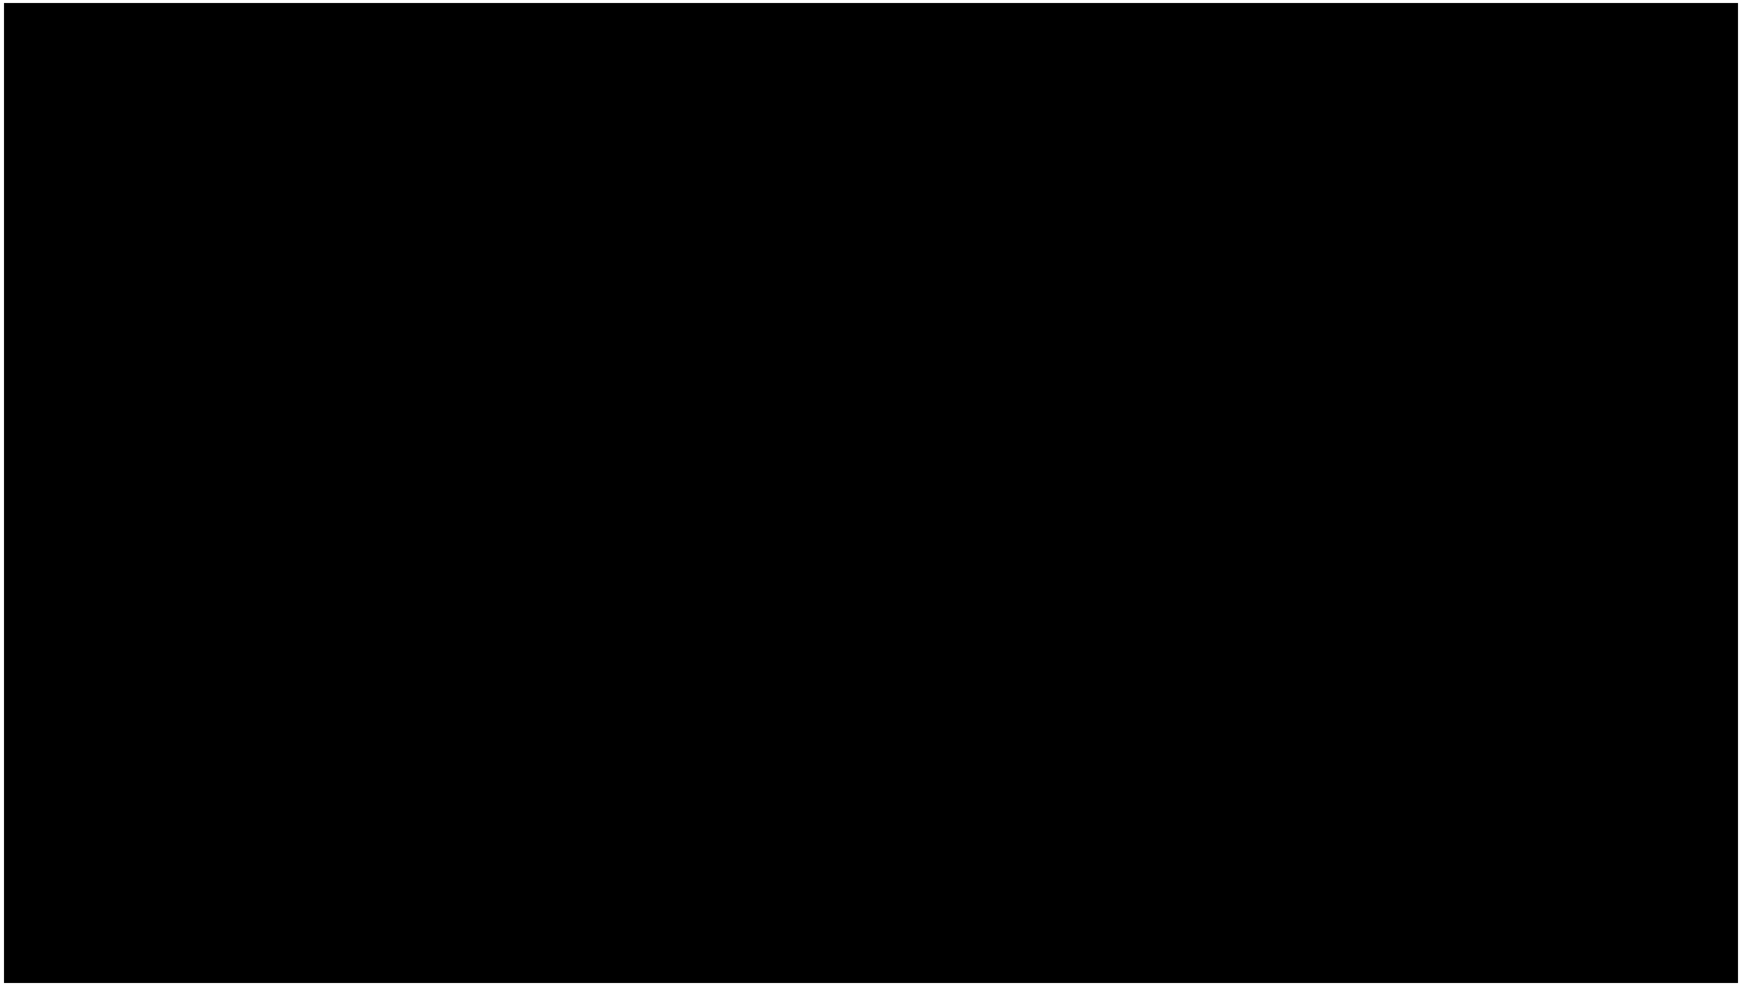

Práctica: Illumina microarrays

- ¿Qué información hay en un microarray de Illumina?
- ¿Cuántas sondas/SNPs incorpora?
- ¿Cuántas sondas hay para alguno de los genes que pueden interesarnos?

Índice

- Patrones de herencia
- Microarray de genotipado
- Bases de datos de variantes
- Direct-to-Consumer Genomic Testing
- Personal Genome Project
- Enfermedades monogénicas
  - Alzheimer y APOE
  - Cáncer de mama y útero y BRCA1, BRCA2
  - Fibrosis quística y CFTR
- Interpetación: Odds ratio

dbSNP Reference (rs) number

- El catálogo RefSNP es una colección no redundante de variantes publicadas que han sido agrupadas, integradas y anotadas
- El número RefSNP es un método de acceso estable independientemente de las diferencias en los ensamblajes genómicos
- Los números RefSNP facilitan los estudios a gran escala en genética de asociación, genética médica, genómica funcional y farmacológica, genética de poblaciones y biología evolutiva, genómica personal y medicina de precisión
- Proporcionan una notación de variantes estable para el análisis de mutaciones y polimorfismos, la anotación, la elaboración de informes, la extracción de datos y la integración de datos

Práctica: dbSNP y bases de datos asociadas

- dbSNP
- ClinVar
- LitVar
- Variation Viewer
- OMIM

Índice

- Patrones de herencia
- Microarray de genotipado
- Bases de datos de variantes
- Direct-to-Consumer Genomic Testing
- Personal Genome Project
- Enfermedades monogénicas
  - Alzheimer y APOE
  - Cáncer de mama y útero y BRCA1, BRCA2
  - Fibrosis quística y CFTR
- Interpetación: Odds ratio

Direct-to-Consumer Genomic Testing (23andMe)

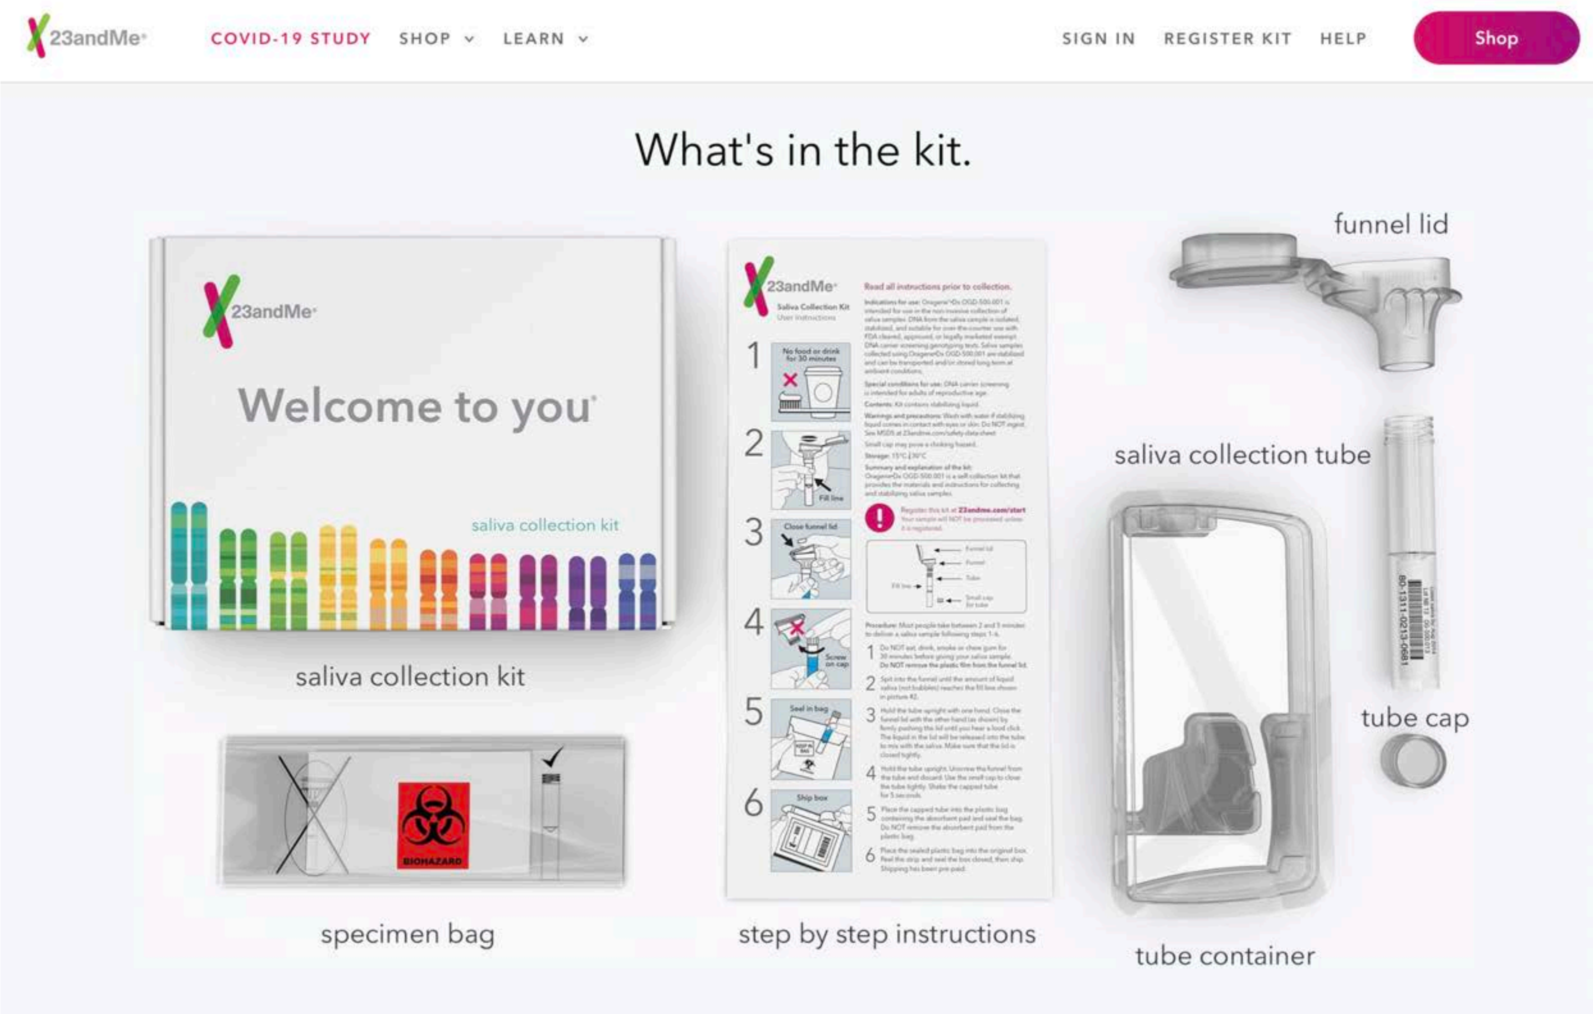

Direct-to-Consumer Genomic Testing (MyHeritage)

MyHeritage DNA Family tree Research Help

Our technology and standards

In accordance with the industry standard, MyHeritage uses the Illumina OmniExpress-24 chip, with hundreds of thousands of strategically selected probes to capture the greatest amount of genetic variation, and facilitate research. The lab is CLIA-certified (CLIA is the Clinical Laboratory Improvement Amendments), a standard indicating, among other key qualifications, that all lab technicians who analyze MyHeritage users' DNA have achieved a particular level of qualification. The lab is also CAP-accredited, the highest level of credential in the United States for this kind of laboratory.

Descarga de datos 23andMe

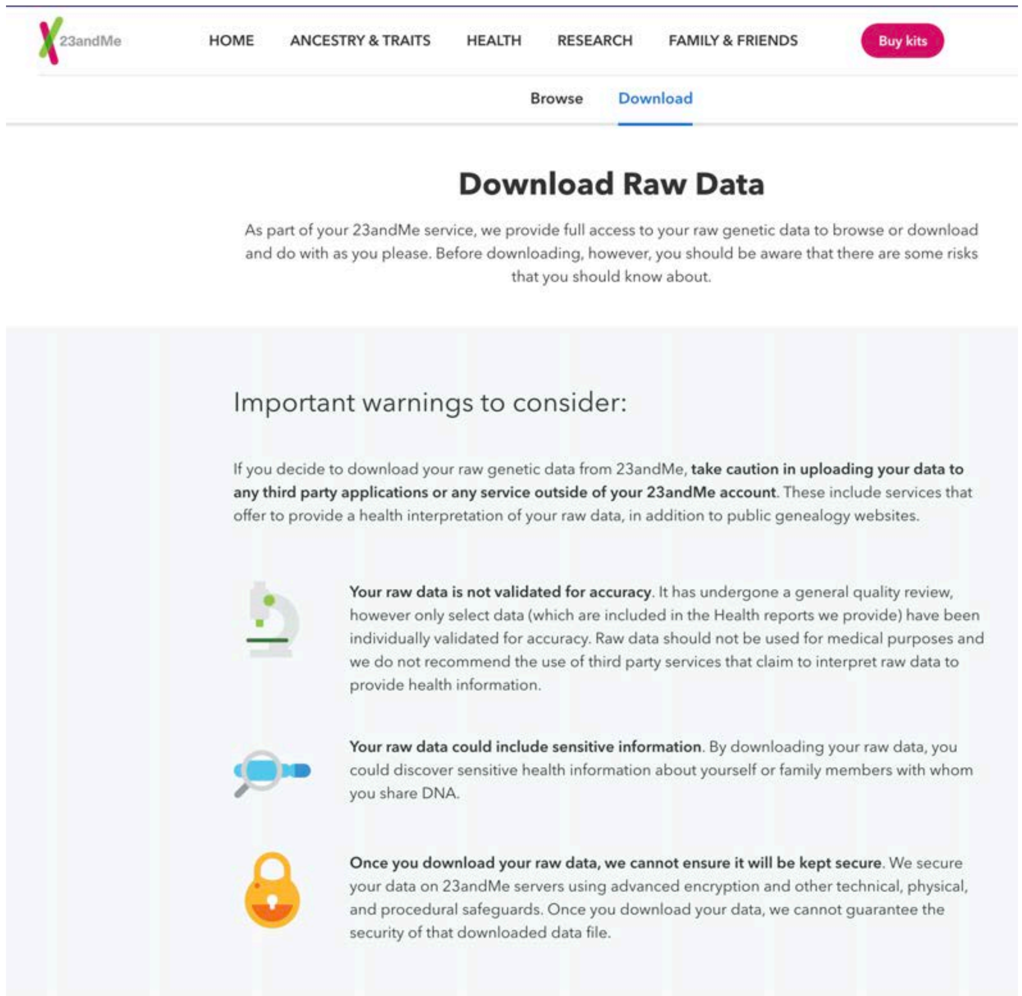

Descarga de datos en MyHeritage

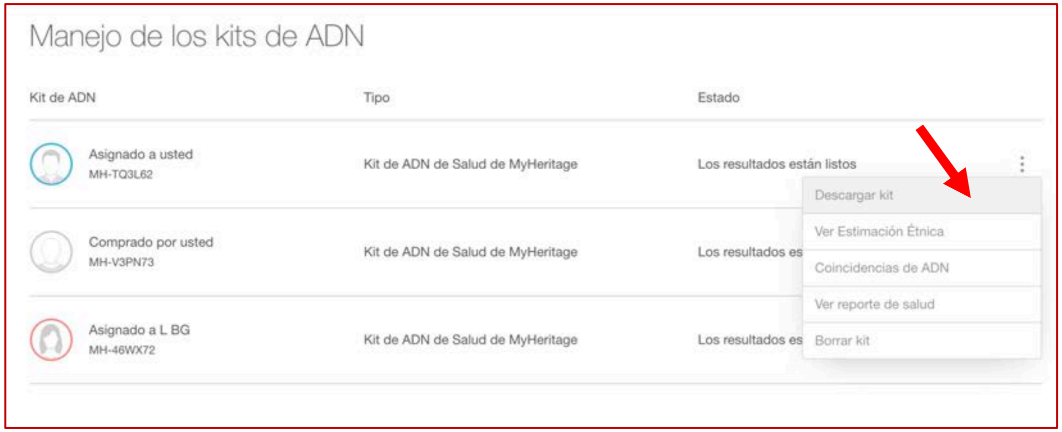

Descarga de archivo de datos de ADN

El archivo de datos de ADN incluye los datos sin procesar de su muestra de ADN producidos por el laboratorio. La prueba de ADN de MyHeritage cubre entre 600.000 y 700.000 SNPs (polimorfismos de un solo nucleótido) usados para calcular sus resultados y compararlos con los resultados de ADN de otras personas.

Usted puede leer más acerca de los SNPs en el International Society of Genetic Genealogy Wiki.

Su archivo de datos de ADN se descargará como un archivo de texto. Los datos aparecen en una tabla, en la que cada línea representa un SNP. Incluye los siguientes valores:

- rsID - Reference SNP Cluster ID. Este número es la escala de fiabilidad que permite el control del conocimiento sobre los SNPs contribuidos por diferentes proyectos de investigación en todo el mundo sin duplicaciones ni solapados. Cada SNP está asociado con un rsDI.
- Cromosoma - Especifica en qué cromosoma está localizado el SNP específico.
- Posición - Indica la posición del SNP en la parte superior del cromosoma. Cada cromosoma está compuesto por dos áreas en la estructura en hélice llamada un alelo.
- Alelo 1 - Cuál nucleótido de su secuencia de ADN presenta en esta posición en el cromosoma que es una estructura sencilla de la hélice.
- Alelo 2 - Cuál nucleótido de su secuencia de ADN presenta en esta posición en el cromosoma que es una estructura doble de la hélice.

Usted puede leer más sobre nucleótidos y la estructura de doble hélice del ADN en el International Society of Genetic Genealogy Wiki.

Un ejemplo del archivo de datos de ADN tiene esta apariencia:

```
RSID,CHROMOSOME,POSITION,RESULT
"rs3094315","1","752566","AA"
"rs3131972","1","752721","AA"
"rs12562034","1","768448","GG"
"rs12124819","1","776546","AA"
"rs11240777","1","798959","GG"
"rs6681049","1","800007","CC"
```

Índice

- Patrones de herencia
- Microarray de genotipado
- Bases de datos de variantes
- Direct-to-Consumer Genomic Testing
- Personal Genome Project
- Enfermedades monogénicas
  - Alzheimer y APOE
  - Cáncer de mama y útero y BRCA1, BRCA2
  - Fibrosis quística y CFTR
- Interpetación: Odds ratio

Personal Genome Project

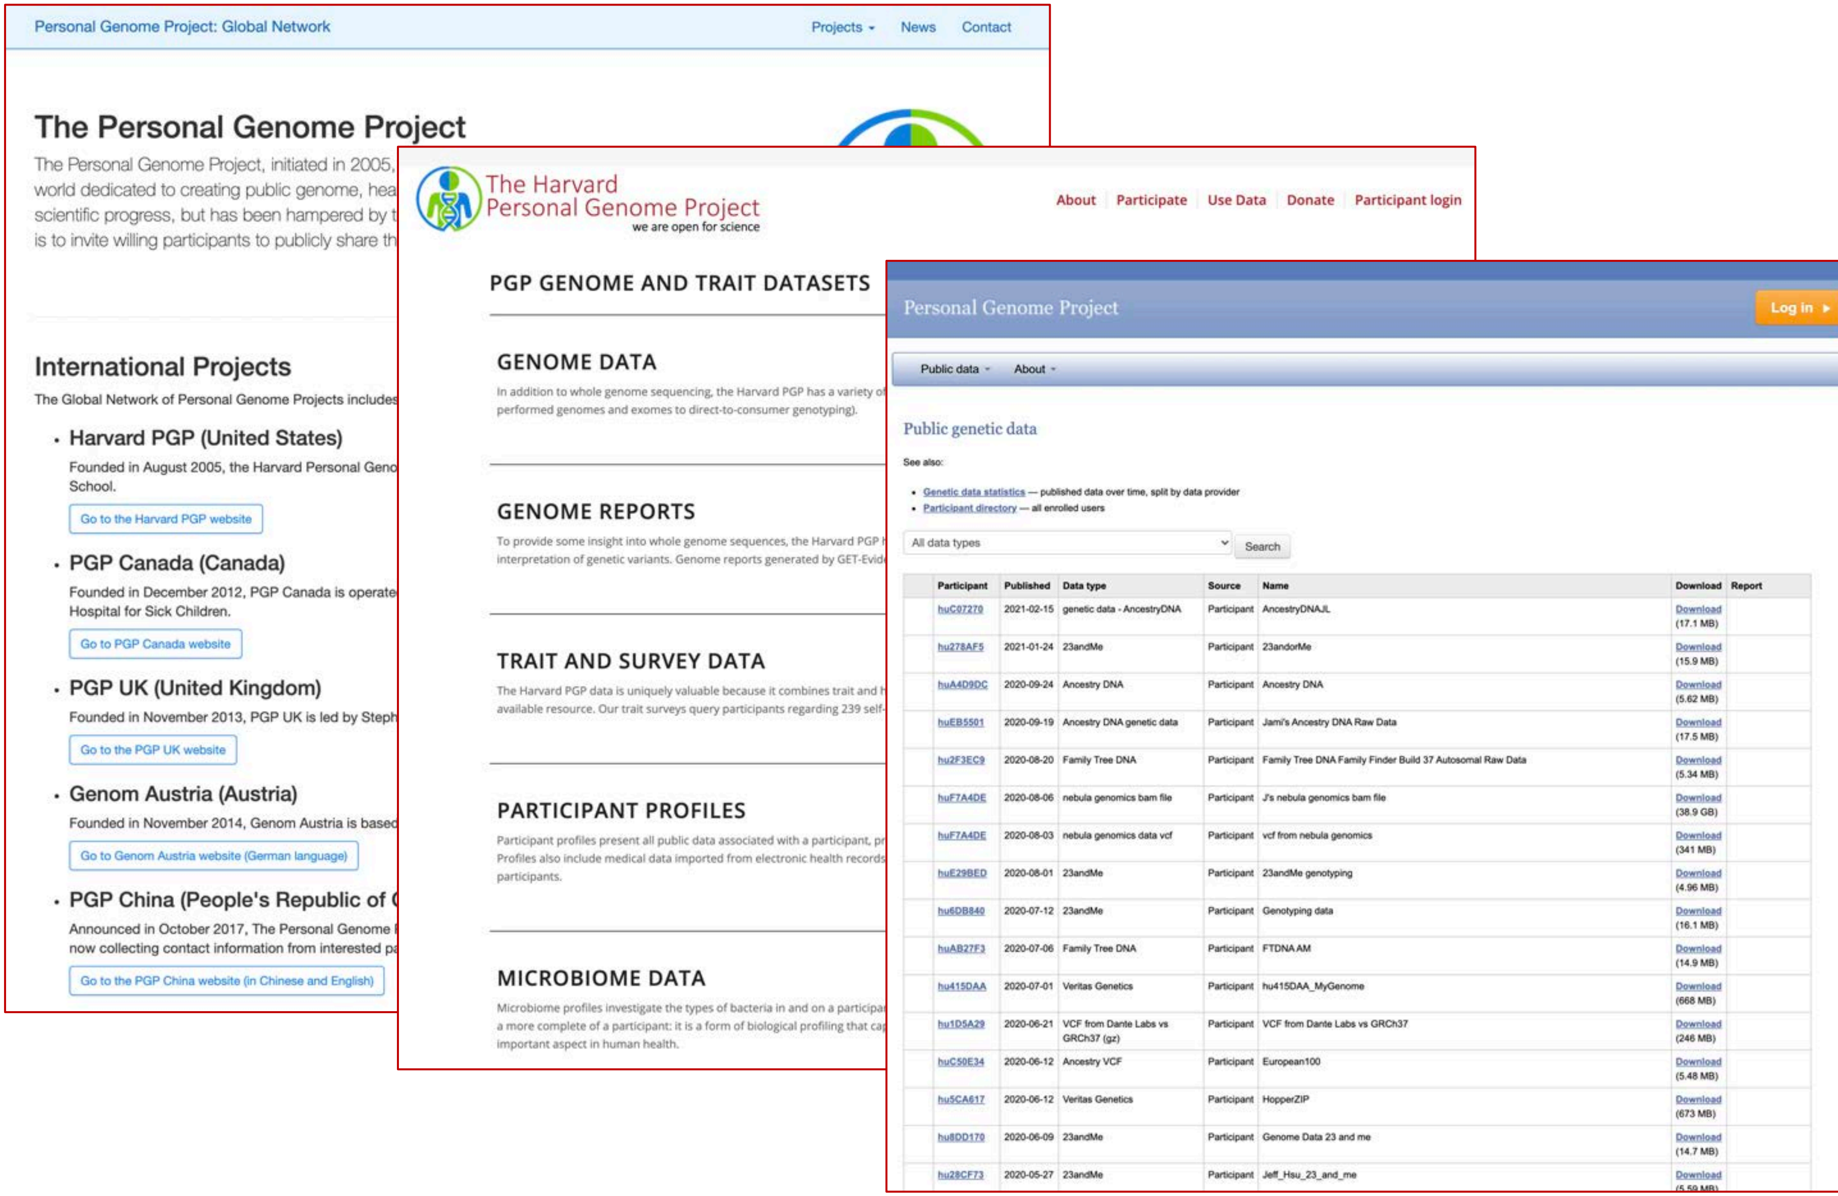

Descargar el genoma humano (UCSC)

Práctica: raw format de microarrays

- Descargar datos raw del tipo ”23andMe” desde Harvard PGP
- Descomprimir (si es necesario) y visualizar su contenido
- Consultar en dbSNP alguno de los rsIDs
- Convertir a formato VCF
- Visualizar con IGV

Índice

- Patrones de herencia
- Microarray de genotipado
- Bases de datos de variantes
- Direct-to-Consumer Genomic Testing
- Personal Genome Project
- Enfermedades monogénicas
  - Alzheimer y APOE
  - Cáncer de mama y útero y BRCA1, BRCA2
  - Fibrosis quística y CFTR
- Interpetación: Odds ratio

Alzheimer y APOE

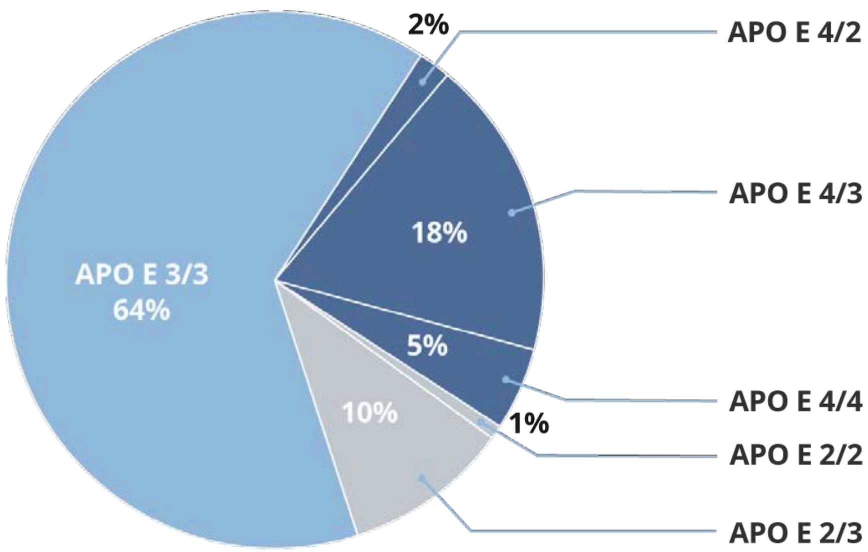

Genotype	E2/E2	E2/E3	E2/E4	E3/E3	E3/E4	E4/E4
Disease Risk	40% less likely	40% less likely	2.6 times more likely	Average risk	3.2 times more likely	14.9 times more likely

APOE Allele	rs429358	rs7412
ε2/ε2	TT	TT
ε2/ε3	TT	TC
ε2/ε4	TC	TC
ε3/ε3	TT	CC
ε3/ε4	TC	CC
ε4/ε4	CC	CC

Práctica: APOE genotipo

- Genotipado de
  - rs429358
  - rs7412
- Visualización con IGV del gen APOE y los dos rsIDs anteriores

Índice

BRCA1 y BRCA2

- Los genes BRCA1 y BRCA2 codifican proteínas que son fundamentales para que las células reparen el ADN dañado
- Las mutaciones específicas heredadas en estos genes aumentan el riesgo de varios tipos de cáncer, en particular el de mama y el de ovario
- El riesgo se ve influido por la localización de las mutaciones dentro de los genes BRCA y el alcance de los antecedentes familiares de cáncer de mama

Estadísticas BRCA1, BRCA2

BRCA1/2 associated cancer risks.

Cancer Type	General Population Risk	Mutation Risk	
		BRCA1	BRCA2
Breast	12%	50%-80%	40%-70%
Second primary breast	3.5% within 5 years Up to 11%	27% within 5 yrs	12% within 5 yrs 40%-50% at 20 yrs
Ovarian	1%-2%	24%-40%	11%-18%
Male breast	0.1%	1%-2%	5%-10%
Prostate	15% (N. European origin) 18% (African Americans)	<30%	<39%
Pancreatic	0.50%	1%-3%	2%-7%

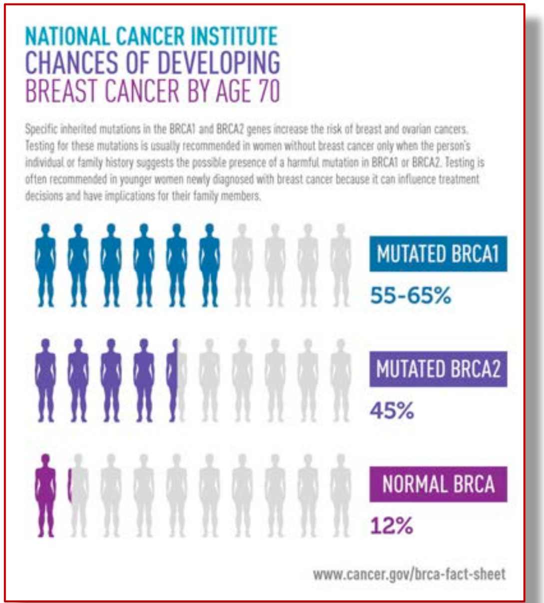

Myriad Genetics

EL PAÍS

La revelación de Angelina Jolie mueve el parqué de Wall Street

Las acciones de Myriad Genetics, que desarrolla la prueba que detecta si se puede padecer cáncer de mama, se dispararon un 15% tras la confesión de la actriz

SANDRO POZZI

Nueva York - 10 JUN 2013 - 18:26 CEST

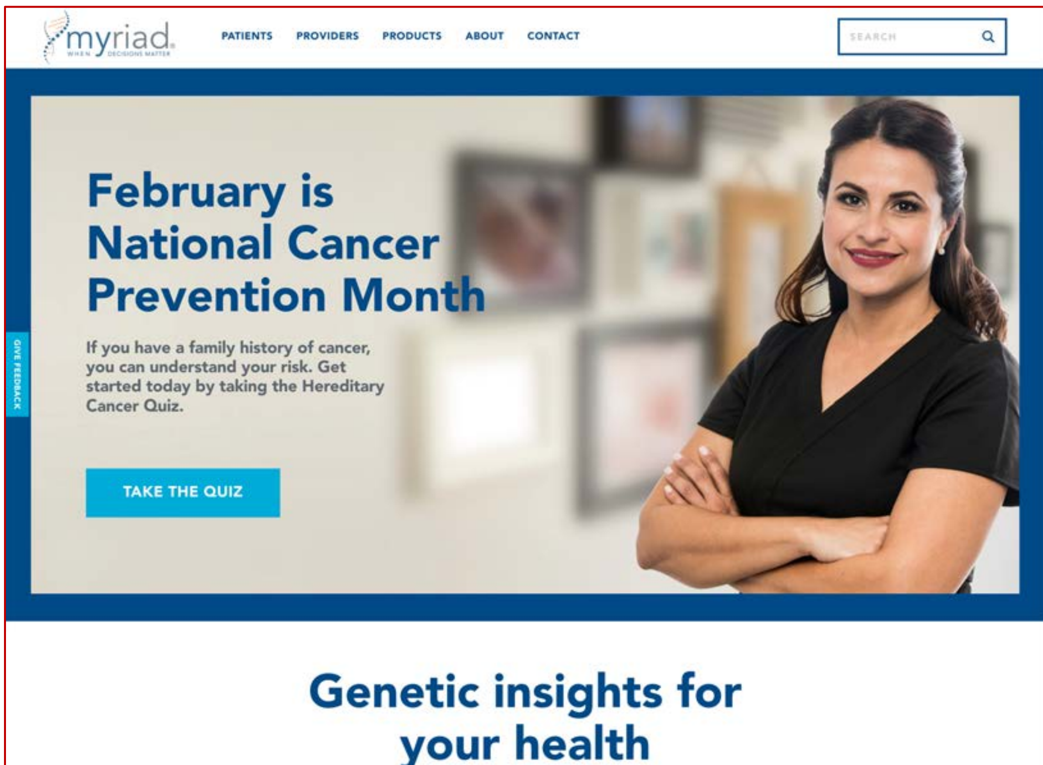

BRCAnalysis

BRACAnalysis®

BRACAnalysis®

BRACAnalysis®: H
Hereditary Breast a

BRACAnalysis® is a genetic test that de
responsible for the majority of hereditar
the BRCA1 or BRCA2 gene have risks of
developing ovarian cancer by age 70. M
increased risk of developing a second p
percent chance of developing a second

BRACAnalysis requires only a simple blo
or BRCA2 mutation. Knowing the results
the onset of cancer or detect it at an ear

Myriad has developed a Hereditary Can
genetic testing using BRACAnalysis.

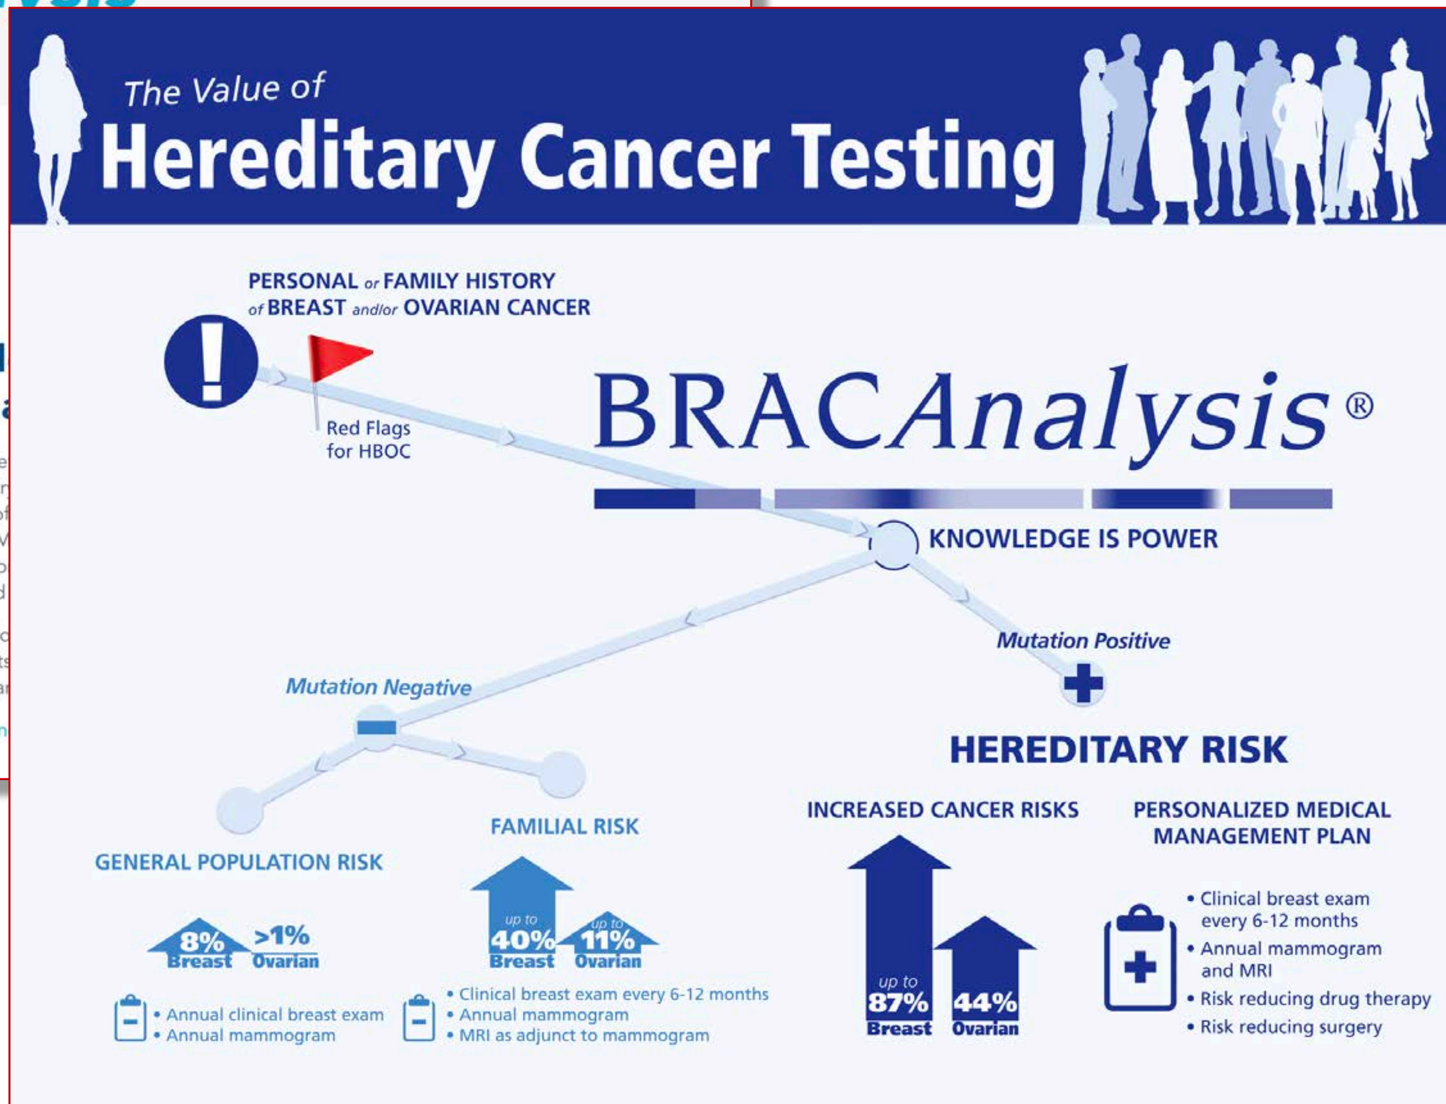

BRCA1, BRCA2 ubicación

Genomic Locations for BRCA1 Gene

Genomic Locations for BRCA1 Gene

chr17:43,044,295-43,170,245 (GRCh38/hg38)

Size: 125,951 bases *Orientation:* Minus strand

chr17:41,196,312-41,277,500 (GRCh37/hg19)

Size: 81,189 bases *Orientation:* Minus strand

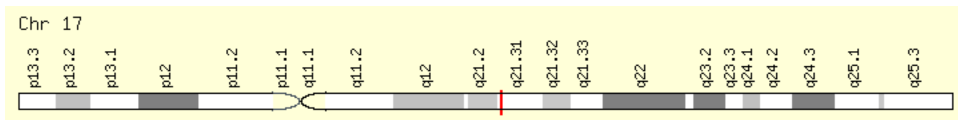

Genomic Locations for BRCA2 Gene

Genomic Locations for BRCA2 Gene

chr13:32,315,086-32,400,268 (GRCh38/hg38)

Size: 85,183 bases *Orientation:* Plus strand

chr13:32,889,611-32,973,809 (GRCh37/hg19)

Size: 84,199 bases *Orientation:* Plus strand

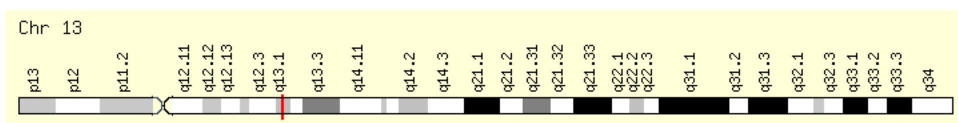

BRCA1, BRCA2

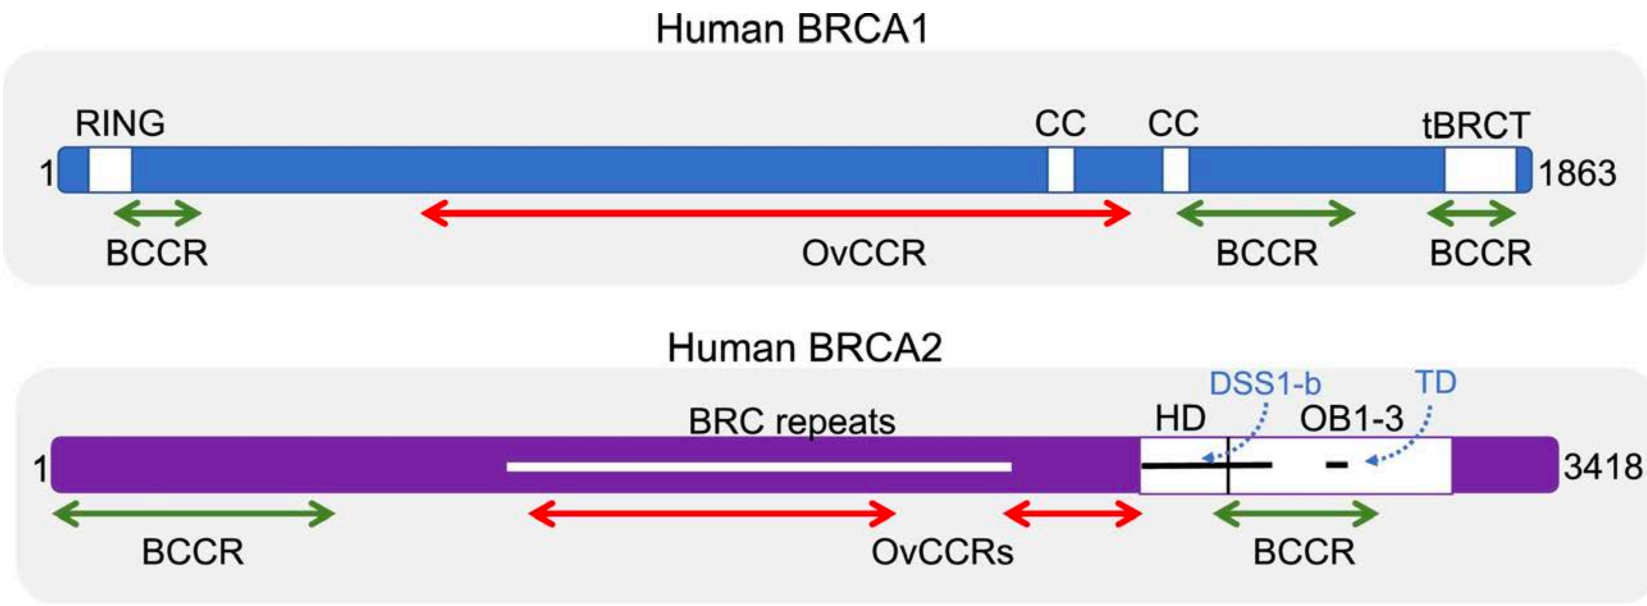

Human BRCA1
RING
CC
CC
tBRCT
1
1863
BCCR
OvCCR
BCCR
BCCR
Human BRCA2
DSS1-b
TD
BRC repeats
HD
OB1-3
1
3418
BCCR
OvCCRs
BCCR

BRCA Exchange

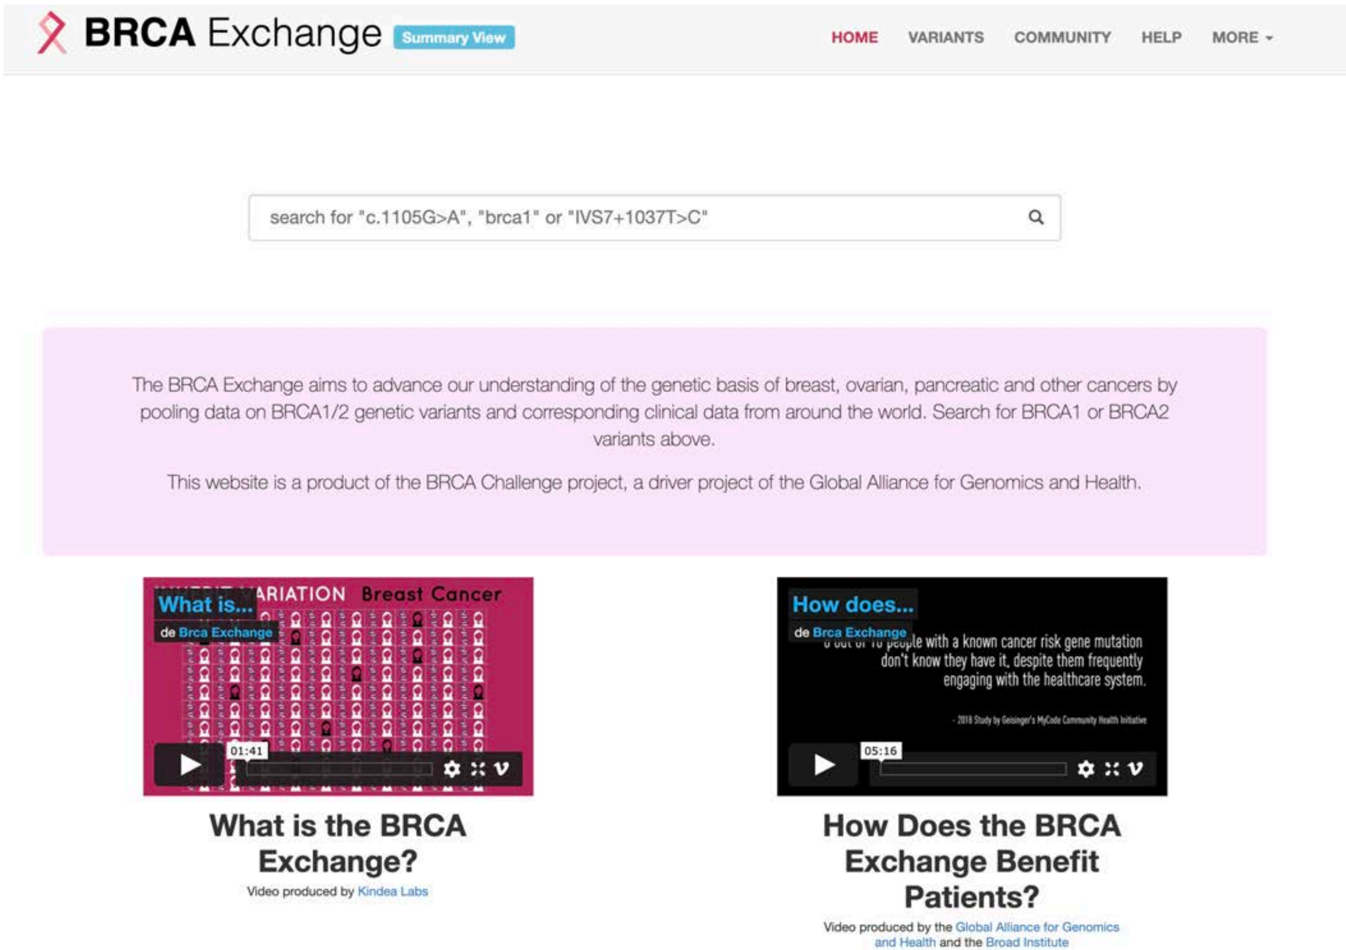

Práctica: genotipado de BRCA1 y BRCA2

- Identificar las variantes reportadas que afectan a BRCA1 y BRCA2
- Pasos:
  - Detectar las variantes presentes en las coordenadas genómicas correspondientes a cada gen
  - Verificar si las variantes son patogénicas
  - ANNOVAR
  - BRCA Exchange

Índice

- Patrones de herencia
- Microarray de genotipado
- Bases de datos de variantes
- Direct-to-Consumer Genomic Testing
- Personal Genome Project
- Enfermedades monogénicas
  - Alzheimer y APOE
  - Cáncer de mama y útero y BRCA1, BRCA2
  - Fibrosis quística y CFTR
- Interpetación: Odds ratio

Fibrosis quística

- Enfermedad genética
- Herencia autosómica recesiva
- Afecta a pulmones y en menor medida páncreas, hígado e intestino

PAIS	INCIDENCIA
Dinamarca	1/4700
España	1/7213
Finlandia	1/25000
Francia	1/4000
Francia (Bretaña)	1/2913
Holanda	1/3600
Irlanda	1/1461
Italia	1/2730
Noruega	1/6500
Reino Unido	1/2400
Suecia	1/4000
Suiza	1/2000

Gen CFTR

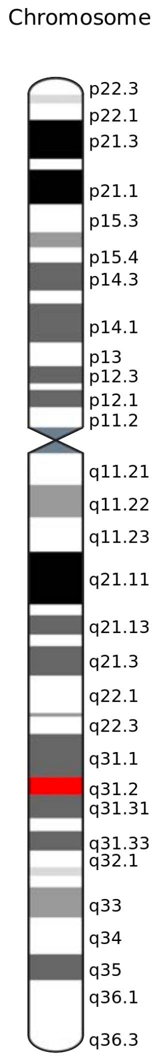

- Símbolo gen: CFTR
- Nombre proteína: Cystic Fibrosis Transmembrane conductance Regulator
- Cromosoma 7, región 7q31
- 189 kb
- 27 exones
- RefSeq: NP_000483
- Uniprot: P13569
- Proteína: 1480 aa

Base de datos de mutaciones: estadísticas

Cystic Fibrosis Mutation Database

Home Search CFTR Gene History Team Statistics Links Submit Help

CFMDB Statistics

There are currently **2103** mutations listed in this CFTR mutation database.

Statistics by mutation type:

Mutation Type	Count	Frequency %
Missense	815	38.75
Frameshift	342	16.26
Splicing	230	10.94
Nonsense	177	8.42
In frame in/del	43	2.04
Large in/del	59	2.81
Promoter	17	0.81
Sequence variation	269	12.79
Unknown	151	7.18

Frecuencia de mutaciones (I)

Journal of
Cystic Fibrosis

Log in Register

ORIGINAL ARTICLE | VOLUME 13, ISSUE 4, P403-409, JULY 01, 2014

PDF [665 KB] Figures

The relative frequency of *CFTR* mutation classes in European patients with cystic fibrosis

K. De Boeck • A. Zolin • H. Cuppens • H.V. Olesen • L. Viviani

Published: January 21, 2014 • DOI: https://doi.org/10.1016/j.jcf.2013.12.003 • Check for updates

Abstract

More than 1900 different mutations in the *CFTR* gene have been reported. These are grouped into classes according to their effect on the synthesis and/or function of the CFTR protein. CFTR repair therapies that are mutation or mutation class specific are under development. To progress efficiently in the clinical phase of drug development, knowledge of the relative frequency of *CFTR* mutation classes in different populations is useful. Therefore, we describe the mutation class spectrum in 25,394 subjects with CF from 23 European countries.

In 18/23 countries, 80% or more of the patients had at least one class II mutation, explained by F508del being by far the most frequent mutation. Overall 16.4% of European patients had at least one class I mutation but this varied from 3 countries with more than 30% to 4 countries with less than 10% of subjects. Overall only respectively 3.9, 3.3 and 3.0% of European subjects had at least one mutation of classes III, IV and V with again great variability: 14% of Irish patients had at least one class III mutation, 7% of Portuguese patients had at least one class IV mutation, and in 6 countries more than 5% of patients had at least one class V mutation.

Frecuencia de mutaciones (II)

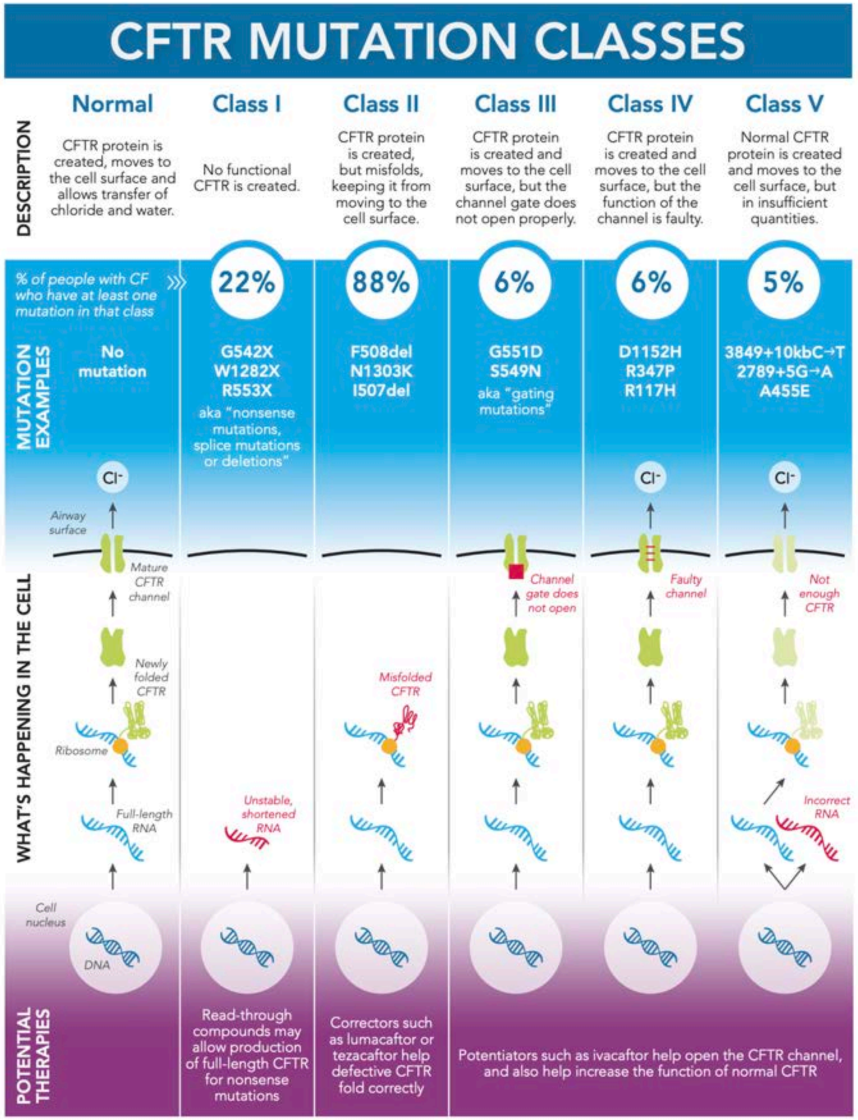

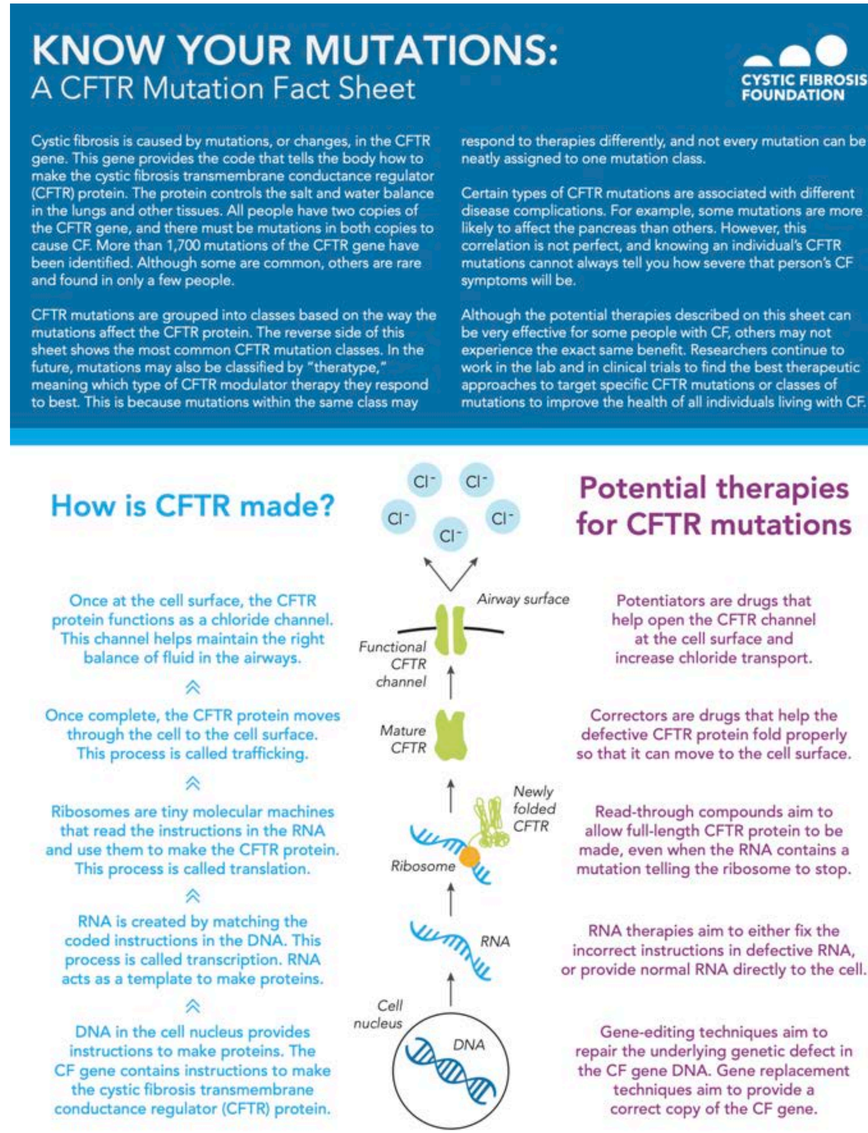

Práctica: genotipado de CFTR

- Identificar las variantes reportadas que afectan CFTR
- Pasos:
  - Detectar las variantes presentes en las coordenadas genómicas correspondientes al gen
  - Verificar si las variantes son patogénicas
  - ANNOVAR

Índice

- Patrones de herencia
- Microarray de genotipado
- Bases de datos de variantes
- Direct-to-Consumer Genomic Testing
- Personal Genome Project
- Enfermedades monogénicas
  - Alzheimer y APOE
  - Cáncer de mama y útero y BRCA1, BRCA2
  - Fibrosis quística y CFTR
- Interpetación: Odds ratio

Sentido común e interpretación cautelosa

- Preguntas clave
  - ¿Es realmente probable que el rasgo/enfermedad sea producido por un solo SNP?
    - Probablemente haya que hacer algún estudio adicional
  - ¿Es correcto y reproducible?
    - Número de estudios/publicaciones relacionadas con el SNP
  - ¿En qué medida me va a afectar como individuo?
    - Tamaño de efecto
    - Necesitamos la estadística

Odds ratio (OR)

- Si encontramos que un SNP tiene un OR=1.3 para un alelo G de un accidente cerebrovascular significa:
  - Para cada alelo G es 1.3 veces más probable que una persona esté en el grupo de personas que tiene accidentes cerebrovasculares
- Valores típicos:
  - 1.1-1.5
- Valores no tan típicos:
  - OR=3.5 APOE en Alzheimer
  - Tabaquismo OR=16, para provocar cáncer de pulmón
    - No todo es la composición genética del individuo: ambiente y hábitos

DESVÍO: Traducciones de *odds ratio*

- desigualdad relativa
- razón de productos cruzados
- producto cruzado
- cociente de probabilidades relativas
- oportunidad relativa
- razón de oposiciones
- razón de momios
- razón del producto cruzado
- razón de ventajas
- relación de probabilidad
- razón de probabilidad
- relación impar
- razón de posibilidades

Tabla de contingencia 2x2

	Alelo riesgo si	**Alelo riesgo no**	Total
Caso (enfermo)	***a***	***b***	*a+b*
Control (sano)	***c***	***d***	*c+d*
Total	*a+c*	*b+d*	*a+b+c+d*

Simétrico

$$OR = \frac{a/c}{b/d} = \frac{ad}{bc}$$

$$OR = \frac{a/b}{c/d} = \frac{ad}{bc}$$

$$SE(\ln(OR)) = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$$

OR: Ejemplo 1 (parte 1)

Enfermedad cardiovascular

rs4977574

	Alelo riesgo si	**Alelo riesgo no**	Total
Enfermo	***8000***	***7000***	*15000*
Sano	***7000***	***8000***	*15000*
Total	*15000*	*15000*	*30000*

$$OR = \frac{8000/7000}{7000/8000} = \mathbf{1.31}$$

$$SE(\ln(OR)) = \sqrt{\frac{1}{8000} + \frac{1}{7000} + \frac{1}{7000} + \frac{1}{8000}}$$

$$CI(95)_{lower} = e^{\ln(OR)-1.96*SE} = \mathbf{1.25}$$

$$CI(95)_{upper} = e^{\ln(OR)+1.96*SE} = \mathbf{1.37}$$

OR: Ejemplo 1 (parte 2)

Se sabe que aproximadamente el 0.1% de la población entre 35 y 74 años muere cada año a causa de una enfermedad coronaria

Ahora hacemos el muestro aleatoriamente en individuos entre 35 y 74 años

¿Qué encontraríamos para tener un OR = 1.3?

	Alelo riesgo si	**Alelo riesgo no**	Total
Enfermo	***6***	***5***	*10*
Sano	***4700***	***5300***	*10000*
Total	*4706*	*5305*	*10011*

OR = 1.35 (CI95: 0.41-4.44)

11/10011 = 0.11%
6/4706 = 0.13%

Conclusión: si tengo el alelo de riesgo tengo un 0.13% de probabilidad de estar enfermo, en lugar de 0.11%.

Es mejor decir que el OR es 1.3, que decir que se tiene un 30% de incremento de riesgo

OR: Ejemplo 2. Efecto alto.

Fumador y cáncer de pulmón

	Fumador	**No fumador**	Total
Enfermo	***647***	***2***	*649*
Sano	***622***	***27***	*649*

OR = **14.04** (CI95: 3.3-59.3)

Preocupante:

- OR > 5
- "complete disease association"
- "completely penetrant"

OR: Ejemplo 3. Gene BRCA2

	BRCA2 alelo	NO BRCA2 alelo
Cáncer de mama	***3k***	***110k***
No cáncer de mama	***2k***	***890k***

OR = **12.1** (CI95: 2.0-73.4)

3/2 ➔ 50% más probable cáncer de mama si alelo
(3+2)/(3+110+2+890) ➔ 0.5% frecuencia de mutación BRCA2
(110+3)/(3+110+2+890) ➔ 11% prevalencia cáncer de mama

Cálculos de OR con Python

```
import numpy as np
from sys import argv
from scipy.stats import norm

a = int(argv[1])
b = int(argv[2])
c = int(argv[3])
d = int(argv[4])

oddsratio = (a*d)/(b*c)
logodd = np.log(oddsratio)
selogodd = np.sqrt(1/a + 1/b +1/c +1/d)
#ci_low_95 = np.exp(logodd-1.96*selogodd)
#ci_upp_95 = np.exp(logodd+1.96*selogodd)
ci_low_90 = np.exp(logodd-norm.ppf(.95)*selogodd)
ci_upp_90 = np.exp(logodd+norm.ppf(.95)*selogodd)
ci_low_95 = np.exp(logodd-norm.ppf(.975)*selogodd)
ci_upp_95 = np.exp(logodd+norm.ppf(.975)*selogodd)
ci_low_99 = np.exp(logodd-norm.ppf(.995)*selogodd)
ci_upp_99 = np.exp(logodd+norm.ppf(.995)*selogodd)
print ('Odds ratio = %.2f' %oddsratio)
print ('CI (90%%) = %.2f - %.2f' % (ci_low_90,ci_upp_90))
print ('CI (95%%) = %.2f - %.2f' % (ci_low_95,ci_upp_95))
print ('CI (99%%) = %.2f - %.2f' % (ci_low_99,ci_upp_99))
```

Genotipado con microarrays
Máster en Sistemas Inteligentes

Luis Quintales
Departamento de Informática

VNiVERSiDAD
D SALAMANCA