




Trabajo Final de Minería de Datos

Aplicación de técnicas de Minería de
datos con la herramienta WEKA

[Arlet Acosta González](#)

MÁSTER EN SISTEMAS INTELIGENTES
UNIVERSIDAD DE SALAMANCA

Descripción del conjunto de datos

Entre los arroces certificados cultivados en Turquía, se han seleccionado para el estudio la especie Osmancik, que cuenta con una gran superficie de plantación desde 1997, y la especie Cammeo, cultivada desde 2014.

La especie Osmancik, tiene un aspecto ancho, largo, vidrioso y opaco; mientras la especie Cammeo, tiene un aspecto ancho y largo, vítreo y opaco. Se tomaron un total de 3810 imágenes de granos de arroz para las dos especies, se procesaron y se hicieron inferencias de características. Se obtuvieron 7 características morfológicas para cada grano de arroz:

1. Área: Devuelve el número de píxeles dentro de los límites del grano de arroz.
2. Perímetro: Calcula la circunferencia calculando la distancia entre píxeles alrededor de los límites del grano de arroz.
3. Longitud del eje mayor: la línea más larga que se puede dibujar en el grano de arroz, es decir, la distancia del eje principal.
4. Longitud del eje menor: la línea más corta que se puede dibujar en el grano de arroz, es decir, la distancia del eje más pequeño.
5. Excentricidad: Mide qué tan redonda es la elipse.
6. Área convexa: Devuelve el recuento de píxeles de la capa convexa más pequeña de la región formada por el grano de arroz.
7. Extensión: Devuelve la relación entre la región formada por el grano de arroz y los píxeles del cuadro delimitador.
8. Clase: Arroces Cammeo y Osmancik

Objetivo

El objetivo del trabajo es clasificar el arroz en dos especies: Cammeo y Osmancik, en dependencia de los valores de las características morfológicas.

Preprocesamiento de los datos

El aspecto que tiene el data set seleccionado se muestra en la figura 1.

Viewer								
Relation: Rice_Cammeo_Osmancik								
No.	1: Area Numeric	2: Perimeter Numeric	3: Major_Axis_Length Numeric	4: Minor_Axis_Length Numeric	5: Eccentricity Numeric	6: Convex_Area Numeric	7: Extent Numeric	8: Class Nominal
1	15231.0	525.5789794921875	229.7498779296875	85.09378814697266	0.9288820028305054	15617.0	0.5728955268859863	Cammeo
2	14656.0	494.3110046386719	206.0200653076172	91.73097229003906	0.8954049944877625	15072.0	0.615436315536499	Cammeo
3	14634.0	501.12200927734375	214.10678100585938	87.7682876586914	0.9121180772781372	14954.0	0.6932588219642639	Cammeo
4	13176.0	458.3429870605469	193.33738708496094	87.44839477539062	0.8918609023094177	13368.0	0.640669047832489	Cammeo
5	14688.0	507.1669921875	211.74337768554688	89.31245422363281	0.9066908955574036	15262.0	0.6460239291919101	Cammeo
6	13479.0	477.0159912109375	200.0530548095703	86.6502914428711	0.9013283252716064	13786.0	0.6578972935676575	Cammeo
7	15757.0	509.281005859375	207.2966766357422	98.33613586425781	0.8803234696388245	16150.0	0.5897080898284912	Cammeo
8	16405.0	526.5700073242188	221.61251811054688	95.43670654296875	0.9025205969810486	16837.0	0.6588882803916931	Cammeo
9	14524.0	483.6409912109375	196.65081787109375	95.0506820678711	0.8754285573959351	14932.0	0.6496513485908508	Cammeo
10	13485.0	471.57000732421875	198.27264404296875	87.72728729248047	0.8967893123626709	13734.0	0.5723198652267456	Cammeo
11	14930.0	498.92498779296875	212.24581909179688	90.0174789428711	0.9056064486503601	15248.0	0.6243727207183838	Cammeo
12	14626.0	496.58599853515625	204.5341339111328	92.97486877441406	0.8907115459442139	15070.0	0.57021445025593445	Cammeo
13	15926.0	522.739990234375	225.73605346679688	91.05709075927734	0.9150331616401672	16240.0	0.7797688841819763	Cammeo
14	14076.0	479.677001953125	199.48915100097656	90.7099838256836	0.8906388878822327	14434.0	0.7812187671661377	Cammeo
15	13500.0	476.9150085449219	202.5466766357422	85.40547180175781	0.9067548513412476	13800.0	0.7177033424377441	Cammeo
16	14349.0	496.9460144042969	213.5440216064453	86.16077423095703	0.9149883985519409	14678.0	0.6668370962142944	Cammeo
17	15209.0	496.56500244140625	214.05007934570312	91.02632141113281	0.9050725698471069	15395.0	0.5693695545196533	Cammeo
18	15238.0	496.8710021972656	208.5317840576172	93.82839965820312	0.8930549025355583	15487.0	0.7323144674301147	Cammeo
19	13509.0	480.46600341796875	207.1371612548828	83.9401626586914	0.9142105579376221	13732.0	0.595634937828377	Cammeo
20	13699.0	480.72900390625	197.97091674804688	89.9490737915039	0.8908207416534424	14178.0	0.6720467209815979	Cammeo
21	13921.0	481.9930114746094	203.444869951172	88.12581634521484	0.9013131856918335	14210.0	0.5613306164741516	Cammeo
22	14405.0	488.23699951171875	204.4301300048828	90.62645721435547	0.896367073059082	14742.0	0.763787794761658	Cammeo
23	13377.0	472.96099853515625	199.94078063964844	86.68286895751953	0.901133008506775	13685.0	0.7948306798934937	Cammeo
24	15043.0	498.29901123046875	206.01170349121094	94.76668548583984	0.8879156708717346	15414.0	0.5868836045265198	Cammeo

Fig. 1 Data set

El data set está conformado por 8 atributos (7 atributos descriptivos y uno etiqueta) y un total de 3810 instancias. Los atributos descriptivos son datos numéricos y la etiqueta es nominal.

Análisis de la distribución de valores de los atributos

En la figura se muestra en un histograma la distribución del atributo de clase para el data set en cuestión. La clase Cammeo tiene 1630 instancias, mientras la Osmancik tiene 2180. Cabe destacar que esta última clase posee 550 más instancias, que representa el 14,4% del total de instancias.




Fig. 2 Distribución de valores del atributo clase




Fig. 3 Gráfico Minor_Axis_Length vs. Major_Axis_Length

En este gráfico, por ejemplo, se presenta la relación entre los atributos *Minor_Axis_Length* en las “x” y *Major_Axis_Length* en las “y”. Se puede distinguir que la clase Cameo tiene mayores valores del atributo *Major_Axis_Length*, lo que se traduce en un grano más largo; mientras la clase Osmancik ostenta menores valores de este atributo.




Fig. 4 Gráfico Perimeter vs. Area

Este otro gráfico representa la relación entre el atributo *Perimeter* en las “x” y el *Area* en las “y”. La clase Osmancik exhibe de forma general menores valores en ambos atributos.

Detección y tratamiento de valores perdidos

El data set no tiene valores perdidos. Así consta en la página web de procedencia. También se constató con una inspección visual al data set mediante WEKA. Además, esta herramienta lo señala como se ve en la figura 5.

Detección y tratamiento de ruido en los datos

Con el fin de detectar datos anómalos, se aplicó el algoritmo no supervisado *InterquartileRange* con los parámetros por defecto, para todos los atributos, exceptuando el atributo clase. Como

resultado se detectaron a penas dos instancias anómalas, que fueron eliminadas aplicando el algoritmo no supervisado *RemoveWithValues* especificando el índice del atributo *Outlier* que sea creó al aplicar el algoritmo anterior, así como el índice del valor de este atributo a eliminar.




Fig. 5 Missing values 0 (0%)




Fig. 6 Eliminación de los outliers.

Remuestreo

Entre las clases hay una diferencia de 550 instancias. Se aplicó el algoritmo supervisado SMOTE de remuestreo para balancear el número de instancias de las clases, puesto que los algoritmos de clasificación suelen clasificar mejor las clases con más instancias. Entonces se aplica este algoritmo para evitar ese problema.




Fig. 7 Selección de parámetros del algoritmo SMOTE

La diferencia de instancias entre ambas clases es 550, aproximadamente 30% de la clase menor (Cammeo), por lo que este es el valor que se ha puesto en el porcentaje de instancias de SMOTE que se van a crear, como se ve en la figura 7.

Ahora resulta un data set con 4297 instancias en total, en la clase Cammeo 2119 y en la Osmancik 2178, ya más balanceadas, como se muestra en la figura 8.




Fig. 8 Resultado de aplicar SMOTE.

Aplicación de algoritmos de aprendizaje supervisado

Aplicación del algoritmo SMO de WEKA. Algoritmo de Máquinas de Vectores de Soporte (SVM)

Este es un clasificador lineal definido para clasificaciones binarias y atributos numéricos, como es el caso de este data set. Se aplicó con los parámetros por defecto. Fig. 9.




Fig. 9 Configuración del algoritmo SMO

=== Summary ===		
Correctly Classified Instances	3988	92.8089 %
Incorrectly Classified Instances	309	7.1911 %
Kappa statistic	0.8562	
Mean absolute error	0.0719	
Root mean squared error	0.2682	
Relative absolute error	14.3848 %	
Root relative squared error	53.6374 %	
Total Number of Instances	4297	

Fig. 10 Principales métricas

El algoritmo tiene una **exactitud** (instancias correctamente clasificadas) de 92.8%, un valor bastante alto. Fig. 10.

El valor de **Kappa statistic**, es bastante alto también (0.8562). Determina la probabilidad de que una instancia se clasifique exactamente igual en dos ejecuciones paralelas del algoritmo. Fig. 10.

El **error medio absoluto** es pequeño (0.0719). Fig. 10.

=== Detailed Accuracy By Class ===									
	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0,933	0,076	0,923	0,933	0,927	0,856	0,928	0,894	Cammeo
	0,924	0,067	0,934	0,924	0,929	0,856	0,928	0,901	Osmancik
Weighted Avg.	0,928	0,072	0,928	0,928	0,928	0,856	0,928	0,897	

Fig. 11 Precisión detallada por clase

En la figura 11 se aprecian la **sensibilidad o recall** (posibilidad de que un ejemplo positivo sea clasificado como positivo), la **tasa de verdaderos positivos** y la **precisión** (probabilidad de que un ejemplo sea positivo si el clasificador lo clasifica como positivo) exhiben valores muy altos, todos superiores al 92%.




Fig. 12 Curva ROC para SMO.

En la figura 12 se muestra la curva ROC. El **área bajo la curva ROC** es de 0.928 para cada clase, por lo que se puede considerar un buen clasificador.

=== Confusion Matrix ===				
	a	b	<-- classified as	
1976	143		a = Cammeo	
166	2012		b = Osmancik	

Fig. 13 Matriz de confusión para el algoritmo SMO.

En la figura 13 aparece la matriz de confusión asociada a la aplicación del algoritmo SMO. Se obtuvieron un total de 3988 instancias clasificadas correctamente (1976 verdaderos positivos y 2012 verdaderos negativos). Por otra parte, 309 instancias resultaron mal clasificadas (166 falsos negativos y 143 falsos positivos).

Aplicación de una red bayesiana

Se ha aplicado una red bayesiana como método de clasificación. En la figura 14 se puede ver que se ha utilizado la configuración por defecto, que incluye al algoritmo de búsqueda K2.




Fig. 14 Configuración de la red bayesiana.

=== Summary ===		
Correctly Classified Instances	3937	91.6221 %
Incorrectly Classified Instances	360	8.3779 %
Kappa statistic	0.8324	
Mean absolute error	0.0875	
Root mean squared error	0.2706	
Relative absolute error	17.4947 %	
Root relative squared error	54.1261 %	
Total Number of Instances	4297	

Fig. 15 Resumen de algunas métricas.

El algoritmo tiene una **exactitud** (instancias correctamente clasificadas) de 91.6%, un valor bastante alto. Fig. 15.

El valor de **Kappa statistic**, es bastante alto también (0.8324). Determina la probabilidad de que una instancia se clasifique exactamente igual en dos ejecuciones paralelas del algoritmo. Fig. 15.

El **error medio absoluto** es pequeño (0.0875). Fig. 15.

=== Detailed Accuracy By Class ===									
	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0,902	0,070	0,926	0,902	0,914	0,833	0,974	0,975	Cammeo
	0,930	0,098	0,907	0,930	0,918	0,833	0,974	0,974	Osmancik
Weighted Avg.	0,916	0,084	0,916	0,916	0,916	0,833	0,974	0,974	

Fig. 16 Precisión detallada por clase.

En la figura 16 se aprecian la **sensibilidad o recall** (posibilidad de que un ejemplo positivo sea clasificado como positivo), la **tasa de verdaderos positivos** y la **precisión** (probabilidad de que un ejemplo sea positivo si el clasificador lo clasifica como positivo) exhiben valores muy altos, todos superiores al 90%. Sin embargo, en todos los casos son menores a los obtenidos con SMO.




Fig. 17 Curva ROC para la red bayesiana.

La curva ROC se muestra en la figura 17. El **área bajo la curva ROC** es de 0.974 para cada clase, por lo que se puede considerar un buen clasificador.

```

=== Confusion Matrix ===
      a    b  <-- classified as
1912  207 |    a = Cammeo
 153 2025 |    b = Osmancik

```

Fig. 18 Matriz de confusión asociada a la red bayesiana.

En la figura 16 aparece la matriz de confusión asociada a la aplicación de la red bayesiana. Se obtuvieron un total de 3937 instancias clasificadas correctamente (1912 verdaderos positivos y 2025 verdaderos negativos). Por otra parte, 360 instancias resultaron mal clasificadas (153 falsos negativos y 207 falsos positivos).

De forma general, se puede decir que los resultados de aplicar el algoritmo SOM son mejores que los de la red bayesiana, pues exhibe mejores métricas, incluyendo mayor número de instancias bien clasificadas.

Aplicación de algoritmos no supervisados

Clustering

Como método de clustering se ha aplicado el de **Agrupamiento Jerárquico** con los parámetros que vienen por defecto, que incluye la distancia euclídea. Fig. 19.




Fig. 19 Configuración del algoritmo de clustering jerárquico.



Fig. 20 Visualización de los dos clústeres obtenidos

En la figura 20 se observan los clústeres obtenidos y en la figura 21 se puede apreciar la relación de los clústeres con las clases, que coinciden.




Fig. 21 Relación de los clústeres con las clases.

```

=== Model and evaluation on training set ===

Clustered Instances

0      2119 ( 49%)
1      2178 ( 51%)

```

Fig. 22 Resultado del clustering jerárquico.

En la figura 22 muestra el resultado del clustering jerárquico y cabe destacar nuevamente la coincidencia de los clústeres obtenidos con las clases.

Reglas de asociación

Primeramente, antes de aplicar algún método de asociación se deben discretizar los atributos numéricos. En la figura 23 se presenta la configuración del algoritmo no supervisado de discretización, para que no tenga en cuenta el atributo clase. Se ha dejado la creación de diez intervalos y que se aplique a todos los atributo a la vez.




Fig. 23 Configuración del algoritmo Discretize

En la figura 24 se ve el resultado de aplicar el algoritmo Discretize. Aparece un histograma con la distribución de valores para el atributo *Area* en los diez intervalos y en colores diferenciada la proporción de instancias de cada clase.




Fig. 24 Resultado de aplicar el algoritmo Discretize.

A continuación, se ha aplicado el algoritmo *Apriori* de reglas de asociación. Se han dejado los valores por defecto en la configuración: 1% de umbral de soporte, 90% de umbral de confianza y 10 reglas (mostrará sólo las 10 mejores reglas). En la figura 25 aparecen las 10 mejores reglas encontradas junto a algunas medidas de calidad (confianza, *lift*, Leverage y convicción).

```
Best rules found:

1. Major_Axis_Length='(164.013672-173.388275)' 680 ==> Class=Osmancik 678 <conf:(1)> lift:(1.97) lev:(0.08) [333] conv:(111.78)
2. Convex_Area='(14665.4-15773.8)' 674 ==> Class=Cammeo 661 <conf:(0.98)> lift:(1.99) lev:(0.08) [328] conv:(24.4)
3. Major_Axis_Length='(201.512085-210.886688)' 764 ==> Class=Cammeo 749 <conf:(0.98)> lift:(1.99) lev:(0.09) [372] conv:(24.2)
4. Perimeter='(415.903799-434.838397)' 841 ==> Class=Osmancik 818 <conf:(0.97)> lift:(1.92) lev:(0.09) [391] conv:(17.28)
5. Major_Axis_Length='(173.388275-182.762878)' 861 ==> Class=Osmancik 827 <conf:(0.96)> lift:(1.9) lev:(0.09) [390] conv:(12.13)
6. Perimeter='(472.707593-491.642191)' 707 ==> Class=Cammeo 676 <conf:(0.96)> lift:(1.94) lev:(0.08) [327] conv:(11.2)
7. Convex_Area='(11340.2-12448.6)' 978 ==> Area='(11157-12265)' 932 <conf:(0.95)> lift:(4.04) lev:(0.16) [701] conv:(15.9)
8. Convex_Area='(11340.2-12448.6)' Class=Osmancik 867 ==> Area='(11157-12265)' 823 <conf:(0.95)> lift:(4.03) lev:(0.14) [618] conv:(14.72)
9. Area='(11157-12265)' Class=Osmancik 871 ==> Convex_Area='(11340.2-12448.6)' 823 <conf:(0.94)> lift:(4.15) lev:(0.15) [624] conv:(13.73)
10. Area='(11157-12265)' 1013 ==> Convex_Area='(11340.2-12448.6)' 932 <conf:(0.92)> lift:(4.04) lev:(0.16) [701] conv:(9.54)
```

Fig. 25 Diez mejores reglas de asociación encontradas con el algoritmo *Apriori*.

En cuanto a la **confianza**, se puede decir que sus valores son bastante altos, siendo la unidad para la primera regla y superior a 0.92 para las otras nueve.

El valor del ***lift*** es en todos los casos superior a 1, lo que indica que la regla aparece más veces de lo esperado en condiciones de independencia de antecedente y consecuente, porque existe cierta dependencia entre los atributos, lo que le da fuerza a la regla. Por tanto, mientras más grande sea que uno, mejor.

Los valores de **Leverage**, por otra parte, no son muy buenos. El valor más alto que alcanza es 0.16, bastante cercano a cero, por lo que no es muy bueno. Este es una medida entre la probabilidad e la regla y la probabilidad conjunta del antecedente y el consecuente si fueran independientes. La probabilidad de que ocurra la regla es ligeramente superior a la probabilidad de que ocurran el antecedente y el consecuente conjuntamente por azar.

Los valores de la **convicción** son buenos por ser superiores a la unidad.

Conclusiones

Las técnicas de minería de datos aplicadas al conjunto de datos de clasificación de especies de arroz cultivadas en Turquía proporcionaron valiosas percepciones y resultados. Se utilizaron diversas técnicas de preprocesamiento de datos en WEKA, incluyendo la detección y eliminación de outliers, remuestreo y discretización de atributos numéricos.

En la fase de modelado supervisado, se implementaron una red bayesiana y el algoritmo SMO para la clasificación. Los resultados indicaron que SMO superó a la red bayesiana en términos de métricas de rendimiento, subrayando su eficacia en este contexto específico.

Adicionalmente, se exploraron enfoques no supervisados, como la clusterización mediante agrupamiento jerárquico. Este método demostró su capacidad para identificar clústers que coincidían con las clases predefinidas, proporcionando una validación adicional de la estructura inherente en los datos.

La aplicación del método Apriori, basado en reglas de asociación, tras la discretización de atributos numéricos, permitió descubrir patrones interesantes en los datos.

En última instancia, el estudio destacó la importancia y utilidad de la minería de datos en la clasificación de especies de arroz. La combinación de técnicas de preprocesamiento y algoritmos de clasificación demostró ser efectiva para extraer conocimientos significativos de conjuntos de datos complejos. Estos hallazgos subrayan el potencial de la minería de datos como una herramienta valiosa en la investigación agrícola y la toma de decisiones relacionada con las variedades de cultivos.