

TEMA 1

INTRODUCCIÓN A LA MINERÍA DE DATOS


María N. Moreno García

Departamento de Informática y Automática

Grupo de Investigación en Minería de Datos

mida.usal.es

Asignatura: **Minería de Datos**

Three diagonal lines (two blue, one red) and three horizontal lines (two blue, one red) intersecting at the bottom of the slide.



Índice

1. Introducción
2. Clasificación de las técnicas
 - Métodos supervisados
 - Métodos no supervisados
3. El proceso de minería de datos
 - Determinación de objetivos
 - Preparación de datos
 - Transformación de datos
 - Minería de datos
 - Análisis de resultados
 - Asimilación del conocimiento

1. INTRODUCCIÓN

Introducción

Minería de datos es el proceso de obtener información **previamente desconocida, válida y transformable** a partir de grandes volúmenes de datos para utilizarla posteriormente en la toma de decisiones cruciales



Herramientas de minería de datos y visualización

Componentes de un entorno de minería de datos

Introducción

- Diferencias entre el enfoque de minería de datos y el análisis tradicional de datos
 - Se descubre información sin una hipótesis formulada previamente
 - Los algoritmos de minería de datos generalmente pueden procesar muchos tipos de datos
- La minería de datos es un componente importante de la denominada *inteligencia de negocio*

Inteligencia de negocio


Conjunto de procesos, técnicas y herramientas de ayuda a las decisiones de negocio basadas en la tecnología de la información

Introducción




Inteligencia de negocio

2. CLASIFICACIÓN DE LAS TÉCNICAS




Clasificación de las técnicas



*Aprendizaje **supervisado** o de **predicción***

- Predicen valores de atributos basándose en valores de otros atributos
- Requieren una fase de entrenamiento



*Aprendizaje **no supervisado** o **descubrimiento de conocimiento***

- Descubren patrones y segmentos de datos

Clasificación de las técnicas

Métodos supervisados

*Algoritmos **supervisados** o de **predicción***

Predicen el valor de un atributo llamado **etiqueta** de un conjunto de datos, conocidos otros atributos llamados **atributos descriptivos**



Clasificación de las técnicas

Métodos supervisados

- Se analiza un conjunto de datos existente para determinar características esenciales sobre los datos
 - Los datos deben incluir observaciones válidas y completas para que el modelo pueda aprender a hacer predicciones fiables
 - El algoritmo debe encontrar la respuesta correcta de algunos casos ya resueltos antes de aplicarse a nuevas observaciones
- Esta forma de trabajar se conoce como ***aprendizaje supervisado***




Modelado predictivo

Clasificación de las técnicas

Métodos supervisados

- Los modelos supervisados se desarrollan en dos fases
 - **Entrenamiento**: construcción de un modelo usando datos históricos (con etiqueta conocida). El modelo inducido es una relación entre la etiqueta y los atributos descriptivos
 - **Prueba**: prueba del modelo con datos diferentes a los utilizados para construir el modelo



El modelo inducido, una vez probado, se puede usar posteriormente para predecir el valor de la etiqueta de registros no etiquetados

Clasificación de las técnicas

Métodos supervisados

- Hay dos especializaciones del modelado predictivo:
 - **Clasificación**
 - Se usa un modelado predictivo para establecer una clase para cada registro del conjunto de datos
 - El atributo etiqueta representa la clase
 - La clase debe ser una de un conjunto finito de posibles clases
 - Técnicas de clasificación: **árboles de decisión, redes bayesianas, máquinas de vectores de soporte, inducción neuronal...**
 - **Predicción de valores**
 - El modelo de predicción se utiliza para estimar un valor numérico continuo que se asocia con un registro del conjunto de datos
 - Las principales técnicas de este tipo son **regresión y series temporales**

Clasificación de las técnicas

Métodos supervisados

Clasificación (I)

- Se crea automáticamente un modelo de clasificación a partir de un conjunto de entrenamiento y de un inductor
 - **Conjunto de entrenamiento**: registros de datos cuya etiqueta se conoce
 - **Inductor**: algoritmo que construye automáticamente un clasificador a partir de un conjunto de entrenamiento




Construcción de un clasificador a partir de registros clasificados

Clasificación de las técnicas

Métodos supervisados

Clasificación (II)

- El modelo inducido (**clasificador**) consiste en una serie de patrones que son útiles para distinguir las clases
- Una vez que se ha inducido el modelo se puede utilizar para predecir automáticamente la clase de otros registros no clasificados (de etiqueta desconocida)



Clasificación de las técnicas

Métodos supervisados

Clasificación (III)

- **Ejemplo**

- **Clases:**

- Permanece
 - Abandona

- **Atributos descriptivos:**

- Antigüedad
 - Servicios

- **Inductor:** algoritmo de árboles de decisión

- **Modelo inducido:** Reglas de decisión

- Si *antigüedad* > 2,5 años entonces *permanece*
 - Si *antigüedad* ≤ 2,5 años y *servicios* ≥ 3 entonces *permanece*
 - Si *antigüedad* ≤ 2,5 años y *servicios* < 3 entonces *abandona*





Modelado predictivo

Clasificación de las técnicas

Métodos supervisados

Predicción de valores

- Las técnicas tradicionales de predicción de valores son la **regresión lineal y no lineal**
- Una técnica de regresión, más robusta, es la conocida como **función base radial**
- En problemas con características dependientes del tiempo se puede hacer uso de las **series temporales** para la predicción




Clasificación de las técnicas

Métodos no supervisados

Algoritmos **no supervisados** o de descubrimiento del conocimiento

Detectan patrones de diferentes tipos en los datos

- **Detección de desviaciones**
Detección de cambios respecto a la norma
- **Segmentación o agrupación (clustering)**
División de los datos en grupos basándose en una o varias características
- **Análisis de asociación**
Sirven para encontrar patrones de comportamiento o reglas de implicación entre atributos
- **Resumen**
Descripciones compactas de datos



- Clasificación

3D visualization of the relationship between LRS (Left Reciprocal Score) and RRS (Right Reciprocal Score) for various movies. The plot shows vertical bars representing the LRS for each movie, with the RRS value indicated on the horizontal axis. The data points are labeled with movie titles and their corresponding LRS values.


Movie Title	LRS	RRS
GENRE_Unknown_binWestern_2.62708e+02	2.62708e+02	OCCUPATION=writer
timeStamp_binWestern_2.09800e+05	2.09800e+05	OCCUPATION=educator
GENRE_Unknown_binAction_2.08000e+05	2.08000e+05	OCCUPATION=administ
timeStamp_binFilm-Noir_2.59703e+02	2.59703e+02	
timeStamp_binFantasy_2.58778e+03	2.58778e+03	
timeStamp_binFilm-Noir_2.60753e+03	2.60753e+03	

Clasificación de las técnicas

Métodos no supervisados

Segmentación o agrupamiento (*clustering*)

- Partición del conjunto de datos en segmentos de registros similares
- Se realiza para descubrir subpoblaciones homogéneas y determinar mejor su perfil



Clasificación de las técnicas

Métodos no supervisados

Análisis de asociación

- Persigue el establecimiento de relaciones entre registros individuales o grupos de registros de un conjunto de datos
 - **Reglas de asociación:** en una transacción comercial revela afinidades ocultas entre los productos

Si **X** entonces **Y**

Si un cliente *compra una camisa* **entonces** también *compra una corbata*

- **Patrones secuenciales:** revelan información sobre la secuencia en que los consumidores adquieren bienes



Cientes	Patrones secuenciales con soporte > 40%
L. López, A. Ramos	(cerveza) (brandy)
J. Martín, A. Ramos	(cerveza) (vino, sidra)

Clasificación de las técnicas


Métodos no supervisados

Detección de desviaciones


- Permiten detectar fenómenos que ocurren para un subconjunto relativamente pequeño de datos
- Clasificación
 - Visualización
 - Estadísticas



3. EL PROCESO DE MINERÍA DE DATOS



El proceso de minería de datos



El proceso de minería de datos

Determinación de objetivos

- La finalidad de esta etapa es asegurar
 - Que hay aspectos críticos científicos o de negocio que se pueden resolver
 - Que se disponen de los medios necesarios
- Pasos

Desarrollar una definición cuidadosa de las necesidades

Estimar el tiempo en el que se espera obtener resultados

Realizar un primer análisis del coste-beneficio para determinar si los beneficios potenciales compensarán el esfuerzo realizado

El proceso de minería de datos

Preparación de datos

Selección

El objetivo de esta etapa es identificar las fuentes de datos disponibles y extraer los datos necesarios para un análisis preliminar

- Las variables seleccionadas llevan asociada información semántica (metadatos)
- Los metadatos deben incluir:
 - Sólidas definiciones de los datos
 - Descripciones de los tipos de datos
 - Posibles valores
 - Formato
 - Procedencia de los datos ...

El proceso de minería de datos

Preparación de datos

Selección

- **Tipos de variables**
 - **Clasificadoras o categóricas:** toman valores finitos y difieren en el tipo
 - **Nominales:** nombran el tipo de objeto sin establecer un orden
 - **Ordinales:** sus posibles valores tienen un orden
 - **Cuantitativas:** hay una diferencia medible entre los posibles valores
 - **Continuas:** sus valores son números reales
 - **Discretas:** sus valores son enteros
- Las variables seleccionadas para la minería de datos se llaman **variables activas**
- En esta etapa hay que determinar la estabilidad de las variables
- Hay que tener en cuenta posibles algoritmos de minería para tratar esos datos

El proceso de minería de datos

Preparación de datos

Preprocesamiento


El objetivo de esta etapa es asegurar la calidad de los datos seleccionados

- Se utiliza una combinación de métodos estadísticos y técnicas de visualización de los datos
- Para variables clasificatorias se utiliza:
 - Distribuciones de frecuencia
 - Histogramas
 - Diagramas de sectores
- Para variables cuantitativas se combinan medidas estadísticas:
 - Valores máximo y mínimo
 - Media, mediana
 - Tendencia ...

El proceso de minería de datos

Preparación de datos

Preprocesamiento



Histograma



Diagrama de sectores

El proceso de minería de datos

Preparación de datos

Preprocesamiento

Otros gráficos muy utilizados son

- **Gráficos de cajas** (boxplots): utilizados para representar valores estadísticos
- **Gráficos de dispersión** (scatterplots): gráficos que representan la relación entre dos o más variables continuas






Gráfico de cajas

El proceso de minería de datos

Preparación de datos

Preprocesamiento



Gráficos de dispersión

El proceso de minería de datos

Preparación de datos

Preprocesamiento

- Durante el preprocesamiento nos podemos encontrar:
 - ***Datos con ruido***
 - Una o más variables tienen valores que están significativamente fuera de la línea que se espera para esas variables
 - ***Valores perdidos***
 - Valores que no se encuentran en los datos seleccionados o valores no válidos que se han eliminado durante la detección de ruido.
 - Los valores perdidos pueden aparecer por:
 - Errores humanos
 - Selección de datos de fuentes heterogéneas

Para solucionar el problema se puede eliminar toda la observación que tiene valores perdidos, eliminar la variable o sustituir el valor perdido por el más probable ...

El proceso de minería de datos

Preparación de datos

Preprocesamiento

- En problemas de clasificación
 - **Desequilibrio de datos**
 - El número de ejemplos o instancias de una o varias clases es significativamente mayor al del resto de las clases
 - El modelo inducido está sesgado hacia la clase o clases mayoritarias
 - Se trata mediante técnicas de remuestreo
 - Técnicas de remuestreo
 - RUS (Random Under Sampling): submuestreo aleatorio
 - ROS (Random Over Sampling): sobremuestreo aleatorio
 - SMOTE (Synthetic Minority Over-Sampling Technique)
 - Tomek Link (T-Link)
 - OSS (One Sided Selection)


El proceso de minería de datos

Preparación de datos


Preprocesamiento

- **RUS (Random Under Sampling)**
 - Eliminación de instancias de la clase mayoritaria de forma aleatoria
- **ROS (Random Over Sampling)**
 - Replicación de instancias de la clase minoritaria de forma aleatoria

RUS (Random Under Sampling)



ROS (Random Over Sampling)




El proceso de minería de datos

Preparación de datos

Preprocesamiento

- **SMOTE**

- Técnica utilizada para generar nuevos ejemplos de la clase minoritaria interpolando los ya existentes



El proceso de minería de datos

Transformación de datos

Durante la transformación de datos, los datos preprocesados se transforman para producir un modelo de datos analítico

- Después de construir el modelo, los datos se refinan para ajustarlos a los requisitos de entrada del algoritmo de minería que se va a usar
 - Conversión de formato
 - Cálculo de variables derivadas
 - Reducción de datos
 - Discretización
 - Técnica uno-de-N

El proceso de minería de datos

Transformación de datos

Reducción de datos

- Las técnicas de reducción de datos se aplican para obtener una representación reducida del conjunto de datos manteniendo la integridad
- El objetivo es aumentar la eficiencia produciendo resultados analíticos similares a los obtenidos con el conjunto original
- Existen diferentes estrategias
 - Reducción de la dimensionalidad
 - Reducción del número
 - Compresión de datos

El proceso de minería de datos

Transformación de datos

Reducción de la dimensionalidad

Análisis de los componentes principales

Transformaciones de wavelet

Reducción del número

Métodos paramétricos
Regresión

Métodos no paramétricos
Histogramas,
clustering, sampling

Compresión de datos

Sin pérdida
(*lossless*)

Con pérdida
(*lossy*)

El proceso de minería de datos

Transformación de datos


- **Análisis de los componentes principales**

- Conocido por las siglas PCA (*Principal Component Analysis*) o como el método Karhunen-Loeve (K-L)
- Consiste en transformar los atributos o variables originales $x_1, x_2, \dots, x_m$ en otro conjunto de atributos $f_1, f_2, \dots, f_p$ donde $p < m$
- El procedimiento consiste en proyectar el conjunto de datos original a un espacio de menor dimensionalidad
- PCA busca los vectores ortonormales (ejes) que permitan la mejor representación de los datos (conservan la máxima varianza)
- Los vectores ortonormales son los **componentes principales**
- Es necesario normalizar los datos antes de realizar el análisis

El proceso de minería de datos

Transformación de datos

- **Análisis de los componentes principales**



El proceso de minería de datos

Transformación de datos

- **Análisis de los componentes principales**

- Los componentes principales se pueden obtener con técnicas de factorización de matrices como SVD (*Singular Value Decomposition*)
- Los nuevos atributos (vector f) se obtienen a partir de los anteriores (vector x)

$$f = A^T x$$


$$f_j = a_{j1}x_1 + a_{j2}x_2 + \dots + a_{jm}x_m$$

- Es necesario encontrar los coeficientes a_{ji}
- Los nuevos atributos
 - Se generan de forma que sean independientes entre sí
 - Están colocados en orden de mayor a menor relevancia
 - Los primeros deben tener mayor varianza que los que están por detrás

El proceso de minería de datos

Transformación de datos

- **Análisis de los componentes principales**



El proceso de minería de datos

Transformación de datos




- **Transformaciones de wavelet**

- DWT (*Discrete Wavelet Transform*) es una técnica de procesamiento de la señal lineal que transforma un vector X en otro vector numérico X' de coeficientes *wavelet* con la misma dimensión L
- Cuando se aplica a la reducción de la dimensionalidad el vector X' se puede truncar reteniendo sólo los coeficientes con un valor mayor de un determinado umbral
- Utiliza un algoritmo jerárquico de pirámide que reduce a la mitad los datos en cada iteración
- Cada transformación implica dos funciones
 - **Suavizado de datos:** suma o media ponderada
 - **Detalle de los datos:** diferencia ponderada
- Las funciones se aplican a pares de elementos de datos (x_{2i}, x_{2i+1})
- La salida son dos conjuntos de datos de longitud $L/2$
- Las dos funciones se aplican recursivamente a los conjuntos de datos de la iteración anterior hasta alcanzar una longitud de 2 en los conjuntos de salida
- Los valores seleccionados de los conjuntos de datos obtenidos en las iteraciones precedentes se denominan **coeficientes wavelet** de los datos transformados

El proceso de minería de datos

Transformación de datos

- **Transformaciones de *wavelet***



El proceso de minería de datos

Minería de datos

El objetivo es aplicar los algoritmos de minería de datos seleccionados a los datos preprocesados y transformados

- Para aplicar los algoritmos se necesita disponer
 - Datos preprocesados en las etapas anteriores
 - Los correspondientes metadatos
 - El conocimiento subyacente en el contenido de los datos
- Esta etapa está estrechamente ligada con la siguiente (análisis de resultados) y ambas se llevan a cabo de forma iterativa.
- El proceso de minería varía de unas aplicaciones a otras
 - Por ejemplo para una segmentación de un conjunto de datos puede ser suficiente la ejecución de dos algoritmos
 - El desarrollo de un modelo predictivo será un proceso cíclico en el que los modelos se entrenan repetidamente

El proceso de minería de datos

Análisis de resultados

El objetivo es conocer si los resultados obtenidos son interesantes y válidos

- El análisis de resultados no puede separarse de la etapa anterior
- Si los resultados no son adecuados el proceso de minería-análisis de resultados se repite
- En la segmentación del conjunto de datos, cada segmento debe ser lo suficientemente homogéneo para permitir su interpretación
- En los modelos predictivos hay que chequear su exactitud
 - Técnicas de estimación de errores
 - Curvas de esfuerzo y de aprendizaje
 - Matrices de confusión
 - Matrices de pérdida
 - Análisis sensitivo de la entrada ...

El proceso de minería de datos

Asimilación del conocimiento

El objetivo es poner en acción los compromisos fijados en la primera etapa de acuerdo a la información obtenida a lo largo de todo el proceso

- Esta tarea tiene dos aspectos importantes
 - Presentar los hallazgos de forma convincente y orientada al área de negocio (o a cualquier otro dominio que se aplique)
 - Formular maneras en las que la nueva información pueda explotarse
- Algunas de las acciones a realizar pueden ser
 - Integración de nuevos modelos predictivos y reglas de asociación en las aplicaciones existentes
 - Los sistemas de bases de datos pueden mejorarse con nuevas estructuras de datos
 - Mejora de la calidad de los datos

Bibliografía

- Cabena, P. , Hadjinian, P., Stadler, R., Verhees, J., Zanasi, A. *Discovering Data Mining. From Concept to Implementation*, Prentice Hall, 1998.
- Géron, A., *Hands-On Machine Learning with Scikit-Learn, Keras and Tensorflow*, O'Reilly, 2022.
- Han, J. , Kamber, M., Pei, J. *Data Mining, Concepts and Techniques*, Morgan Kaufmann, 2011 .
- Hernández, J. , Ramírez, M.J., Ferri, C. *Introducción a la Minería de Datos*, Pearson Education, 2004 .
- Mineset user's guide, v. 007-3214-004, 5/98, Silicon Graphics, 1998.
- Weiss, S.M., Indurkha, N. , *Predictive Data Mining. A Practical Guide*, Morgan Kaufmann Publishers, San Francisco, 1998.
- Zaki, M. J., Meira, W. Jr., *Data Mining and Analysis: Fundamental Concepts and Algorithms*, Cambridge University Press, 2020.