


TEMA 3

MÉTODOS NO SUPERVISADOS

María N. Moreno García
Departamento de Informática y Automática
Grupo de Investigación en Minería de Datos
mida.usal.es

Asignatura: **Minería de Datos**



Índice


1. Introducción
2. Segmentación
3. Análisis de asociación
4. Detección desviaciones

1. INTRODUCCIÓN

Introducción

Los algoritmos **no supervisados** o **de descubrimiento del conocimiento** detectan patrones de diferentes tipos en los datos

- La inducción de los modelos no requiere una fase de entrenamiento
- Los modelos no son predictivos sino descriptivos



Introducción

- Los algoritmos de descubrimiento sirven para explorar las propiedades de los datos
 - Similitudes
 - Resúmenes
 - Tendencias
 - Patrones
 - Asociaciones

Segmentación de la base de datos	Análisis de asociación	Detección de desviaciones
Agrupación (clustering)	Reglas de asociación Descubrimiento de patrones secuenciales	Visualización Estadísticas

Clasificación de los métodos no supervisados

2. SEGMENTACIÓN (*CLUSTERING*)

Segmentación

La segmentación es la partición de la base de datos en segmentos de registros similares

- Dado un gran conjunto multidimensional de datos, los métodos de agrupación identifican los espacios con distinta densidad de población y a partir de ahí descubre patrones de distribución del conjunto de datos
- Cada atributo de los datos constituye una dimensión del espacio multidimensional de registros
- Realizan una medida de la distancia entre parejas de registros
- En función de la distancia los registros de entrada se asignan a una agrupación específica
- Los algoritmos de agrupación demográfica distribuyen los registros de datos en agrupaciones de N elementos con dispersión mínima

$$Dispersión^2 = \frac{\sum_{i=1}^N (distancia)^2}{N}$$

Segmentación

- Medidas de distancia para **atributos categóricos**
 - Distancia basada en el **principio de Condorcet**
 - Cuando un par de registros tiene el mismo valor para el mismo campo se le asigna una puntuación de +1 (puede extenderse a variables continuas preestableciendo una tolerancia en la comparación)
 - Cuando el campo no tiene el mismo valor para ambos registros se le asigna la puntuación de -1
 - La puntuación final se calcula sumando las puntuaciones parciales
 - Distancia de **Hamming**
 - Medida similar a la anterior
 - La distancia es 1 cuando los valores son diferentes y 0 cuando son iguales

Segmentación

- Medidas de distancia para **atributos numéricos (I)**

- Distancia **Euclídea**

- $d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$

- Distancia **Manhattan**


- $d(x, y) = ||x - y|| = \sum_{i=1}^n |x_i - y_i|$

- Distancia **Euclídea estandarizada**

- $d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2 / S_i}$

n: número de atributos

S_i : desviación estándar del atributo i



Segmentación

- Medidas de distancia para **atributos numéricos (II)**

- Distancia **Chebyshev**


- $d(x, y) = \max (|x_i - y_i|)$

- Distancia **del coseno**

Es una medida de similitud

- $d(x, y) = 1 - \cos(x, y)$

- $$\cos(x, y) = \frac{x \cdot y}{\|x\| \|y\|} = \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n x_i^2} \sqrt{\sum_{i=1}^n y_i^2}}$$



Segmentación

- **Algoritmo *k*-medias sencillo**

- Se establece inicialmente un número de agrupaciones n
- Los centroides de las n agrupaciones se inicializan en posiciones al azar del espacio de todos los registros
- Cada uno de los registros restantes se asigna a una agrupación, aquella cuyo centroide esté mas cerca del registro
- Se recalculan los centroides de las nuevas agrupaciones
- Los siguientes pasos se ejecutan **iterativamente** hasta que no se consiga ninguna mejora
 - Si hay registros que están más cercanos al centroide de una agrupación distinta a la que pertenecen se mueven a dicha agrupación
 - Se recalculan los centroides de las nuevas agrupaciones

Segmentación

- **Algoritmo *k-medias iterativo (I)***

- Se establece inicialmente un número mínimo y máximo de agrupaciones
- Con el número mínimo se realiza una ejecución del algoritmo *k-medias sencillo* para obtener las agrupaciones iniciales
- Los siguientes pasos se ejecutan iterativamente hasta que se alcance el número máximo de agrupaciones
 - La agrupación con mayor dispersión se divide en dos partes, creando dos nuevas agrupaciones y se recalculan sus centroides
 - Si hay registros más cercanos al centroide de otra agrupación que al de la suya, se mueven a la agrupación más cercana y se recalculan los centroides de las agrupaciones
 - El último paso se repite hasta que no sea necesario mover ningún registro o hasta que se haya ejecutado el número máximo de veces permitido

Segmentación

- **Algoritmo k-medias iterativo (II)**

- **Punto de selección:** selecciona el grado de dispersión deseado, medido como la proporción entre la dispersión media del número mínimo de agrupaciones y la dispersión media del máximo número de agrupaciones

Se utiliza para determinar las agrupaciones finales:

- Si tiene valor 1, se seleccionará el número máximo de agrupaciones
- Si tiene valor 0 se seleccionará el número mínimo

$$CP = \frac{d_{min} - d}{d_{min} - d_{max}}$$

d_{min} : dispersión media del número mínimo de *clusters*

d_{max} : dispersión media del número máximo de *clusters*

Segmentación


- ***Ponderación de atributos***

- Se puede asignar a cada atributo un peso que determina su influencia en la determinación de la distancia
 - Si tiene valor 0 el atributo no se utiliza para calcular la distancia
 - Si tiene valor n la influencia será la de n copias exactas de la columna correspondiente al atributo

Segmentación

- **Agrupamiento jerárquico (I)**


- Construcción de un árbol denominado **dendograma**
 - Los nodos hoja son los elementos del conjunto de ejemplos
 - El resto de los nodos son subconjuntos de ejemplos



Segmentación


- **Agrupamiento jerárquico (II)**

- Se pueden generar varios agrupamientos dependiendo de lo compacta que se desee la solución o el número de grupos a generar
- Tipos de métodos según la forma de construir el árbol



Aglomerativos

- Se construye desde las hojas hasta la raíz.
- Los ejemplos correspondientes a las hojas se van aglomerando para construir grupos cada vez más numerosos




**Desaglomerativos
o divisivos.**


- Se parte de la raíz, que contiene todos los ejemplos
- Se van haciendo divisiones hasta llegar a las hojas en que cada ejemplo es un grupo

Segmentación

Aglomerativos



Divisivos



Segmentación

- **Agrupamiento jerárquico (IV)**

- **Métodos aglomerativos**

- La diferencia entre los distintos métodos está en la diferente forma de definir la distancia entre un individuo y un grupo que contenga varios individuos, o entre dos grupos de individuos
- Métodos
 - Enlace simple (*single linkage*) o vecino más próximo
 - Enlace completo (*complete linkage*) o vecino más lejano
 - Enlace en la media (*average linkage*) o grupo promedio (*group average*)
 - Método del centroide
 - Ponderado (basado en la media)
 - No ponderado (basado en la mediana)
 - Método de Ward

Segmentación

- **Agrupamiento jerárquico (III)**

Métodos aglomerativos

Distancias de enlace

Enlace simple (single linkage)

Se calcula la distancia entre todos los puntos de dos grupos y se toma como distancia entre grupos la menor

- $\min_{x_i \in S_i, x_j \in S_j} d(x_i, x_j)$

Enlace completo (complete linkage)

Se toma como distancia entre grupos la mayor de las distancias entre los puntos de ambos grupos

- $\max_{x_i \in S_i, x_j \in S_j} d(x_i, x_j)$


Enlace en la media (average linkage)

Se toma como distancia la media de las distancias entre todos los puntos de los dos grupos

- $\frac{1}{|S_i||S_j|} \sum_{x_i \in S_i} \sum_{x_j \in S_j} d(x_i, x_j)$

Segmentación

- **Agrupamiento jerárquico (V)**
 - Enlace simple o vecino más próximo
 - La característica que define a este método es que la distancia entre grupos se define como la del par de individuos que está más cercano
 - En él sólo se consideran pares los formados con un individuo de cada grupo



Segmentación

- **Agrupamiento jerárquico (VI)**

- **Método del vecino más próximo**

- Se construye la matriz de distancias y se van combinando los ejemplos más próximos



D1							
D2	0.3606						
D3	0.5000	0.4243					
D4	0.9220	0.7071	0.4472				
D5	1.3416	1.0440	0.9220	0.5000			
D6	1.8385	1.5524	1.3892	0.9434	0.5099		
D7	1.7263	1.5000	1.2369	0.8062	0.5831	0.4000	
	D1	D2	D3	D4	D5	D6	D7

D1/D2=D8							
D3	0,4243						
D4	0,7071	0,4472					
D5	1,0440	0,9220	0,5000				
D6	1,5524	1,3892	0,9434	0,5099			
D7	1,5000	1,2369	0,8062	0,5831	0,4000		
	D1/D2=D8	D3	D4	D5	D6	D7	

Segmentación

- **Agrupamiento jerárquico (VII)**
 - Método del vecino más próximo

D1/D2=D8						
D3	0,4243					
D4	0,7071	0,4472				
D5	1,0440	0,9220	0,5000			
D6	1,5524	1,3892	0,9434	0,5099		
D7	1,5000	1,2369	0,8062	0,5831	0,4000	
	D1/D2=D8	D3	D4	D5	D6	D7




D8					
D3	0,4243				
D4	0,7071	0,4472			
D5	1,3416	0,9220	0,5000		
D6/D7=D9	1,5000	1,2369	0,8062	0,5099	
	D8	D3	D4	D5	D6/D7=D9

Segmentación

- **Agrupamiento jerárquico (VIII)**

- **Enlace completo o vecino más lejano**

- La distancia entre grupos la definimos ahora como la mayor distancia entre pares de individuos, uno de cada grupo
- Los grupos se forman siguiendo el mismo procedimiento que en el método del vecino más próximo salvo la medida de la distancia




Segmentación

- **Agrupamiento jerárquico (IX)**

- Enlace en la media o grupo promedio

- La distancia entre dos clusters se define como la distancia media entre todos los pares de individuos de cada grupo



$$D_{AB} = \frac{D_{1-4} + D_{1-5} + D_{2-4} + D_{2-5} + D_{3-4} + D_{3-5}}{6}$$


Segmentación

- **Agrupamiento jerárquico (X)**

- **Método del centroide**


- La distancia entre dos clusters se define como la distancia entre los centroides de cada grupo

Centroides ponderados por el tamaño del cluster



$$m_{AB} = \frac{3 m_A + 2 m_B}{5}$$

Centroides no ponderados




$$m_{AB} = \frac{m_A + m_B}{2}$$

Segmentación

- **Agrupamiento jerárquico (XI)**


- Método de Ward de varianza mínima

- Se intenta minimizar la varianza dentro de cada grupo
- En cada paso se combinan un par de *clusters*
- De todas las posibles combinaciones se selecciona la que produce un incremento mínimo del total de la varianza del clúster



Segmentación

- **Agrupamiento jerárquico (XII)**





Fuente: <https://www.digitalvidya.com/blog/the-top-5-clustering-algorithms-data-scientists-should-know/>

Segmentación

- **Métodos basados en densidad (I)**

- Diseñados para encontrar *clusters* de formas arbitrarias o cuando hay ruido en los datos
 - Los métodos de partición y jerárquicos están diseñados para encontrar clusters de formas esféricas
- Identifican regiones densas de puntos en el espacio de datos separadas por regiones poco densas



Segmentación

- **Métodos basados en densidad (II)**

Métodos basados en conectividad

- DBSCAN (*Density Based Spatial Clustering of Applications with Noise*)
- GDBSCAN (*Generalized DBSCAN*)
- OPTICS (*Ordering Points To Identify the Clustering*)
- DBCLASD (*Distribution Based Clustering of Large Spatial Databases*)
- CLIQUE (*Clustering In QEst*)

Métodos basados en funciones de densidad

- DENCLUE (*DENsity-based CLUstEring*)

Segmentación

- **Métodos basados en densidad (III)**

DBSCAN

- Conecta **objetos core** y sus vecindades para formar regiones densas
 - Los *objetos core* son objetos que tienen entornos densos
 - La densidad de un objeto o puede medirse por los puntos cercanos a él
- Cuantificación de la vecindad de un objeto
 - El parámetro $\varepsilon > 0$ se utiliza para especificar el radio de la vecindad
 - La ε - **vecindad** de un objeto o es el espacio dentro de un radio ε centrado en o
 - La densidad de una vecindad puede medirse a partir del número de objetos que contiene
 - **MinPts** es un parámetro que especifica el umbral de densidad para las regiones densas


Segmentación

- **Métodos basados en densidad (IV)**

DBSCAN

- Dado un conjunto D de objetos, se pueden identificar todos los **objetos core** respecto a unos parámetros dados ε y **MinPts**
- ε – **vecindad** de un objeto p respecto otros objetos q

$$N_{\varepsilon}(p): \{q \mid d(p, q) \leq \varepsilon\}$$



MinPts = 4


- p es un objeto **core**
La densidad de p es alta ($|N_{\varepsilon}(p)|=4$)
- q no es un objeto **core**
La densidad de q es baja

Segmentación

- **Métodos basados en densidad (V)**

DBSCAN

- El proceso de *clustering* consiste en usar *objetos core* y sus vecindades para formar regiones densas
- Un objeto q es **directamente densidad-alcanzable** a partir de p , respecto a ϵ y $MinPts$, si
 - p es un objeto **core** y
 - q está en la ϵ -vecindad de p
- La **densidad-alcanzabilidad** no es una propiedad simétrica



MinPts = 4


- q es directamente alcanzable desde p
- p no es alcanzable desde q

Segmentación

- **Métodos basados en densidad (VI)**

DBSCAN

- Un objeto p es directamente densidad-alcanzable a partir de p_2
- p_2 es directamente densidad-alcanzable a partir de p_1
- p_1 es directamente densidad-alcanzable a partir de q
- p es **indirectamente densidad-alcanzable** a partir de q




Segmentación

- **Métodos basados en densidad (VII)**

DBSCAN

- Dos objetos $p_1, p_2 \in D$ están **densidad-conectados** respecto a ε y $MinPts$, si hay un objeto $q \in D$ tal que p_1 y p_2 son densidad-alcanzables desde q
- La **densidad-conectividad** es una propiedad simétrica



Segmentación

- **Métodos basados en densidad (VIII)**

DBSCAN

- Dado un conjunto de datos D y los parámetros ε y **MinPts**
- Un *cluster* $C \subseteq D$ es un subconjunto de elementos que satisfacen los siguientes criterios
 - $p, q \in C : p$ y q están densidad-conectados
 - Si $p \in C$ y q es densidad-alcanzable desde p , entonces $q \in C$
 - No existe ningún objeto $o \in C$ y otro objeto $o' \in (D - C)$ tal que o y o' estén densidad-conectados

Segmentación

- **Métodos basados en densidad (IX)**

DBSCAN

- **Algoritmo**

Entrada: Conjunto de datos D

Parámetros: ε y MinPts

Para cada objeto p en D

Si p es un objeto core y no se ha procesado
 entonces

C = objetos densidad-alcanzables desde p
 marcar los objetos en C como procesados
 sacar C como un cluster

si no marcar p como un outlier


Fin Si

Fin Para

Segmentación

- **Métodos basados en densidad (X)**

DBSCAN



epsilon = 1.00
minPoints = 4

Restart

Pause

Segmentación

- *Métodos basados en densidad (XI)*

DBSCAN



Segmentación

- *Métodos basados en densidad (XII)*

DBSCAN

DBSCAN



k-means



3. ANÁLISIS DE ASOCIACIÓN


Análisis de asociación

Técnica descriptiva que permite encontrar relaciones no explícitas entre atributos categóricos

- Tienen su origen en el campo de aplicación conocido como “análisis de la cesta de la compra”
- Actualmente se aplican en muchos dominios
 - Sistemas de recomendación
 - Comercio electrónico
 - Patrones de navegación web
 - Análisis de textos
 - Minería de medios sociales



Análisis de asociación



Tipos de métodos

- Reglas de asociación
- Descubrimiento de patrones secuenciales

Aplicación en el análisis de la cesta de la compra

Reglas de asociación

Descubren los productos que tienden a venderse juntos

Patrones secuenciales

Revelan información sobre la secuencia en que los consumidores adquieren bienes

Análisis de asociación

Reglas de asociación

- El propósito de las **reglas de asociación** es descubrir artículos que implican la presencia de otros artículos en la misma transacción
- Una transacción es un conjunto de productos comprados en una visita a una tienda

REGLA “si **X** entonces **Y**”

$$X \rightarrow Y$$

X: Antecedente o cuerpo de la regla **Y**: Consecuente o cabeza de la regla

- Medidas de evaluación
 - **Factor de confianza o previsibilidad**
 - Frecuencia de la regla en relación con la frecuencia del antecedente
 - **Factor de soporte o prevalencia**
 - Relación entre el número de veces que tiene lugar la regla y el número total de transacciones

Análisis de asociación

Reglas de asociación

Ejemplo

Cuando **un cliente compra una camisa**, en el **70%** de los casos **compra también una corbata**. Esto sucede en el **13,5%** de todas las compras

- **Cuerpo de la regla:** Camisa
- **Cabeza de la regla:** Corbata
- **Factor de soporte:** 13,5%
- **Factor de confianza:** 70%
- La técnica se basa en el recuento de ocurrencias de todas las posibles combinaciones de artículos

Análisis de asociación

Reglas de asociación

- **Tipos de reglas de asociación**

- **Booleanas:** atributos binarios

Pañales → Cerveza

- **Nominales:** atributos categóricos

Sexo = mujer → Género película = romántica


- **Cuantitativas:** atributos numéricos

Coste = 5 → precisión = 85

- En la mayoría de los casos es necesario discretizar los atributos

Análisis de asociación

Reglas de asociación



Visualización de reglas de asociación

Análisis de asociación

Reglas de asociación

Algoritmo Apriori [Agrawal y Srikant, 1994]

- Se basa en la búsqueda de un conjunto de ítems con un soporte superior a un valor umbral denominados *ítems frecuentes*
- Se aplica la propiedad de que si un conjunto de ítems es frecuente también lo son todos sus subconjuntos

$$\forall X, Y: (X \subseteq Y) \Rightarrow \text{soporte}(X) \geq \text{soporte}(Y)$$

- Las reglas de asociación se generan a partir de los ítems frecuentes

Análisis de asociación

Reglas de asociación


Algoritmo Apriori (II)

- **Proceso de generación de ítems frecuentes**
 - Cada transacción se asocia con un identificador
 - Las transacciones se ordenan secuencialmente según el identificador
 - Se cuentan todas las ocurrencias de los artículos simples que están presentes en transacciones y se crea un vector en el que se coloca la cuenta para cada artículo.
 - Aquellos elementos en los que la cuenta está por debajo de un umbral se eliminan
 - Se crea una matriz bidimensional donde se almacenan las cuentas de ocurrencias de cada artículo con todos los demás.
 - Se eliminan las celdas cuya cuenta esté por debajo del valor umbral
 - Se crea una tabla tridimensional y se repite el proceso

Análisis de asociación

Reglas de asociación

Algoritmo Apriori (III)



Análisis de asociación

Reglas de asociación

Algoritmo Apriori (IV)

- **Proceso de generación de reglas de asociación**
 - A partir de los conjuntos de ítems frecuentes se derivan las posibles reglas
 - Cada regla es una partición binaria del conjunto de ítems
 - Dado un conjunto de ítems frecuentes I se encuentran todos los subconjuntos no vacíos $f \subset I$
 - Si $|I| = k$ entonces hay $2^k - 2$ reglas
 - Se eliminan las reglas con una confianza inferior a un valor umbral

Análisis de asociación

Reglas de asociación

Algoritmo Apriori (V)

Itemset	Oc
{A}	2
{B}	3
{C}	3
{E}	3

Itemset	Oc
{A C}	2
{B C}	2
{B E}	3
{C E}	2



Regla	Confianza	Regla	Confianza
$A \rightarrow C$	1	$B \rightarrow E$	1
$C \rightarrow A$	2/3	$E \rightarrow B$	1
$B \rightarrow C$	2/3	$C \rightarrow E$	2/3
$C \rightarrow B$	2/3	$E \rightarrow C$	2/3

Itemset	Oc
{B C E}	2




Regla	Confianza	Regla	Confianza
$B \rightarrow CE$	2/3	$CE \rightarrow B$	1
$C \rightarrow BE$	2/3	$BE \rightarrow C$	2/3
$E \rightarrow BC$	2/3	$BC \rightarrow E$	1

Análisis de asociación

Reglas de asociación

Algoritmo Apriori (VI)

- La ejecución del algoritmo Apriori es muy costosa
 - Genera muchas combinaciones de conjuntos de ítems
 - Realiza repetidas búsquedas por conjuntos de ítems frecuentes



Análisis de asociación

Reglas de asociación

Algoritmo Apriori (VII)

Ejercicio

- A partir del conjunto de datos de la tabla obtener reglas de asociación con soporte > 0.5 y confianza > 0.9 mediante el algoritmo Apriori

TID	Artículos
1	Pan, leche, huevos
2	Pan, pañales, cerveza
3	Leche, pañales, cerveza
4	Pan, leche, pañales, cerveza
5	Pan, leche, huevos, cerveza

Análisis de asociación

Reglas de asociación

Algoritmo FP-Growth (I)


- Utiliza una estructura de datos denominada FP-Tree (*Frequent Pattern Tree*) para mejorar el rendimiento
- Proceso
 - Recorrer el conjunto de transacciones y contabilizar las frecuencias de ítems
 - Ordenar los ítems en orden decreciente de frecuencia
 - Recorrer el conjunto de transacciones que contienen ítems frecuentes ordenados y componer cada rama del árbol
 - Obtener las reglas de asociación a partir de los conjuntos de ítems del árbol


Análisis de asociación

Reglas de asociación

- Algoritmo FP-Growth (II)

ID transacción	Ítems	Ítems frecuentes
1	f a c d g i m p	f c a m p
2	a b c f l m o	f c a b m
3	b f h j o	f b
4	b c k s p	c b p
5	a f c e l p m n	f c a m p





Análisis de asociación

Reglas de asociación

Medidas de calidad (I)

- Soporte
- Confianza
- Lift
- Leverage
- Convicción
- Soporte causal
- Confianza causal
- Confirmación

Análisis de asociación

Reglas de asociación

Medidas de calidad (II)

- **Soporte**

- Indica la proporción de ejemplos que satisfacen tanto a la parte antecedente como a la consecuente de una regla, se define como:

$$\text{Soporte } (X \rightarrow Y) = P(X \cap Y) = \frac{|X \cap Y|}{n}$$

Donde $|X \cap Y|$ es el número de ejemplos (transacciones) que contienen X e Y , siendo n el número total de ejemplos

- **Confianza**

- Se define como la proporción de ejemplos que contiene al consecuente y al antecedente de la regla en relación a la proporción de ejemplos que contienen al antecedente

$$\text{Confianza } (X \rightarrow Y) = \frac{P(X \cap Y)}{P(X)} = P(Y|X) = \frac{|X \cap Y|}{|X|}$$

Donde $|X|$ es el número de ejemplos que contienen X

Análisis de asociación

Reglas de asociación

Medidas de calidad (III)

- **Lift**

- Indica la probabilidad de la regla en relación con la probabilidad conjunta del antecedente y el consecuente si fueran independientes

$$Lift(X \rightarrow Y) = \frac{Confianza(X \rightarrow Y)}{Soporte(Y)} = \frac{P(X, Y)}{P(X)P(Y)}$$

- Si $lift > 1$ la regla aparece más veces de lo esperado en condiciones de independencia de antecedente y consecuente

Confianza (Té → Café) = $15/20 = 0.75$

Probabilidad (Café) = 0.90

Probabilidad (Té) = 0.20

Probabilidad (Café, Té) = 0.15

	Café	No café	
Té	15	5	20
No té	75	5	80
	90	10	100

Lift (Té → Café) = $(0.75/0.90) = 0.15/(0.20*0.90) = 0.833$

Análisis de asociación

Reglas de asociación

Medidas de calidad (IV)

- **Leverage**

- Mide la diferencia entre la probabilidad de la regla y la probabilidad conjunta del antecedente y el consecuente si fueran independientes

$$\text{Leverage } (X \rightarrow Y) = P(X, Y) - P(X)P(Y)$$

- Toma valores en el intervalo $[-1, 1]$

Probabilidad (Café) = 0.90

Probabilidad (Té) = 0.20

Probabilidad (Café, Té) = 0.15

	Café	No café	
Té	15	5	20
No té	75	5	80
	90	10	100

Leverage (Té → Café) = $0.15 - (0.20 \cdot 0.90) = -0.03$

Análisis de asociación

Reglas de asociación

Medidas de calidad (V)

- **Convicción**

- Evalúa el grado en que el término antecedente influye en la ocurrencia del término consecuente de una regla de asociación

$$\text{Convicción} = \frac{\text{soporte}(X) \text{ soporte}(\neg Y)}{\text{soporte}(X, \neg Y)}$$

- El valor 1 indica la independencia de los términos de la regla
- El valor $+\infty$ corresponde a una confianza del 100%

Soporte (Té) = 0.20

Soporte ($\neg$ Café) = 0.10

Soporte (Té, $\neg$ Café) = 0.05

	Café	No café	
Té	15	5	20
No té	75	5	80
	90	10	100

Convicción (Té $\rightarrow$ Café) = $(0.20 * 0.10) / 0.05 = 0.4$

Análisis de asociación

Reglas de asociación

Medidas de calidad (VI)

- **Confianza causal**

- Considera la confianza correspondiente a la implicación $X \Rightarrow Y$ y la confianza de su contraposición $\neg Y \Rightarrow \neg X$:

$$\text{confianza_causal}(X \Rightarrow Y) = \frac{1}{2} [P(Y|X) + P(\neg X|\neg Y)]$$

- **Soporte causal**

- Considera el soporte correspondiente a la implicación $X \Rightarrow Y$ con el soporte de su contraposición $\neg Y \Rightarrow \neg X$:

$$\text{soporte_causal}(X \Rightarrow Y) = P(X \cap Y) + P(\neg X \cap \neg Y)$$

- **Confirmación**

- Permite seleccionar entre dos reglas con igual valor de soporte aquella cuyo antecedente posea el valor de soporte más pequeño

$$\text{confirmación}(X \Rightarrow Y) = 2 \cdot P(X \cap Y) - P(X) = 2 \cdot \text{soporte}(X \Rightarrow Y) - \text{soporte}(X)$$

Análisis de asociación

Reglas de asociación

Medidas de calidad (VII)

	Café	No café	
Té	15	5	20
No té	75	5	80
	90	10	100

Probabilidad (Café) = 0.90

Probabilidad (Té) = 0.20

Probabilidad (Café $\cap$ Té) = 0.15

Probabilidad (Café|Té) = $15/20=0.75$

Probabilidad ($\neg$ Café| $\neg$ Té) = $5/80=0.06$

Confianza causal (Té $\rightarrow$ Café) = $\frac{1}{2}[P(\text{Café}|\text{Té})+P(\neg\text{Café}|\neg\text{Té})]=\frac{1}{2} (0.75+0.06)= 0.41$

Soporte causal (Té $\rightarrow$ Café) = $P(\text{Café} \cap \text{Té})+P(\neg\text{Café} \cap \neg\text{Té})=(0.15+0.05)= 0.20$


Confirmación (Té $\rightarrow$ Café) = $2 P(\text{Café} \cap \text{Té})-P(\text{Té})=0.30-0.20 = 0.10$

Análisis de asociación

Reglas de asociación

Reglas generalizadas o multinivel

- Reglas que asocian conceptos o artículos a diferentes niveles de abstracción
- Las reglas obtenidas en niveles bajos
 - Pueden no tener soporte suficiente
 - Pueden ser demasiado específicas



Reglas

- Pan → Bebida
- Pan blanco → Refresco
- Pan integral → Zumo piña

Análisis de asociación

Reglas de asociación

Clasificación basada en asociación (I)

- Consiste en la aplicación de reglas de asociación en problemas de clasificación
- Se basa en generar reglas de asociación que posean en su parte consecuente únicamente a la variable etiqueta
- A este tipo de reglas se les denomina **reglas de asociación de clases**

Algoritmos

- CBA (*Classification Based on Associations*) [Liu et al., 1998]
- CMAR (*Classification Based on Multiple Class-Association Rules*) [Li et al., 2001]
- CPAR (*Classification Based on Predictive Association Rules*) [Yin & Han, 2003]

Análisis de asociación

Reglas de asociación

Clasificación basada en asociación (II)

- Tipos de clasificadores basados en reglas de asociación

Clasificadores basados en reglas ordenadas

Las reglas se ordenan atendiendo a alguna medida de calidad

Se aplica la primera regla que se ajuste al ejemplo a clasificar

Clasificadores basados en reglas no ordenadas

Todas las reglas coincidentes participan en la determinación de la clase del nuevo ejemplo

Posibles métodos a aplicar

- Utilizar el voto de la mayoría de reglas
- Comparar las precisiones reales obtenidas a partir de múltiples reglas para todas las posibles clases

Análisis de asociación

Descubrimiento de patrones secuenciales

- Las técnicas de descubrimiento de **patrones secuenciales** detectan patrones entre transacciones de forma que la presencia de un conjunto de items es seguida por otro conjunto de items en una base de datos de transacciones, durante un periodo de tiempo
- Para una base de datos de compras (transacciones) y clientes (grupo de transacciones):
 - Cada transacción se identifica por su fecha y hora (ID de la transacción)
 - Cada ítem tiene un identificador único (ID del item)
 - Cada cliente tiene un identificador único (grupo de transacciones)
- Los patrones deben superar un umbral de soporte
 - Ocurrencia relativa de los patrones secuenciales detectados dentro del conjunto total de transacciones

Análisis de asociación

Descubrimiento de patrones secuenciales

Cliente	Fecha/hora transacción	Artículos comprados
L. López	21/1/2021, 5:27 pm	cerveza
L. López	22/1/2021, 10:34 am	brandy
J. Martín	20/1/2021, 10:13 am	zumos, pastel
J. Martín	20/1/2021, 11:47 am	cerveza
J. Martín	21/1/2021, 9:22 am	vino, agua, sidra
A. Ramos	20/1/2021, 2:32 pm	cerveza
A. Ramos	21/1/2021, 6:17 pm	Vino, sidra
A. Ramos	22/1/2021, 5:03 pm	brandy


Análisis de asociación

Descubrimiento de patrones secuenciales

Cliente	Artículos comprados
L. López	(cerveza) (brandy)
J. Martín	(zumos, pastel) (cerveza) (vino, agua, sidra)
A. Ramos	(cerveza) (Vino, sidra) (brandy)

Cientes	Patrones secuenciales con soporte > 40%
L. López, A. Ramos	(cerveza) (brandy)
J. Martín, A. Ramos	(cerveza) (vino, sidra)

4. DETECCIÓN DE DESVIACIONES



Detección de desviaciones

Las técnicas de detección de desviaciones facilitan la identificación de datos que se desvían de la norma o del valor esperado


- Las técnicas más utilizadas son
 - **Técnicas de visualización:** permiten representar la información resumida facilitando la detección de desviaciones
 - **Métodos estadísticos:** son útiles para detectar las desviaciones y para medir su importancia

Ambas técnicas se utilizan tanto en la etapa de preparación de los datos como en la de análisis de resultados

Detección de desviaciones



Visualización

- La visualización es una de las técnicas más potentes para identificar patrones ocultos en los datos
- Con estas técnicas se pueden detectar fenómenos que ocurren para un subconjunto relativamente pequeño de datos
- Representaciones: histogramas, gráficos de cajas, gráficos de dispersión, diagramas de sectores, gráficos tridimensionales




Detección de desviaciones

Visualización






Detección de desviaciones

Visualización





Detección de desviaciones Estadísticas

- La medida de la magnitud de la desviación, que proporcionan los métodos estadísticos, es crítica para saber qué hacer con la desviación una vez detectada
- Estos métodos se aplican en la fase de análisis de resultados para obtener una mejor evaluación de los mismos



Detección de desviaciones Estadísticas

- Medidas estadísticas más utilizadas:
 - La **media** y la **mediana** son medidas de la tendencia central en la distribución de los datos. Se pueden usar para medir la magnitud de la desviación
 - La **varianza** es la extensión con que los valores difieren de la media. El significado de la varianza de un valor individual puede obtenerse a partir de la representación de la curva de varianza y del valor estándar



Referencias

- Agrawal, R., Srikant, R. “Fast Algorithms for mining association rules in large databases”. *Proc. of 20th Int. Conference on Very Large Databases*, Santiago de Chile, pp. 487-489, 1994.
- Han, L, Pei, J., Yin, Y., “Mining Frequent Patterns without Candidate Generation”, *Proc. of ACM SIGMOD Int. Conf. on Management of Data*, pp. 1-12, 2000.
- Liu, B., Hsu, W. Ma, Y. Integration Classification and Association Rule Mining. *Proc. 4th Int. Conference on Knowledge Discovery and Data Mining*, pp. 80-86, 1998.
- Liu, B., Hsu, W., Chen, S., Ma, Y. “Analyzing the subjective Interestingness of Association Rules”. *IEEE Intelligent Systems*, september/October, pp. 47-55, 2000.
- Mattt, NSHipster, <https://github.com/NSHipster/DBSCAN> (Última visita: 5/11/2022).
- Moreno, M.N., Miguel, L.A., García, F.J., Polo, M.J., “Building knowledge discovery-driven models for decision support in project management”. *Decisión Support Systems*, 38, pp. 305-317, 2004
- Moreno, M.N., Ramos, I., García F.J., Toro, M. “An association rule mining method for estimating the impact of project management policies on software quality, development time and effort”. *Expert Systems with Applications*, 34 (2008) pp. 522–529, 2008.
- Li, W., Han, J., Pei, J. “CMAR. accurate and efficient classification based on multiple class-association rules”. *Proceedings of the IEEE International Conference on Data Mining, (ICDM '01)*, California, pp. 369-376, 2001.
- Yin, X., Han, J. “CPAR. Classification based on predictive association rules”. In. *SIAM International Conference on Data Mining (SDM'03)*. pp. 331-335, 2003.