

Asignatura: **Minería de Datos**

Trabajo obligatorio

El objetivo principal de este trabajo es **demostrar que se han adquirido los conocimientos impartidos en las clases de la asignatura** mediante la aplicación de los algoritmos explicados en clase y la interpretación de los resultados obtenidos.

Se recomienda la lectura minuciosa de las siguientes especificaciones puesto que **CUALQUIER INCUMPLIMIENTO DE LO INDICADO EN ELLAS SUPONDRÁ UNA PENALIZACIÓN EN LA CALIFICACIÓN.**

ESPECIFICACIONES

El trabajo consiste en la aplicación práctica de **métodos de minería de datos presentados en las clases teóricas** atendiendo a lo indicado en los siguientes puntos.

- Aplicar **dos** algoritmos de aprendizaje supervisado.
- Aplicar **dos** algoritmos de aprendizaje no supervisado, uno de *clustering* y otro de reglas de asociación.
- Previamente se deben realizar tareas de exploración, preprocesamiento y transformación de datos en el *dataset* seleccionado para realizar el trabajo. Algunas de las tareas que pueden hacerse son:
 - **Análisis de la distribución de valores de los atributos, incluido el atributo de clase en problemas de clasificación.**
 - **Detección y tratamiento de valores perdidos, ruido en los datos, etc.**
 - Discretización de valores de los atributos cuando sea necesario.
 - **Aplicación de métodos de selección de características.**
 - **Remuestreo si hay desequilibrio en el número de instancias de las clases.**

El trabajo debe contener:

- Descripción del problema a resolver y definición de objetivos.
- Descripción del conjunto de datos que se va a utilizar.
- Descripción de las tareas de **preprocesamiento** y **minería de datos** realizadas, incluyendo la configuración de **parámetros de los algoritmos** y las **técnicas de validación aplicadas**.
- Presentación y discusión de resultados (se deben interpretar los valores de las métricas explicadas en clase para evaluar los resultados de los distintos tipos de algoritmos, demostrando que se conoce y se entiende el significado de cada una de las métricas).
- Conclusiones.

Se puede utilizar tanto la herramienta Weka (<http://www.cs.waikato.ac.nz/ml/weka/>) como cualquier otra, o implementar un programa que haga uso de librerías disponibles públicamente.

Observaciones:

- **NO** debe describirse la herramienta utilizada ni la forma de hacer las tareas con ella.
- **NO** se pueden utilizar los *datasets* de ejemplo de Weka.
- Elegir un **dataset** que permita hacer el mayor número de tareas posible y una interpretación de resultados adecuada.
- **NO** se pueden aplicar redes neuronales debido a que esos algoritmos se estudian en otra asignatura.
- **SOLO** se aplicarán **2 algoritmos de cada categoría**, aunque sí pueden compararse diferentes modelos generados con el mismo algoritmo, pero con diferentes parámetros de configuración que se hayan visto en clase, o modificando el *dataset* con alguna técnica de preprocesamiento como selección de características o remuestreo.

Pueden encontrarse datos públicos para realizar el trabajo en:

- <https://archive.ics.uci.edu/ml/datasets>
- <https://www.kaggle.com/datasets>
- <https://www.kdnuggets.com> (desde la página se puede acceder a sitios que proporcionan otros conjuntos de datos que también pueden usarse para realizar el trabajo).