


USO DE LAS REDES NEURONALES EN LA SÍNTESIS DEL HABLA

Trabajo Final de Tecnologías del Habla



Arlet Acosta González
Máster en Sistemas Inteligentes

ÍNDICE

Índice de figuras	2
Índice de tablas.....	3
1 Introducción	4
2 Conversión Texto a Voz (TTS, Text To Speech).....	4
2.1 Esquema del proceso	5
2.1.1 El análisis de texto.....	5
2.1.2 El análisis fonético	5
2.1.3 La prosodia.....	6
2.1.4 El bloque Speech Synthesis	6
3 Aplicaciones de los sistemas TTS	6
4 Tipos de sintetizadores	7
4.1 Síntesis articulatoria	7
4.2 Síntesis por concatenación.....	8
4.2.1 Concatenación de forma de onda.....	8
4.3 Síntesis paramétrica	8
4.3.1 Síntesis de formantes	9
4.3.2 Relacionados con técnicas de predicción lineal (LPC).....	9
4.3.3 Síntesis Estadística Paramétrica	9
5 TTS basado en Deep Learning (DL)	16
5.1 TTS basado en modelos autorregresivos (AR)	17
5.1.1 WaveNet.....	17
5.1.2 Tacotron	18
5.1.3 Deep-voice	19
5.2 TTS basado en un modelo no autorregresivo (NAR)	20
5.2.1 ParaNet	20
5.2.2 Tacotron paralelo.....	20
5.2.3 FastSpeech	21
5.2.4 Parallel WaveNet.....	22
6 Ventajas de la síntesis de voz neuronal.....	22
7 Conclusiones	23
8 Referencias	24

ÍNDICE DE FIGURAS

Fig. 1 Diagrama de bloques de síntesis TTS	5
Fig. 2 Varias técnicas de síntesis de voz empleadas en TTS. (Kaur & Singh, 2023).....	6
Fig. 3 Síntesis de voz concatenativa: las unidades son almacenadas en el corpus y concatenadas para sintetizar la voz. (Kaur & Singh, 2023)	8
Fig. 4 Sistema de Síntesis de voz basado en DNN. (Kaur & Singh, 2023)	13
Fig. 5 Estructura RNN para modelar parámetros del habla. (Kaur & Singh, 2023)	15
Fig. 6 Clasificación MOS de WaveNet para voz en inglés de EE. UU.	17
Fig. 7 Comparación de la clasificación MOS de Tacotron 2 con otros modelos.	18
Fig. 8 Comparación de Deep Voice 2 con otros modelos conocidos.....	19
Fig. 9 Comparación de Deep Voice 3 con otros modelos de última generación.	20
Fig. 10 Comparación de la puntuación MOS en inglés y japonés con Wavenets destiladas de varios hablantes.....	22

ÍNDICE DE TABLAS

Tabla 1 Comparación del tiempo de síntesis y MOS de ParaNet y Deep Voice 3	20
Tabla 2 Comparación de sonidos sintetizados usando Parallel Tacotron y Parallel Tacotron 2	21

1 INTRODUCCIÓN

El uso de las redes neuronales en la síntesis del habla ha ganado importancia en los últimos años debido a su capacidad para generar habla sintética de alta calidad y naturalidad. Las redes neuronales pueden aprender patrones complejos en grandes conjuntos de datos de habla y utilizarlos para sintetizar habla que suene como la de un ser humano. El uso de RNs en la síntesis del habla ha revolucionado el campo y ha permitido generar habla sintética de alta calidad y naturalidad en una amplia variedad de idiomas y acentos.

El presente trabajo explica en qué consiste la conversión de texto a voz, las principales etapas del proceso de forma general y las aplicaciones, que han abierto nuevas posibilidades para el desarrollo de aplicaciones en tiempo real y ha mejorado la accesibilidad para personas con discapacidades visuales o de lectura. También se describen algunas técnicas de síntesis de voz, así como su clasificación. Por último, se mencionan algunos ejemplos de modelos de síntesis de voz neuronal y las ventajas de esta.

2 CONVERSIÓN TEXTO A VOZ (TTS, TEXT TO SPEECH)

La síntesis de voz es un proceso que produce artificialmente voz para diversas aplicaciones, disminuyendo la dependencia del uso de la voz grabada de una persona. Los métodos de síntesis de voz permiten que una máquina transmita instrucciones o información al usuario a través del "habla".(Furui, Sadaoki, 2001)

El objetivo de la síntesis de voz es desarrollar una máquina que tenga una voz inteligible y de sonido natural para transmitir información a un usuario con el acento, el idioma y la voz deseados. La investigación en TTS (*Text-To-Speech*, por sus siglas en inglés) es un campo multidisciplinario: desde la fonética acústica (producción y percepción del habla) pasando por la morfología (pronunciación) y la sintaxis (partes del habla, gramática), hasta el procesamiento de señales del habla (síntesis). Hay varias etapas de procesamiento en el sistema TTS: el front-end del texto analiza y normaliza el texto entrante, crea posibles pronunciaciones para cada palabra en contexto y genera prosodia (emociones, melodía, ritmo, entonación) de la oración que se va a decir. La fig. 1 muestra un diagrama de bloques de síntesis TTS (Balyan et al., 2013)




Fig. 1 Diagrama de bloques de síntesis TTS

2.1 ESQUEMA DEL PROCESO

El proceso de transformación de texto en voz consta a grandes rasgos de dos fases: el análisis de texto y la síntesis de voz.

2.1.1 El análisis de texto

Consiste en la normalización del texto, en la que los números y símbolos se convierten en palabras y las abreviaturas se sustituyen por sus palabras o frases completas, etc. La tarea más desafiante en el bloque de análisis de texto es el análisis lingüístico, que significa análisis sintáctico y semántico y tiene como objetivo comprender el contexto del texto. Los métodos estadísticos se utilizan para encontrar el significado más probable de los enunciados. Esto es importante porque la pronunciación de una palabra puede depender de su significado y del contexto. (Balyan et al., 2013)

2.1.2 El análisis fonético

Convierte los símbolos ortográficos en fonológicos utilizando un alfabeto fonético. Por ejemplo, el alfabeto de la Asociación Fonética Internacional contiene símbolos de fonemas, sus signos diacríticos y otros símbolos relacionados con su pronunciación. Otros alfabetos fonéticos como SAMPA (*Speech Assesment MethodsPhonetic Alphabet*), Worldbet y Arpabet también están disponibles. (Balyan et al., 2013)

2.1.3 La prosodia

Es un concepto que contiene el ritmo del habla, los patrones de acento y la entonación. A nivel perceptivo, la naturalidad en el habla se atribuye a ciertas propiedades de la señal relacionadas con los cambios audibles en el tono, la sonoridad y la longitud silábica, llamadas colectivamente prosodia. Acústicamente, estos cambios corresponden a las variaciones en la frecuencia fundamental (F0), la amplitud y la duración de las unidades de voz. (Balyan et al., 2013)

2.1.4 El bloque Speech Synthesis

Finalmente genera la señal de voz. Esto se puede lograr sobre la base de la representación paramétrica, en la que las realizaciones de fonemas se producen a máquina, o mediante la selección de unidades de voz de una base de datos. (Balyan et al., 2013)

La figura 2 muestra varias técnicas de síntesis de voz empleadas en TTS y la relaciones entre ellas. El presente trabajo se ha dado a la tarea de abordarlas.




Fig. 2 Varias técnicas de síntesis de voz empleadas en TTS. (Kaur & Singh, 2023)

3 APLICACIONES DE LOS SISTEMAS TTS

Los sistemas TTS tienen numerosas aplicaciones potenciales. A continuación, se enumeran algunos. (Balyan et al., 2013)

1. En el servicio de telecomunicaciones: La mayoría de las llamadas requieren muy poca conectividad, los sistemas TTS muestran una gran presencia en los servicios de telecomunicaciones al permitir el acceso a información textual por teléfono.
2. En el servicio de gobierno electrónico: TTS puede ser muy útil al proporcionar información sobre políticas gubernamentales por teléfono, información sobre centros de votación, información sobre registros de tierras, seguimiento y monitoreo de solicitudes, etc.

3. Ayuda a las discapacidades: TTS puede brindar un apoyo invaluable a las personas con discapacidad visual.

4. Navegación por voz: TTS es la columna vertebral de los navegadores de voz, que se puede controlar por voz en lugar de por el mouse y el teclado, lo que permite la navegación con manos libres y sin implicar la visión.

5. Monitoreo vocal: A veces se supone que la información oral es más eficiente que su contraparte escrita. De ahí la idea de incorporar sintetizadores de voz en los sistemas de medición o control, como las cabinas, para evitar que los pilotos se vean abrumados por la información visual.

6. Sistemas complejos de respuesta de voz interactiva: Con el apoyo de reconocedores de voz de buena calidad, los sistemas de síntesis de voz pueden hacer realidad sistemas complejos de respuesta de voz interactiva.

7. Multimedia, comunicación hombre-máquina: La multimedia es el primer pero prometedor paso en la dirección e incluye libros y juguetes parlantes, lectores de correo y documentos.

Sin embargo, a medida que las aplicaciones se extienden, la cuestión de la naturalidad es de suma importancia en el desarrollo de sintetizadores de texto a voz ilimitados.

4 TIPOS DE SINTETIZADORES

4.1 SÍNTESIS ARTICULATORIA

El método de síntesis del habla articulatoria sintetiza las formas de onda sonoras basadas en el sistema natural de producción del habla humana que implica simular digitalmente el flujo de aire a través del tracto vocal y las actividades de articulación que ocurren allí. Si bien, este tipo de síntesis produce un discurso muy inteligible, carece de naturalidad. Las formas de onda generadas suenan robóticamente. Esto se debe a que los datos utilizados para modelar el sistema natural de producción del habla humana se derivan tradicionalmente del análisis de rayos X 2D, por lo tanto, existen dificultades para modelar lo articular con precisión.

En la práctica, también se considera un método difícil de implementar y, por lo tanto, el mismo nivel de éxito era inalcanzable en comparación con otros métodos de síntesis de voz. (Kaur & Singh, 2023)

4.2 SÍNTESIS POR CONCATENACIÓN

4.2.1 Concatenación de forma de onda

La síntesis concatenativa se basa en la concatenación de fragmentos de oración que se almacenan en una base de datos. Por lo general, la base de datos consta de unidades de habla que van desde oraciones completas hasta sílabas que son grabadas por actores de doblaje. En la inferencia, el sistema TTS concatenativo busca unidades de voz para que coincidan con el texto de entrada dado y produce la forma de onda de voz concatenando estas unidades. (Tan et al., 2021)

El punto fuerte de la síntesis de voz concatenativa basada en unidades es su corpus de voz de tamaño masivo, que almacena casi todas las expresiones habladas en el lenguaje en el que se basa TTS. A partir del corpus de voz disponible, los archivos de sonido coincidentes más grandes se concatenan para generar la voz de destino, como se muestra en la Fig. 3.(Kaur & Singh, 2023)




Fig. 3 Síntesis de voz concatenativa: las unidades son almacenadas en el corpus y concatenadas para sintetizar la voz. (Kaur & Singh, 2023)

En términos generales, el TTS concatenativo puede generar audio con alta inteligibilidad y timbre auténtico cercano al actor de voz original. Sin embargo, el TTS concatenativo requiere una gran base de datos de grabación para cubrir todas las combinaciones posibles de unidades de voz para las palabras habladas. Otro inconveniente es que la voz generada es menos natural y emocional, ya que la concatenación puede resultar en una menor suavidad en el estrés, la emoción, la prosodia, etc.(Tan et al., 2021)

4.3 SÍNTESIS PARAMÉTRICA

La síntesis paramétrica de voz se refiere al método que utiliza tecnologías de procesamiento de señales digitales para sintetizar voz a partir de texto. En este método,

se considera el proceso vocal humano como una simulación que utiliza una fuente de estado glotal para excitar un filtro digital variable en el tiempo que describe las características de resonancia del canal. La fuente puede ser una secuencia de pulsos periódica que se utiliza para representar la vibración de las cuerdas vocales del habla sonora, o un ruido blanco aleatorio para indicar un habla sorda indefinida. Ajustando los parámetros del filtro, puede sintetizar varios tipos de discursos. (Ning et al., 2019)

Los métodos típicos incluyen la síntesis paramétrica de formantes, la síntesis de voz basada en HMM y la síntesis de voz basada en redes neuronales profundas (DNN) y la síntesis de voz basada en RNN.

4.3.1 Síntesis de formantes

La síntesis de voz de formantes es un enfoque basado en reglas para sintetizar el habla utilizado en el pasado. El modelo acústico de síntesis de formantes utilizó los diversos parámetros sonoros, como el grado de sonorización en excitación, la frecuencia fundamental (F0), las frecuencias de formantes y su amplitud. Produce el habla altamente inteligible al evitar los fallos acústicos en los límites de las unidades de sonido que se producen comúnmente en la técnica de síntesis de voz concatenativa basada en unidades, pero sigue generando el habla en forma de sonido robótico, por lo tanto, carece de naturalidad. (Kaur & Singh, 2023)

4.3.2 Relacionados con técnicas de predicción lineal (LPC)

El desarrollo de la técnica de codificación predictiva lineal (LPC) para el análisis y la resíntesis del habla ha hecho posible almacenar inventarios relativamente grandes de formas de ondas del habla de alta calidad en un espacio limitado. El sistema es un filtro lineal de todos los polos que simula el espectro de la fuente y la función de transferencia del tracto vocal (modelo del tracto como secuencia de cilindros huecos). La técnica tiene muchas ventajas, como el análisis automático de la señal original, la integración algorítmica bastante fácil y la fidelidad al sonido original. Este filtro es excitado por un modelo de fuente que debe ser capaz de manejar todo tipo de sonidos: sonoros, aspirativos y fricativos. Sin embargo, se ha encontrado que el uso de LPC no tiene éxito en la conversión de texto a voz, probablemente debido a su capacidad limitada para representar parámetros de voz. (Balyan et al., 2013)

4.3.3 Síntesis Estadística Paramétrica

Para abordar los inconvenientes de la TTS concatenativa, se propone la síntesis estadística paramétrica de voz (SPSS). La idea básica es que, en lugar de generar forma de onda directa a través de la concatenación, primero podemos generar los parámetros

acústicos que son necesarios para producir el habla y luego recuperar el habla a partir de los parámetros acústicos generados utilizando algunos algoritmos. (Tan et al., 2021)

Un sistema SPSS completo se compone generalmente de tres módulos: un módulo de análisis de texto, un módulo de predicción de parámetros que utiliza un modelo estadístico para predecir los parámetros de las características acústicas, como la frecuencia fundamental (F0), los parámetros espectrales y la duración, y un módulo de síntesis de voz. El módulo de análisis de texto preprocesa principalmente el texto de entrada y lo transforma en características lingüísticas utilizadas por el sistema de síntesis de voz, incluida la normalización del texto, la segmentación automática de palabras y la conversión de grafema a fonema. Estas características lingüísticas suelen incluir fonemas, sílabas, palabras, frases y características a nivel de oraciones. El propósito del módulo de predicción de parámetros es predecir los parámetros de características acústicas de la voz objetivo de acuerdo con la salida del módulo de análisis de texto. El módulo de síntesis de voz genera la forma de onda de la voz de destino de acuerdo con la salida del módulo de predicción de parámetros mediante el uso de un algoritmo de síntesis particular. El SPSS suele dividirse en dos fases: la fase de entrenamiento y la fase de síntesis. En la fase de entrenamiento, los parámetros de las características acústicas, como F0 y los parámetros espectrales, se extraen primero del corpus y, a continuación, se entrena un modelo acústico estadístico basado en las características lingüísticas del módulo de análisis de texto, así como en los parámetros de las características acústicas extraídas. En la fase de síntesis, los parámetros de las características acústicas se predicen utilizando el modelo acústico entrenado con la guía de las características lingüísticas. Por último, la voz se sintetiza en función de los parámetros de las características acústicas predichas mediante un vocoder (una contracción de VOice CODER, que se usa ampliamente para referirse a los codificadores de voz que involucran operaciones de análisis y resíntesis. La mayoría de los vocoders se basan en un modelo de producción de voz que separa el proceso de generación de sonido de la posterior operación de filtrado del tracto vocal (Holmes, J. N. & Holmes, Wendy, 2001)).(Ning et al., 2019)

4.3.3.1 *Análisis de texto*

El análisis de texto es un módulo importante del modelo SPSS. Los métodos tradicionales de análisis de texto se basan principalmente en reglas, que requieren mucho tiempo para recopilar y aprender estas reglas. Con el rápido desarrollo de la tecnología de minería de datos, se han desarrollado gradualmente algunos métodos basados en datos, como el método basado en HMM y el método basado en DNN. Cuando se utilizan estos dos últimos métodos para el análisis de textos, se suele utilizar

el sistema Festival para realizar la segmentación y anotación de fonemas en el corpus, que incluye principalmente los siguientes cinco niveles: nivel de fonemas, nivel de sílabas, nivel de palabras, nivel de frase, nivel de oración.(Ning et al., 2019)

4.3.3.2 Predicción de parámetros

La predicción de parámetros se utiliza para predecir los parámetros de las características acústicas en función del resultado del módulo de análisis de texto y el modelo acústico entrenado. (Ning et al., 2019)

Para el SPSS, generalmente hay tres tipos de métodos de predicción de parámetros: predicción de parámetros basada en HMM, predicción de parámetros basada en DNN y predicción de parámetros basada en RNN.

4.3.3.2.1 Predicción de parámetros basada en HMM

Es similar a la síntesis de selección de unidades, entrenada con voz natural, sin embargo, debido al enfoque del modelo paramétrico; permite una mejor modelización de la variación. Las principales ventajas de las técnicas de síntesis basadas en el modelo oculto de Markov es que la alteración de la voz se puede realizar sin grandes bases de datos, estando a la par con la calidad. (Kayte et al., 2015)

El método de predicción de parámetros basado en HMM genera principalmente la secuencia de parámetros F0 y espectrales a partir de los HMM entrenados. Se logra calculando la secuencia de características acústicas con el algoritmo de estimación de máxima verosimilitud (MLE) dada una secuencia de distribución gaussiana. Debido a las diferencias entre F0 y los parámetros espectrales, se han adoptado diferentes métodos para modelar los dos tipos de parámetros de características. Para los parámetros espectrales continuos, se utiliza el modelo de Markov oculto de densidad continua (CD-HMM) y la salida de cada estado HMM es un solo modelo gaussiano o un modelo de mezcla gaussiana (GMM). Sin embargo, para los parámetros F0 de dimensión variable que incluyen regiones sonoras y sordas, es difícil aplicar HMM discretos o continuos porque los valores de F0 no están definidos en regiones sordas. Para abordar este problema, el método basado en HMM adopta una distribución de probabilidad multiespacio para modelar las regiones sonoras y sordas (por ejemplo, parámetros sonoros/sordos (V/UV)), por separado. (Ning et al., 2019)

Árboles de decisión y H(S)MMs: HSMM (Hidden Semi-Markov Model), una variante de HMM, se utiliza para modelar la excitación del habla y la información del espectro. Los árboles de decisión se utilizan para modelar las características prosódicas y lingüísticas

del habla y el nodo individual del árbol de decisión está vinculado a una característica contextual.(Kaur & Singh, 2023)

4.3.3.2.2 Predicción de parámetros basada en DNN

Es bien sabido que las características acústicas de un fonema en particular se verán afectadas por la información de contexto asociada con el fonema. Esto significa que la información de contexto juega un papel importante en la predicción de las características acústicas. Los investigadores muestran que el proceso de generación del habla humana suele utilizar una estructura jerárquica para convertir la información del contexto en una forma de onda del habla. Inspirados en esta idea, se han introducido los modelos de estructura profunda en la predicción de parámetros de características acústicas para la síntesis de voz.

Para compararse con los métodos de predicción de parámetros basados en HMM, los métodos basados en DNN no solo pueden mapear características lingüísticas complejas en parámetros de características acústicas, sino también utilizar información de contexto a largo plazo para modelar la correlación entre tramas, lo que mejora la calidad de la síntesis de voz. Además, para los métodos basados en HMM, el principio de MLE se utiliza para maximizar la probabilidad de salida, lo que hace que la secuencia de parámetros sea una secuencia vectorial media, lo que da como resultado una función escalonada. Los saltos provocan discontinuidades en el discurso sintetizado. Para abordar este problema, se utiliza el algoritmo de generación de parámetros de máxima verosimilitud (MLPG) para suavizar la trayectoria teniendo en cuenta las características dinámicas. Sin embargo, los métodos basados en DNN no pueden sufrir este problema.(Ning et al., 2019)

En la síntesis de voz basada en DNN, los árboles de decisión utilizados en los HMM se sustituyen por redes neuronales profundas que asignan el vector de características lingüísticas de entrada a los parámetros de voz de salida para sintetizar el habla resultante. La frecuencia fundamental de la característica de excitación (F0) y las características espectrales se extraen de las bases de datos de voz durante la fase de entrenamiento. Al establecer las entidades de salida predichas de la DNN como vectores medios y precalcular las varianzas globales de las entidades de salida de todos los datos de entrenamiento, el algoritmo de generación de parámetros de voz puede generar trayectorias suaves de entidades de parámetros de voz que concilian las características estáticas y dinámicas de la voz. La Figura 4 muestra la arquitectura básica del uso de DNN para sintetizar voz. En esta figura, el texto que se va a articular se traduce primero en un vector lingüístico de entrada. Este vector se asigna a los parámetros de voz de

salida utilizando una red neuronal profunda y, por último, un módulo de síntesis de forma de onda de vocoder sintetizó la forma de onda del habla.




Fig. 4 Sistema de Síntesis de voz basado en DNN. (Kaur & Singh, 2023)

Sobre la base de la representación del vector de características de voz de entrada y salida, los métodos de aprendizaje profundo se clasifican como modelos generativos profundos (mapeo de clúster a característica), modelo de articulación profunda y modelo condicional profundo (mapeo de entrada a característica). DNN se entrena mediante algoritmos de aprendizaje supervisado, como el algoritmo de propagación de gradiente de descenso hacia atrás. Pero estos algoritmos sufren el problema del sobreajuste de la red. Para superar el problema del sobreajuste, también se ha propuesto en la literatura la DNN pre-entrenada utilizando DBN (*Deep Belief Nets*). Para mejorar la precisión de la modelización acústica de los sistemas basados en DNN, se utilizan máquinas de Boltzmann restringidas (RBM) para modelar las envolventes espectrales. En lugar de

inicializar los pesos de DNN al azar, el DNN se aplica utilizando las DBN con RBM apilado.

Una ventaja de usar DNN sobre HMM es que son capaces de representar automáticamente las dependencias entre las características contextuales de entrada y acústicas de salida del habla. Además, DNN se puede entrenar fácilmente mediante la optimización de minibatches a partir del gran conjunto de datos. Sin embargo, el rendimiento de las redes neuronales profundas en el corpus de habla de múltiples hablantes se mejora al alimentar los códigos de los hablantes en las capas ocultas de la estructura de la red DNN. (Kaur & Singh, 2023)

4.3.3.2.3 Predicción de parámetros basada en RNN

Como alternativa a las DNN, las RNN se utilizan recientemente para las aplicaciones de procesamiento de voz. En RNN, las unidades se conectan para formar un ciclo. Al tener una memoria a corto plazo (LSTM) en RNN, es posible capturar información de la secuencia de características, por lo tanto, se puede mapear el vector de características de texto lingüístico en las características de salida de voz. Comprende una puerta de entrada para determinar cuándo recuperar la entrada, una puerta de salida para enviar la salida y una puerta de olvido para determinar si se olvidan o recuperan los valores. Como se describe en la Fig. 5, el lado izquierdo de la figura representaba el modelo DNN típico, que comprende pocas capas ocultas no lineales constituidas por RBM pre-entrenados y una capa de salida. El lado derecho de la figura muestra que el apilamiento de al menos una capa recurrente comprende RNN bidireccional (BRNN) con LSTM.

Las RNN se utilizan para mejorar el modelo acústico mediante el uso de características lingüísticas categóricas y numéricas para la entrada. Además, en comparación con DNN, RNN con LSTM bidireccional (BLSTM) puede aprender fácilmente los datos de series temporales, por lo tanto, es capaz de modelar las características de coarticulación en la síntesis estadística de voz. Como resultado, estos generan trayectorias de voz suaves en la capa de salida que luego sintetizan voz de alta calidad. Debido a la gran cantidad de computación involucrada en la implementación de BLSTM-RNN, no es fácilmente aplicable a las aplicaciones de síntesis de voz en tiempo real, que es el principal inconveniente de BLSTM-RNN sobre la síntesis de voz basada en DNN. (Kaur & Singh, 2023)




Fig. 5 Estructura RNN para modelar parámetros del habla. (Kaur & Singh, 2023)

4.3.3.3 Síntesis de voz basada en vocoder

El sintetizador de voz o vocoder es un componente importante de la síntesis de voz paramétrica estadística, que tiene como objetivo sintetizar la forma de onda del habla en función de los parámetros de características acústicas estimados. Los métodos tradicionales suelen utilizar el sintetizador HTS_engine, ya que es libre y rápido para sintetizar el habla. Sin embargo, el discurso sintetizado suele sonar aburrido, lo que hace que la calidad no sea buena. Para mejorar la calidad del habla sintetizada, se propone STRAIGHT y se utiliza en varios estudios, lo que facilita la manipulación del habla. También se proponen otros métodos como el vocoder de fase, PSOLA y el modelo sinusoidal. Legacy-STRAIGHT y TANDEM-STRAIGHT se desarrollaron como algoritmos para cumplir con los requisitos de síntesis de voz de alta calidad. Aunque estos métodos pueden sintetizar el habla con buena calidad, la velocidad aún no puede cumplir con los escenarios de aplicación del mundo real. Para abordar este problema, los métodos en tiempo real siguen siendo un tema de investigación popular.

SPSS tiene varias ventajas sobre los sistemas TTS anteriores:

- 1) naturalidad, el audio es más natural;
- 2) flexibilidad, es conveniente modificar los parámetros para controlar la generación de voz;

3) Bajo costo de datos, requiere menos grabaciones que la síntesis concatenativa.

Sin embargo, SPSS también tiene sus inconvenientes:

1) el discurso generado tiene una menor inteligibilidad debido a artefactos como audio amortiguado, zumbante o ruidoso;

2) La voz generada sigue siendo robótica y se puede diferenciar fácilmente de la grabación humana del habla.(Tan et al., 2021)

Cerca de la década de 2010, a medida que las redes neuronales y el aprendizaje profundo lograron un rápido progreso, algunos trabajos introducen por primera vez redes neuronales profundas en SPSS, como las basadas en redes neuronales profundas (DNN) las redes neuronales recurrentes (RNN). Sin embargo, estos modelos sustituyen a los HMM por redes neuronales y siguen prediciendo las características acústicas a partir de las características lingüísticas, que siguen el paradigma de SPSS. Más tarde, se propone generar directamente características acústicas a partir de la secuencia de fonemas en lugar de características lingüísticas, lo que puede considerarse como la primera exploración para la síntesis de voz de extremo a extremo.(Tan et al., 2021)

5 TTS BASADO EN DEEP LEARNING (DL)

Recientemente, el sintetizador de voz basado en el aprendizaje profundo utiliza un modelo autorregresivo (AR) para sintetizar formas de onda de alta fidelidad. Estos modelos generalmente se componen de tuberías en las que primero se genera un espectrograma de Mel a partir de texto escrito y, a continuación, se utiliza un vocoder para generar artificialmente la forma de onda del habla a partir del espectrograma de Mel generado. Dichas estructuras solo requieren audio y la transcripción correspondiente como datos de entrenamiento. Sin embargo, en estos modelos autorregresivos, la síntesis es relativamente lenta debido a la falta de paralelismo en el momento del entrenamiento y la síntesis y el discurso generado no es robusto, las palabras se saltan y, a veces, se repiten.

Ahora, los modelos no autorregresivos (NAR) también se proponen en la literatura para la generación de formas de onda paralelas que poseen una mayor tasa de síntesis, pero una menor precisión en comparación con sus contrapartes AR. La destilación de conocimientos, el mapeo de palabras, las restricciones de alineación de objetivos de origen y la predicción de la duración son algunas de las técnicas que se utilizan para disminuir la privación de precisión.

Por un lado, los TTS autorregresivos son capaces de regenerar voz de alta calidad, por otro lado, los TTS no autorregresivos son capaces de sintetizar voz a alta velocidad.

5.1 TTS BASADO EN MODELOS AUTORREGRESIVOS (AR)

5.1.1 WaveNet

Introducido en 2016 por Google DeepMind, WaveNet (Oord et al., 2016) facilitó la síntesis de voz de extremo a extremo. Es un modelo totalmente autorregresivo y probabilístico. El sonido sintetizado generado por WaveNet es natural. Tiene un modelo de red neuronal de convolución profunda (CNN) que se entrena mediante grabación de voz. Modela la distribución de probabilidad de las formas de onda de audio en función de las formas de onda del habla producidas previamente. Durante la fase de entrenamiento, WaveNet se entrena utilizando una gran grabación de muestras de voz para determinar las estructuras originales de las muestras de voz. A continuación, el habla sintética se genera utilizando una muestra a la vez desde cero con 24.000 muestras por segundo. La voz generada varía según el género, el idioma y el acento. Es compatible con varios idiomas hablados en el mundo como árabe, bengalí, chino (Hong Kong), inglés (Australia), inglés (India) y muchos más. Incluso algunos idiomas admiten varias voces. La Figura 6 muestra la calificación de la Puntuación Media de la Opción (Mean Opinion Scores, MOS) para diferentes voces generadas con WaveNet. La calificación MOS expresa la opinión de las personas sobre la calidad del habla. Los resultados de la prueba que se muestran en la Fig. 6 para la voz en inglés de EE. UU. producida con WaveNet obtuvieron una calificación MOS promedio de 4.1 en la escala de 1 a 5, que es un 20% mejor que la voz estándar. Esto reduce la brecha entre la voz humana natural y la voz sintetizada en un 70%.




Fig. 6 Clasificación MOS de WaveNet para voz en inglés de EE. UU.

5.1.2 Tacotron

Lanzado en 2017, Tacotron (Wang et al., 2017) utiliza un modelo generativo similar a WaveNet para la síntesis de voz de extremo a extremo. Dado un par < texto, audio >, el modelo de Tacotron utilizó la inicialización aleatoria para el entrenamiento. Sintetizó el habla utilizando el modelo seq2seq que mapea el texto lingüístico con el espectrograma Mel. *Dado que el espectrograma Mel no consiste en información de fase, la información de fase faltante se estima utilizando el algoritmo de Griffin-Lim.* Tacotron se aplica a casi todos los idiomas porque utiliza caracteres como unidad básica para sintetizar el habla. Además, tiene una calificación MOS de 3.82 en la escala de 1 a 5 para inglés de EE. UU. y voz sintetizada a nivel de fotograma, lo que lo hace más rápido que WaveNet u otro TTS que sintetiza voz a nivel de muestra. Además, se puede ampliar fácilmente en función de la disponibilidad de datos acústicos de transcripción, por lo que no implica ninguna alineación a nivel de fonema.

5.1.2.1 Tacotron 2

Tacotron-2 es una versión mejorada de Tacotron que fue lanzada por Google en 2018. Combina CNN y RNN para sintetizar el habla natural de alta calidad. El modelo genera el espectrograma mel a partir del texto y, a continuación, se utiliza el vocoder WaveNet modificado para generar formas de onda de voz en el dominio del tiempo a partir de espectrogramas mel basados en frecuencia. En comparación con la versión original de Tacotron, Tacotron-2 utilizaba bloques de construcción simplificados como LSTM y CNN para la codificación y decodificación. La Figura 7 a continuación muestra la clasificación MOS de varios enfoques TTS bien conocidos con Tacotron 2.

Tacotron produjo una canalización más simple al emplear el marco seq2seq con la capacidad de extensión que lo hace apropiado para varias tareas desafiantes como la clonación de voz, adaptando el sistema a un nuevo altavoz.




Fig. 7 Comparación de la clasificación MOS de Tacotron 2 con otros modelos.

5.1.3 Deep-voice

Deep voice TTS (Arik et al., 2017) presentado por primera vez en 2017 por Baidu Silicon Valley Artificial Intelligence Lab. El TTS de Deep Voice se basa en las redes neuronales que comprende un modelo de segmentación, un modelo para cambiar grafema a fonema, modelos para predecir la duración de los fonemas y su valor F0, variante de un modelo WaveNet que necesita menos hiperparámetros para sintetizar el audio.

5.1.3.1 Deep Voice 2

Deep Voice 2 es la variante de Deep Voice 1 que es capaz de generar varias voces utilizando un solo modelo. La arquitectura de Deep Voice 2 es análoga a la de Deep Voice 1 con módulos separados para predecir la duración del fonema y F0. En Deep Voice 1, un solo módulo determina conjuntamente la duración del fonema y su F0. Además, el modelo de segmentación de Deep voice 2 utiliza RNN de convolución con normalización por lotes. La Figura 8 muestra la comparación del sonido sintetizado de Deep Voice 2 con Deep Voice 1 y Tacotron utilizando Griffin-Lim y vocoder basado en WaveNet.




Fig. 8 Comparación de Deep Voice 2 con otros modelos conocidos

5.1.3.2 Deep Voice 3

La tercera variante, Deep Voice 3 (Ping et al., 2018), utiliza una red neuronal de convolución completa que se aprende en el conjunto de datos LibriSpeechASR. La arquitectura de Deep Voice 3 consta de tres componentes principales: un codificador para convertir las características lingüísticas en representaciones internas, un decodificador utilizado para decodificar las representaciones internas aprendidas y un convertidor para convertir las representaciones aprendidas en parámetros de vocoder. La figura 9 representa la comparación de Deep Voice 3 con otros modelos de última generación en la clasificación MOS.




Fig. 9 Comparación de Deep Voice 3 con otros modelos de última generación.

5.2 TTS BASADO EN UN MODELO NO AUTORREGRESIVO (NAR)

5.2.1 ParaNet

ParaNet (Peng et al., 2020) es un TTS no autorregresivo totalmente convolucional basado en la atención que genera forma de onda de voz a partir de texto en un solo paso de realimentación. Itera capa por capa y utiliza la destilación de la atención del codificador autorregresivo y refina repetidamente la alineación entre el texto y el espectrograma Mel. Tiene un codificador similar al de Deep Voice 3 autorregresivo, excepto el decodificador paralelo que se compone en primer lugar de un bloque de atención para la codificación posicional, seguido de un bloque de convolución completa y un bloque de atención más. Para mejorar el rendimiento, también predice espectrogramas log-lineales además de espectrogramas log-Mel. Cuando se compara con el modelo autorregresivo, se encuentra que es 254 veces más rápido que los modelos autorregresivos para la síntesis en tiempo real y una velocidad de hasta 46,7 veces, como se muestra en la Tabla 1.

Tabla 1 Comparación del tiempo de síntesis y MOS de ParaNet y Deep Voice 3

TTS	Synthesis time (ms)	MOS Score
Deep Voice 3 + WaveNet	$181.8 + 5 \times 10^5$	4.09 ± 0.26
ParaNet + WaveNet	$3.9 + 5 \times 10^5$	4.01 ± 0.24
Deep Voice 3 + WaveVAE (variational autoencoder)	$181.8 + 64.9$	3.70 ± 0.29
ParaNet + WaveVAE	$3.9 + 64.9$	3.31 ± 0.32

5.2.2 Tacotron paralelo

Parallel Tacotron (Elias et al., 2021) es un modelo TTS no autorregresivo de convolución ligera cuyo entrenamiento y síntesis se realiza en paralelo utilizando un autocodificador

variacional que captura de manera competente los contextos locales. Su variante, Parallel Tacotron 2, es un modelo de síntesis de texto a voz de extremo a extremo no autorregresivo de red neuronal cuyo modelo de duración se basa en la destilación de la atención y el refinamiento iterativo utilizando el envoltorio de tiempo dinámico suave para reducir la pérdida de espectrograma. Durante el entrenamiento, no se basa ni en las señales de duración supervisada ni en el forzamiento de la duración objetivo por parte del modelo maestro, sino que utiliza un modelo de duración totalmente diferenciable para propagar gradientes de error a la red, como resultado, sintetiza el sonido de forma más natural y rápida en comparación con Parallel Tacotron. La Tabla 2 a continuación, muestra la comparación de ambos Parallel Tacotron en la clasificación y preferencia de MOS.

Tabla 2 Comparación de sonidos sintetizados usando Parallel Tacotron y Parallel Tacotron 2

	Natural speech	Parallel Tacotron	Parallel Tacotron 2
MOS	4.49 ± 0.05	4.42 ± 0.05	4.46 ± 0.05
Preference	Reference	-0.08 ± 0.09	0.01 ± 0.09

5.2.3 FastSpeech

Propuesto por un equipo de investigación de Microsoft y la Universidad de Zhejiang, FastSpeech TTS (Ren et al., 2019) es capaz de producir el espectrograma Mel 270x y voz en un 38x mediante la generación de espectrograma Mel en paralelo. Predice la duración del fonema extrayendo la atención del modelo maestro utilizado en modelos autorregresivos utilizando la pérdida de error cuadrático medio (MSE) y tiene seis bloques de transformación de avance para convertir la secuencia de fonemas en una secuencia de espectrograma Mel. Cualquier desajuste de longitud que se encuentre en ambas secuencias se salva mediante un regulador de longitud. Sin embargo, no determina con precisión la duración utilizando el modelo maestro y el espectrograma de Mel generado también conlleva la pérdida de información, ya que estos se simplifican utilizando el modelo maestro, lo que reduce la calidad final del habla.

Estas limitaciones se abordan en su variante FastSpeech 2 (Ren et al., 2022). La pérdida de información, en este caso, se evita entrenando FastSpeech 2 directamente desde el objetivo de la verdad sobre el terreno en lugar de utilizar datos simplificados del modelo maestro. Este modelo determina los valores de duración, tono y energía del habla objetivo y utiliza el método de transformación de ondículas continuas para traducir el contorno de tono en espectrograma de tono. Alcanza el 3x de velocidad con respecto

a su versión original FastSpeech mediante el uso de canalización de entrenamiento simplificada y voz de alta calidad.

5.2.4 Parallel WaveNet

El Parallel WaveNet (Oord et al., 2017) utiliza una red de alimentación paralela que utiliza el método de destilación de densidad de probabilidad para el entrenamiento. Este modelo genera formas de onda de voz de alta fidelidad utilizadas en línea por la aplicación Google Assistant. Puede sintetizar varias voces de hablantes con diferentes acentos. La figura 11 ofrece la comparación de la clasificación MOS en voces en inglés y japonés utilizando WaveNet paramétrico, concatenativo y destilado, y la puntuación MOS significativamente mejorada que se puede lograr con Distilled WaveNet. (Kaur & Singh, 2023)




Fig. 10 Comparación de la puntuación MOS en inglés y japonés con Wavenets destiladas de varios hablantes

6 VENTAJAS DE LA SÍNTESIS DE VOZ NEURONAL

En comparación con los sistemas TTS anteriores basados en síntesis concatenativa y síntesis paramétrica estadística, las ventajas de la síntesis de voz basada en redes neuronales incluyen una alta calidad de voz en términos de inteligibilidad y naturalidad, y menos requisitos de preprocesamiento humano y desarrollo de características. (Tan et al., 2021)

También cabe mencionar:

Personalización: La síntesis de habla neuronal permite personalizar la voz para diferentes aplicaciones y usuarios, como la creación de una voz única para una marca o la adaptación de la voz a las preferencias del usuario.

Flexibilidad: La síntesis de habla neuronal puede generar voz en tiempo real y adaptarse a diferentes idiomas, acentos y estilos de habla.

Escalabilidad: La síntesis de habla neuronal puede generar grandes cantidades de voz en poco tiempo, lo que la hace adecuada para aplicaciones como la generación de noticias personalizadas o la creación de contenido de audio para redes sociales.

Accesibilidad: La síntesis de habla neuronal puede mejorar la accesibilidad para personas con discapacidades visuales o de lectura, al permitirles escuchar texto en lugar de leerlo.

Reducción de costos: La síntesis de habla neuronal puede reducir los costos asociados con la grabación y edición de audio, así como con la contratación de actores de voz.

7 CONCLUSIONES

El trabajo presenta una descripción detallada de las diferentes técnicas de síntesis de voz, incluyendo la síntesis articulatoria, la síntesis por concatenación, la síntesis paramétrica y la síntesis estadística paramétrica. También se discuten las ventajas y desventajas de cada técnica, así como las aplicaciones potenciales de la síntesis de voz en diferentes campos. En general, proporciona una visión bastante amplia de las técnicas de síntesis de voz y su importancia en la investigación y el desarrollo de tecnologías de voz.

8 REFERENCIAS

- Arik, S. O., Chrzanowski, M., Coates, A., Diamos, G., Gibiansky, A., Kang, Y., Li, X., Miller, J., Ng, A., Raiman, J., Sengupta, S., & Shoeybi, M. (2017). *Deep Voice: Real-time Neural Text-to-Speech* (arXiv:1702.07825). arXiv. <http://arxiv.org/abs/1702.07825>
- Balyan, A., Agrawal, S. S., & Dev, A. (2013). Speech Synthesis: A Review. *International Journal of Engineering Research*, 2(6).
- Elias, I., Zen, H., Shen, J., Zhang, Y., Jia, Y., Skerry-Ryan, R. J., & Wu, Y. (2021). *Parallel Tacotron 2: A Non-Autoregressive Neural TTS Model with Differentiable Duration Modeling* (arXiv:2103.14574). arXiv. <http://arxiv.org/abs/2103.14574>
- Furui, Sadaoki. (2001). *Digital speech processing, synthesis, and recognition* (2nd ed., rev.expanded). Marcel Dekker.
- Holmes, J. N. & Holmes, Wendy. (2001). *Speech synthesis and recognition* (2nd ed.). Taylor & Francis.
- Kaur, N., & Singh, P. (2023). Conventional and contemporary approaches used in text to speech synthesis: A review. *Artificial Intelligence Review*, 56(7), 5837-5880. <https://doi.org/10.1007/s10462-022-10315-0>
- Kayte, S., Mundada, M., & Kayte, C. (2015). Performance Evaluation of Speech Synthesis Techniques for Marathi Language. *International Journal of Computer Applications*, 130(3), 45-50. <https://doi.org/10.5120/ijca2015907023>
- Ning, Y., He, S., Wu, Z., Xing, C., & Zhang, L.-J. (2019). A Review of Deep Learning Based Speech Synthesis. *Applied Sciences*, 9(19), 4050. <https://doi.org/10.3390/app9194050>
- Oord, A. van den, Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, A., & Kavukcuoglu, K. (2016). *WaveNet: A Generative Model for Raw Audio* (arXiv:1609.03499). arXiv. <http://arxiv.org/abs/1609.03499>
- Oord, A. van den, Li, Y., Babuschkin, I., Simonyan, K., Vinyals, O., Kavukcuoglu, K., Driessche, G. van den, Lockhart, E., Cobo, L. C., Stimberg, F., Casagrande, N., Grewe, D., Noury, S., Dieleman, S., Elsen, E., Kalchbrenner, N., Zen, H., Graves, A., King, H., ... Hassabis, D. (2017). *Parallel WaveNet: Fast High-Fidelity Speech Synthesis* (arXiv:1711.10433). arXiv. <http://arxiv.org/abs/1711.10433>
- Peng, K., Ping, W., Song, Z., & Zhao, K. (2020). *Non-Autoregressive Neural Text-to-Speech* (arXiv:1905.08459). arXiv. <http://arxiv.org/abs/1905.08459>
- Ping, W., Peng, K., Gibiansky, A., Arik, S. O., Kannan, A., Narang, S., Raiman, J., & Miller, J. (2018). *Deep Voice 3: Scaling Text-to-Speech with Convolutional Sequence Learning* (arXiv:1710.07654). arXiv. <http://arxiv.org/abs/1710.07654>

- Ren, Y., Hu, C., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, T.-Y. (2022). *FastSpeech 2: Fast and High-Quality End-to-End Text to Speech* (arXiv:2006.04558). arXiv. <http://arxiv.org/abs/2006.04558>
- Ren, Y., Ruan, Y., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, T.-Y. (2019). *FastSpeech: Fast, Robust and Controllable Text to Speech* (arXiv:1905.09263). arXiv. <http://arxiv.org/abs/1905.09263>
- Tan, X., Qin, T., Soong, F., & Liu, T.-Y. (2021). *A Survey on Neural Speech Synthesis* (arXiv:2106.15561). arXiv. <http://arxiv.org/abs/2106.15561>
- Wang, Y., Skerry-Ryan, R. J., Stanton, D., Wu, Y., Weiss, R. J., Jaitly, N., Yang, Z., Xiao, Y., Chen, Z., Bengio, S., Le, Q., Agiomyrgiannakis, Y., Clark, R., & Saurous, R. A. (2017). Tacotron: Towards End-to-End Speech Synthesis. *Interspeech 2017*, 4006-4010. <https://doi.org/10.21437/Interspeech.2017-1452>